**Roteiro – 5 minutos.** Alvo: **4min35s** (25 s de folga), cerca de 690 palavras faladas (uns 150 por minuto), sem pressa. As marcas de tempo de cada página dizem onde você deve estar. Os desenhos das redes são rápidos: 10 a 20 s cada.

**Três ideias que o público precisa levar:** (1) cada camada do modelo vira uma rede sobre *as mesmas* ocorrências de tokens; (2) a rede deixa de ser organizada pela identidade do token, e no meio do modelo aparece o tema; (3) no fim aparece outra organização: *hubs* e a posição do token na palavra.

**Se o tempo apertar:** no slide dos graus, diga só a última frase; os de clusterização e de componentes podem passar sem fala; no de L01, diga só "no bloco 1, quase nada muda"; na construção, pule "no máximo 50 por token". Marcas de controle: **2:05** ao sair da construção, **3:05** ao sair das componentes, **4:20** ao sair do último desenho.

**0:00 → 0:10**

**Fala.** Boa tarde! Eu sou a Juliana. O meu projeto usa redes complexas para ver como um modelo de linguagem reorganiza as palavras, camada

## 0:10 → 0:40



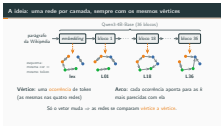

**Fala.** O modelo divide o texto em tokens: palavras ou partes de palavras; "polissêmica", por exemplo, vira quatro tokens. Cada token começa com um vetor, uma lista de números. A cada camada, sua representação é atualizada com informações do texto anterior. Aqui, o mesmo token "banco" aparece em três contextos. Sabemos que o contexto muda essas representações. Neste trabalho, queremos entender como isso reorganiza as relações de semelhança entre elas.

**Aponte:** o esquema de cima, da esquerda para a direita; depois, as frases com "banco".

**Se perguntarem:** a divisão de "polissêmica" é a do Qwen3; as cores são ilustrativas (cada casa é um número). O modelo só olha para o texto anterior (as linhas nos blocos); por isso, nos exemplos, o contexto vem antes de "banco". O vetor inicial (*embedding*) é o mesmo quando o token é o mesmo.

**Transição:** "Para responder, eu transformo cada camada numa rede."

## 0:40 → 1:05




**Fala.** A ideia é transformar cada camada numa rede. Eu guardo o vetor de cada ocorrência de token em quatro pontos: na entrada e na saída dos blocos 1, 18 e 36, o último. Em cada ponto, cada ocorrência aponta para as mais parecidas com ela. Os vértices são os mesmos nas quatro redes; só muda o vetor. Então dá para comparar as redes vértice a vértice.

**Aponte:** as duas bolinhas laranja (o mesmo token): ligadas na entrada, separadas no fim. É só um esquema.

**Transição:** "Com isso, o que eu quero descobrir é. . . "

**1:05 → 1:30**




**Fala.** O objetivo é medir quanto e como essa estrutura muda: quanto a rede muda, em que camadas, se aparecem comunidades de contexto, como o tema, e se as ocorrências de “banco” se separam pelo sentido. Eu espero menos arcos entre ocorrências do mesmo token, clusterização menor e mais arcos dentro do mesmo tema.

**Transição:** “Agora, como as redes foram construídas.”

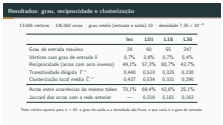
**1:30 → 2:05**




**Fala.** Os dados são artigos da Wikipédia em português, de oito temas. Os vértices são 13.606 ocorrências de cerca de 2.900 tokens, no máximo 50 por token. O modelo é o Qwen3, com 4 bilhões de parâmetros e 36 blocos; na rede lex, o vetor é o *embedding*, igual para todas as ocorrências do token. Cada ocorrência aponta para as 10 mais parecidas pelo cosseno, em qualquer parágrafo. Então a rede é direcionada: todo vértice tem grau de saída 10, e o grau de entrada, quantos o escolheram, varia.

**Transição:** "E o que as métricas mostram?"

## 2:05 → 2:25




**Fala.** Estas são as métricas das redes direcionadas. Na entrada, 70% dos arcos ligam ocorrências do mesmo token; na última camada, só 25%. A transitividade e a clusterização caem quase pela metade. E, depois do bloco 1, a sobreposição dos arcos com a rede anterior fica abaixo de 0,2.

**Aponte:** a linha dos arcos do mesmo token e, depois, a do Jaccard.

**Se perguntarem:** a reciprocidade sobe até L18 (61%) e cai em L36 (44%), a camada em que aparecem os *hubs*.

**Transição:** "E quem alcança quem?"

## 2:25 → 2:45




**Fala.** As componentes fortes, onde todo mundo alcança todo mundo, contam a mesma história: em lex, os grupos de um token apontam só para dentro, e só 18% dos pares têm caminho. Em L18, a maior componente forte tem 95% dos vértices, e as distâncias são as menores. Em L36, o alcance cai para 80%.

**Aponte:** a linha dos pares com caminho e, depois, a da eficiência.

**Transição:** "As figuras mostram as distribuições."

## 2:45 → 2:55

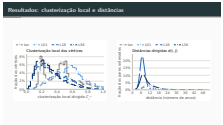



**Fala.** O grau de entrada: à esquerda, a fração de vértices com cada grau; à direita, com pelo menos esse grau. Em L36 a cauda vai até 247: são os *hubs*.

**Se perguntarem:** $P(K = d)$ é a fração de vértices com grau de entrada exatamente $d$, e $P(K \geq d)$, com pelo menos $d$. O piso perto de $10^{-4}$ é um vértice só (1 em 13.606). Os de grau 0 (0,7% a 5,4%) não cabem no eixo logarítmico.

**Se o tempo apertar:** diga só a última frase.

## 2:55 → 3:00




**Fala.** A clusterização local cai para perto de 0,2, e em L18 os pares ficam mais perto.

**Se perguntarem:** a área sob cada curva das distâncias é a fração de pares com caminho; os demais têm distância infinita.

## 3:00 → 3:05




**Fala.** E as componentes fortes: em L18, uma só reúne quase toda a rede.

**Se perguntarem:** cada painel dá quantas componentes fortes (eixo vertical) têm cada tamanho (eixo horizontal); o título dá o total, e o rótulo, o tamanho da maior.

**Transição:** "E como essas redes ficam desenhadas?"

**3:05 → 3:20**




**Fala.** Agora os desenhos, um por rede. O layout é UMAP, as cores são os temas, e o desenho ignora o sentido dos arcos. Na entrada, a rede é um monte de grupinhos, quase sempre ocorrências de um mesmo token, com os temas misturados.

## 3:20 → 3:30

**Fala.** No bloco 1, quase nada muda: ainda grupinhos de um token, com temas misturados, como a tabela já mostrava.



**3:30 → 3:50**




**Fala.** No bloco 18, os grupos se fundem num bloco central, e aparecem regiões de um tema só, como física em azul e computação em rosa. Mais da metade dos arcos, 55%, liga ocorrências do mesmo tema. O contexto aparece no meio do modelo.

**Aponte:** a região azul e a rosa.

## 3:50 → 4:00

**Fala.** No último bloco, a rede se divide em dois blocos, e o tema perde força: 47% dos arcos. O que separa os dois blocos?



## 4:00 → 4:20




**Fala.** É a posição do token na palavra. Em azul, os tokens em que a palavra continua no token seguinte, como os pedaços de uma palavra longa. O bloco menor é 94% azul. Perto da saída, o modelo agrupa os tokens pelo que vem depois, e não pelo tema. Essa foi a surpresa da visualização.

**Aponte:** o bloco azul.

**Se perguntarem:** isso combina com a tarefa do modelo, que é prever o próximo token; é uma interpretação, ainda não testada.

**4:20 → 4:35**




**Fala.** Resumindo: a rede deixa de ser organizada pelo token; no meio aparece o tema; e no fim, *hubs* e a divisão pela posição na palavra. As redes interativas estão no QR code. Obrigada!

## Perguntas prováveis (1/3)




**Por que $k$ vizinhos e não um limiar de similaridade?** Com $k$ fixo, toda ocorrência faz o mesmo número de escolhas em todas as camadas. A distribuição dos cossenos muda de uma camada para outra, então o mesmo limiar daria redes de densidades muito diferentes.

**Por que a rede direcionada?** É o que o $k$-NN produz: $i$ escolher $j$ não implica o contrário (só 44% a 61% dos arcos têm o arco inverso). Como o grau de saída é fixo em 10, a informação está no grau de entrada, que mostra os *hubs*. A versão não direcionada (por união) também foi calculada e mostra a mesma tendência.

**E a distância média?** Muitos pares não têm caminho (82% em lex), e a distância deles é infinita. Entre os pares com caminho, a média é 10,4 (lex), 11,3 (L01), 7,0 (L18) e 10,0 (L36): L18 é a rede em que se chega mais longe e mais rápido.

## Perguntas prováveis (2/3)




**E os empates na rede lex?** Ocorrências do mesmo token têm o mesmo vetor (cosseno 1), então quem entra entre os 10 vizinhos é sorteado, com semente fixa. Por isso o Jaccard entre lex e L01 (0,32) subestima a semelhança. A robustez a outras sementes e a outros tratamentos de empate ainda não foi testada.

**Por que o Qwen3-4B-Base?** É aberto, atual, multilíngue, tem 36 blocos (dá para fazer a curva camada a camada) e cabe numa GPU de 8 GiB. A versão *Base* é o modelo treinado só para prever o próximo token, sem o ajuste para conversa. O custo é que ele quebra muito o português em pedaços; por isso as medidas são separadas por categoria de token.

**Por que só quatro camadas?** A entrega parcial compara entrada, início, meio e fim. Os vetores das 36 camadas já foram extraídos, para a curva camada a camada.

**Perguntas prováveis (3/3)**




**O que é o tema?** A categoria da Wikipédia de onde veio o artigo (“esporte” é a categoria Futebol).

**Por que o desenho não tem setas?** Com 136 mil arcos, as setas não seriam legíveis. O UMAP usa os arcos sem o sentido; ele aproxima vértices ligados e afasta os não ligados. A posição e a orientação absolutas não têm significado. Cada slide mostra o miolo da rede; de 2% a 4% dos vértices ficam de fora (eles estão na página interativa).

***Hubs*?** Em espaços de alta dimensão, algumas representações viram vizinhas de muitas outras (*hubness*). Em L36, uma ocorrência é escolhida por 247 outras, e 5,4% não são escolhidas por ninguém.

**De onde vêm os 94%?** Das comunidades (Leiden, resolução baixa) da visualização: o bloco menor de L36 tem 4.012 vértices, e 94% deles são “continua”.