MO438 – Redes Complexas: Relatório Final

Da rede lexical à rede contextual

Como um Transformer reorganiza as ocorrências de tokens, visto por redes complexas

Juliana Midlej do Espirito Santo (RA 200208)
Unicamp. Números da execução de 12/11/2026.

Resumo

Na entrada de um Transformer, todas as ocorrências de um mesmo token são representadas pelo mesmo vetor; ao atravessar as camadas, cada ocorrência passa a carregar o texto em que aparece. Este trabalho descreve essa passagem com redes complexas. Os vértices são 13.606 ocorrências de tokens em parágrafos da Wikipédia em português, de oito temas, e cada vértice se liga aos 10 vértices de vetor mais parecido (k vizinhos mais próximos pelo cosseno). Os mesmos vértices recebem quatro vetores do modelo Qwen3-4B-Base: o *embedding* de entrada e as saídas dos blocos 1, 18 e 36. As quatro redes têm, portanto, os mesmos vértices e podem ser comparadas vértice a vértice. No bloco 1, a rede ainda é praticamente a rede lexical: as ocorrências de um token continuam vizinhas umas das outras. A reorganização vem depois e é grande. No bloco 36, uma ocorrência mantém em média menos de 2 dos seus 10 vizinhos lexicais, a fração de vizinhos do mesmo token cai de 0,70 para 0,25 (ainda muito acima do acaso), surgem *hubs* e as distâncias encurtam. As comunidades deixam de seguir o token e passam a seguir o contexto: nos blocos do meio (do 12 ao 19, aproximadamente), elas concordam mais com o artigo, o parágrafo e o tema de origem do que com o próprio token; nos últimos blocos, essa concordância cai e cresce a concordância com o próximo token. Palavras ambíguas, como *banco*, *órgão* e *matriz*, separam as suas ocorrências por tema e por sentido mais do que palavras de sentido estável. O texto descreve também a coleta dos dados, a construção das redes, o tratamento dos empates e as limitações do estudo.

1 Introdução

Um modelo de linguagem do tipo Transformer lê o texto como uma sequência de *tokens* (palavras ou pedaços de palavras) e representa cada um por um vetor. Na entrada, esse vetor é uma linha de uma tabela fixa, a matriz de *embeddings*: todas as ocorrências da palavra *banco* começam com exatamente o mesmo vetor, seja num texto sobre finanças, sobre computação ou sobre geografia. Ao atravessar os blocos do modelo, cada vetor é atualizado com informação dos tokens anteriores, e as ocorrências de um mesmo token deixam de ser iguais. No último bloco, o vetor de uma ocorrência serve para prever o *próximo* token do texto, e não mais para identificar o token atual.

Este trabalho pergunta **como** essa reorganização acontece: quanto da estrutura de semelhança entre os vetores continua organizada pela identidade do token e quanto passa a refletir o contexto, e em que camadas isso muda. Estudos anteriores mediram essa passagem com médias sobre pares de vetores, como o cosseno médio entre as ocorrências de uma palavra [3]. Essas médias dizem quanto os vetores se afastam, mas não dizem *quem é vizinho de quem*, nem se a mudança é só local (troca de alguns vizinhos) ou se altera a organização em escala maior (*hubs*, distâncias, comunidades).

1.1 A ideia: uma rede por camada, com os mesmos vértices

Representamos cada espaço de vetores por uma **rede de k vizinhos mais próximos** (k-NN): cada vértice é uma *ocorrência* de um token num parágrafo, e cada vértice se liga aos $k = 10$ vértices cujos vetores têm o maior cosseno com o seu. Os mesmos vértices recebem quatro vetores: o *embedding* de entrada do seu token (a rede `lex`) e a saída dos blocos 1, 18 e 36 do modelo (as redes `L01`, `L18` e `L36`). As quatro redes têm exatamente os mesmos vértices e diferem só nas arestas. Isso traz três vantagens:

- **comparação vértice a vértice**: a vizinhança de uma ocorrência pode ser comparada diretamente entre camadas, e a fração de vizinhos que são o mesmo token mede quanto a identidade lexical

ainda manda;

- **escalas diferentes**: as medidas de redes complexas separam o que acontece em volta de cada vértice (vizinhança, clusterização) do que acontece na rede inteira (distribuição de graus, *hubs*, distâncias, componentes, comunidades);
- **rótulos externos**: as comunidades encontradas podem ser comparadas com partições conhecidas dos vértices (o token, o tema, o artigo, o parágrafo, a sentença e o próximo token), o que transforma "a rede ficou contextual" numa afirmação mensurável.

1.2 Perguntas e hipóteses

P1. Quanto e de que forma a organização muda? Medimos a troca de vizinhos de cada ocorrência entre a rede lexical e cada camada, a fração de vizinhos do mesmo token e as métricas globais. *Hipótese H1:* a fração de vizinhos do mesmo token cai ao longo das camadas, mas continua acima do acaso no bloco 36; surgem *hubs* diferentes e as comunidades se alinham menos ao token.

P2. Em que camadas a mudança se concentra? Comparamos as transições entre as redes e acompanhamos as medidas nos 36 blocos. *Hipótese H2:* pedaços de palavras precisam dos tokens vizinhos para formar uma palavra e devem mudar mais cedo do que palavras inteiras.

P3. Surgem comunidades associadas a contextos semelhantes? Comparamos as comunidades de cada rede com o token, o tema, o artigo, o parágrafo, a sentença e o próximo token. *Hipótese H3:* a concordância com o token cai e a com o contexto sobe; no último bloco, cresce a concordância com o próximo token.

P4. As ocorrências de um mesmo token se separam conforme o contexto? Olhamos palavras com sentidos diferentes em temas diferentes (*banco*, *campo*, *órgão*...). *Hipótese H4:* essas palavras separam as suas ocorrências, por tema e por sentido, mais do que palavras de controle de sentido estável (*ano*, *grande*, *água*...).

1.3 Resumo dos resultados

As quatro hipóteses se confirmam, com nuances. O bloco 1 quase não muda a rede; a mudança grande acontece entre os blocos 1 e 36 e continua até o último bloco. A identidade do token perde espaço mas não some: no bloco 36, um quarto dos vizinhos ainda é o mesmo token. Os pedaços de palavra que continuam uma palavra mudam mais cedo; os que começam uma palavra mantêm a identidade até o fim. A organização pelo contexto não cresce de forma monótona: ela tem um máximo nos blocos do meio (cerca de 12 a 19), onde as comunidades seguem o artigo e o parágrafo, e cede lugar, nos últimos blocos, a uma organização pelo próximo token, com *hubs* fortes. As palavras ambíguas se separam por tema e, mais ainda, por sentido; as de controle se separam bem menos.

1.4 Organização do texto

A Seção 2 descreve os dados: como os artigos da Wikipédia foram escolhidos e limpos e como a amostra de ocorrências foi montada. A Seção 3 descreve o modelo, como cada ocorrência vira um vetor e como as redes são construídas, incluindo o tratamento dos empates. A Seção 4 define as medidas, a Seção 5 apresenta os resultados, a Seção 6 testa se eles dependem das escolhas de construção, a Seção 7 junta as respostas e a Seção 8 discute as limitações. O código, os dados e um relatório técnico mais longo, com todas as decisões e os problemas encontrados, estão em https://github.com/annwith/gender-representation-networks.

2 Dados: da Wikipédia à amostra de ocorrências

Os vértices das redes são ocorrências de tokens em parágrafos reais da Wikipédia em português. Esta seção descreve o caminho dos dados em duas etapas. Primeiro, montamos um **corpus**: 2.153 artigos de

oito temas, limpos e divididos em 17.066 parágrafos de prosa corrida. Depois, sorteamos desse corpus uma **amostra** de 13.606 ocorrências, que são os vértices de todas as redes. A página interativa https://annwith.github.io/gender-representation-networks/coleta/ mostra a coleta, a amostra e a construção das redes passo a passo.

2.1 Temas e categorias da Wikipédia

A Wikipédia organiza os artigos em **categorias**. Uma categoria contém artigos e outras categorias (subcategorias), e essas ligações formam uma hierarquia: a categoria Física contém subcategorias como Cosmologia e Efeitos físicos, que têm as suas próprias subcategorias, e assim por diante. Usamos essa hierarquia para definir **temas** de forma reproduzível: um tema é o conjunto de artigos alcançados a partir de uma categoria raiz.

São oito temas (Tabela 1). Eles foram escolhidos distantes entre si, para que o vocabulário de cada um seja característico, e de modo que as palavras ambíguas da P4 tenham sentidos diferentes em pelo menos dois deles: *banco* é instituição financeira em Economia, banco de dados em Computação e banco de areia em Geografia. O tema tem dois papéis na análise: é um dos rótulos de contexto da P3 e serve como indicador aproximado do sentido de uma palavra ambígua na P4. O modelo nunca vê o tema; ele é só um rótulo usado na análise.

Tabela 1: Os oito temas. "Artigos" conta os artigos mantidos no corpus, vindos da árvore da categoria raiz e das categorias extras (Seção 2.3). A última coluna resume de onde vieram os 150 artigos da raiz, pelas subcategorias que mais contribuíram.

Tema	**Categoria raiz**	**Artigos**		**O que a busca trouxe da raiz**
		raiz	extras	
Física	Física	150	–	conceitos e efeitos físicos, astronomia, história e organizações da física; também prêmios (33 artigos) e livros de física
Biologia	Biologia	150	240	membros diretos da raiz (78), biotecnologia (36), biomedicina, divisões da biologia
Economia	Economia	150	300	membros diretos da raiz (34), terminologia e indicadores econômicos, economia financeira, teorias e modelos
Política	Política	150	–	membros diretos da raiz (45), ciência política (37), direitos humanos (29), constituições, corrupção
Computação	Ciência da computação	150	173	membros diretos da raiz (123); armazenamento de dados, cibernética
Música	Música	150	60	armazenamento de áudio, gêneros, subculturas e instrumentos musicais, história e indústria da música
Esporte	Futebol	150	–	terminologia, regras e história do futebol, futebol por continente e por país, jogos eletrônicos e hinos de futebol
Geografia	Geografia	150	180	cartografia, geomática, acidentes geográficos, termos geográficos

2.2 Busca pelas categorias

Para cada tema, uma **busca em largura** parte da categoria raiz e desce pelas subcategorias até a **profundidade 2**: a raiz é a profundidade 0, as suas subcategorias são a profundidade 1 e as subcategorias delas, a 2. A busca guarda os títulos de artigos que encontra, até **600 títulos por tema**, e segue três regras:

- só entram páginas do domínio principal (artigos), e não páginas de usuário, predefinições ou discussões;

- não abre subcategorias de manutenção, cujo nome começa com "!" na Wikipédia em português (esboços, avaliação de qualidade, predefinições, portais), nem subcategorias de listas ("Listas de. . . ");
- descarta os títulos "Lista de. . . ", que não são prosa.

A busca registra também, para cada título, *todos* os temas que chegam a ele, o que permite descartar as páginas que pertencem a mais de um tema (Seção 2.4). Depois, os títulos de cada tema são embaralhados com uma semente fixa e baixados em lotes de 50, e os artigos que passam pelos filtros entram até completar **150 por tema**. Todas as respostas da API ficam guardadas em disco, e a revisão exata de cada artigo (`revid`) fica registrada; assim o mesmo texto pode ser obtido de novo, mesmo que os artigos mudem.

Por que limitar a busca, e o que isso custa. A árvore de categorias da Wikipédia não é uma taxonomia limpa: em poucos níveis, uma categoria de ciência chega a pessoas, lugares e obras. Por isso a busca vai só até a profundidade 2 e para em 600 títulos. Esse corte, porém, **não é aleatório**. A API lista os membros de uma categoria em ordem alfabética, e a busca abre as subcategorias nessa ordem; quando o limite é atingido, as que ainda estão na fila nunca são abertas. Os oito temas atingiram o limite, e a busca abriu só uma parte das subcategorias que encontrou: de 7 de 79 (Computação) a 98 de 439 (Música). Em Biologia, Política e Computação, o corte veio antes de terminar a profundidade 1. Em Futebol, a busca parou no meio da lista de subcategorias por país, em "Futebol das Bahamas": dos 150 artigos mantidos, 29 vêm de países de Afeganistão a Azerbaijão e nenhum do Brasil ou de Portugal. A profundidade também varia: em Computação, 123 dos 150 artigos são membros diretos da raiz; em Geografia, 105 vêm da profundidade 2. A última coluna da Tabela 1 mostra o efeito: cada tema representa as subcategorias mais próximas da raiz e alfabeticamente primeiras, e não a área inteira, e inclui artigos pouco típicos (prêmios em Física; em Futebol, canções pop que viraram hinos de torneios, como "Colors", de Jason Derulo e Maluma). Como o objetivo é ter temas bem separados, e não medir o vocabulário de cada área, isso é aceitável, mas os nomes dos temas devem ser lidos como "artigos próximos da categoria raiz".

2.3 Categorias extras

Alguns sentidos das palavras ambíguas quase não aparecem no tema que os representa. Num estudo preliminar (Seção 2.7), *nota* no sentido de cédula tinha só 7 ocorrências em Economia, *carga* tributária 6, *órgão* do corpo 6 em Biologia e *banco* de areia 4 em Geografia. Para esses casos, o corpus inclui **16 categorias extras**, cada uma ligada a um dos oito temas (Tabela 2). A busca nelas vai só até a profundidade 1 e fica com até 60 artigos por categoria. Um artigo de uma categoria extra pertence, para todos os efeitos, ao tema a que ela está ligada: um artigo de Numismática é um artigo de Economia. Por isso o número de artigos varia entre os temas (de 150 em Física, Política e Esporte a 450 em Economia).

2.4 Páginas descartadas: multitema, biografias e outras

Um artigo encontrado pela busca é descartado em cinco casos (Tabela 3):

- **Página multitema**: o artigo é alcançado a partir de mais de um tema, contando as categorias extras. Exemplos reais: "Prêmio Nobel" (Física e Economia), "Harmonices Mundi" (Física e Música) e "Big science" (Física e Política). Uma página assim mistura o vocabulário de dois temas e borraria justamente o rótulo de tema usado na P3 e na P4. Foram 108 descartes.
- **Biografia**, reconhecida pela caixa de informações do artigo (predefinições `Info/Biografia`, `Info/Futebolista`, `Info/Político`, `Info/Músico`, `Info/Cientista` e outras 9). Biografias aparecem em quase todas as árvores de categorias e falam de datas, lugares e carreiras, um vocabulário que não é o do tema. Foram 68.

Tabela 2: As 16 categorias extras e o sentido que cada uma reforça.

Tema	Categoria extra	Sentido reforçado
Economia	Numismática	*nota* (cédula)
	Impostos; Direito tributário	*carga* (tributária)
	Sistema bancário	*banco* (instituição financeira)
	Indústria	*planta* (industrial)
Biologia	Anatomia humana; Órgãos (anatomia)	*órgão* (do corpo)
	Botânica	*planta* (vegetal)
	Taxonomia	*família* (grupo taxonômico)
Computação	Bancos de dados	*banco* (de dados)
	Redes de computadores	*rede* (de computadores)
	Matrizes	*matriz* (matemática)
Geografia	Geomorfologia; Oceanografia	*banco* (de areia), *massa* (de água)
	Hidrografia	*rede* (hidrográfica)
Música	Teoria musical	*nota* (musical)

- **Sem parágrafos**: depois da limpeza (abaixo), não sobra nenhum parágrafo de prosa, em geral porque o artigo é um esboço curto ou é feito de tabelas e listas. Foram 295.
- **Desambiguação** (4) e **duplicada** (3, o mesmo artigo por dois caminhos).

Dos 2.631 candidatos examinados, ficaram 2.153.

2.5 Limpeza dos parágrafos

Os artigos chegam em *wikitext*, a linguagem de marcação da Wikipédia, que mistura o texto com referências, tabelas, fórmulas, caixas de informação e predefinições. A limpeza tem quatro passos.

1. Cortar as seções de apoio. As seções Referências, Ligações externas, Ver também, Bibliografia, Notas, Fontes, Leitura adicional (e variantes) são removidas com as suas subseções. Seções de conteúdo que vêm depois delas são mantidas.

2. Converter em texto, removendo o que não é prosa. A conversão usa a biblioteca `mwparserfromhell`, mas a conversão padrão dela mantém o conteúdo de marcas que não são texto corrido. Antes de converter, a árvore de marcação é reescrita em três pontos:

- referências (`<ref>`), galerias, tabelas, blocos pré-formatados e links para arquivos e categorias são removidos com todo o conteúdo. Sem isso, o texto das referências entrava no meio das frases, colado à palavra anterior ("A energiaSilva, Livro, 2001 é…"), defeito que encontramos no estudo preliminar;
- linhas com fórmulas (`<math>`, `<chem>`) e itens de lista são descartados inteiros, porque apagar só a fórmula deixaria um buraco na frase ("a energia é dada por , onde…"). Fórmulas triviais, de um símbolo ou um número, são mantidas como texto;
- predefinições cujo texto visível é um argumento (números formatados, conversões de unidades) são trocadas por esse texto; as demais (caixas de informação, navegação, pronúncia) são descartadas, e os restos que deixam, como "( )" e ", ,", são limpos.

3. Ficar só com prosa corrida. Um parágrafo é mantido se tem pelo menos 40 palavras, termina como frase (".", "!" ou "?", talvez seguidos de aspas ou parênteses), não começa com marcação de tabela ou lista e tem no máximo 8% de dígitos (o que elimina tabelas de resultados e cronologias). Parágrafos repetidos, comuns porque há texto copiado entre artigos, são removidos comparando os 80 primeiros caracteres.

4. Dividir em sentenças. Cada parágrafo é dividido em sentenças por expressão regular, com uma lista de abreviações do português ("Sr.", "séc.", "p.ex.", iniciais de nomes), para dar o rótulo de sentença usado na P3.

O corpus final tem 2.153 artigos, 17.066 parágrafos, 1.509.556 palavras e 2.657.592 tokens do modelo, de 24.667 tokens distintos (Tabela 3).

Tabela 3: O corpus por tema: artigos, parágrafos e palavras mantidos, e artigos descartados por motivo. Os artigos incluem os das categorias extras.

				Descartados por motivo				
Tema	Artigos	Parágrafos	Palavras	multitema	biografia	desambiguação	sem parágrafos	duplicada
Física	150	1.305	124.902	8	3	0	29	0
Biologia	390	2.980	264.888	48	7	1	88	0
Economia	450	4.292	382.254	20	28	0	30	2
Política	150	1.620	159.305	5	6	0	9	0
Computação	323	2.504	196.213	23	7	0	57	0
Música	210	1.056	89.998	1	10	0	20	1
Esporte	150	873	77.754	0	3	0	25	0
Geografia	330	2.436	214.242	3	4	3	37	0
Total	2.153	17.066	1.509.556	108	68	4	295	3

2.6 Tokens, tipos, ocorrências e categorias de token

O modelo não lê palavras, e sim **tokens**, as unidades produzidas pelo seu *tokenizer*. Um token pode ser uma palavra inteira, um pedaço de palavra, um sinal de pontuação ou um dígito. No Qwen3, o espaço antes de uma palavra faz parte do token seguinte (␣`banco` é um token só; o símbolo ␣ marca esse espaço) e cada dígito é um token separado. Usamos três termos:

- **tipo de token**: um elemento do vocabulário do modelo, como ␣`banco`; o número de vezes que um tipo t aparece na amostra é a sua frequência f_t;
- **ocorrência**: uma aparição de um tipo numa posição de um parágrafo. Cada ocorrência da amostra é um **vértice**;
- **palavra**: uma sequência de letras ou dígitos no texto original, antes da tokenização. Uma palavra pode virar vários tokens.

Cada ocorrência recebe uma **categoria de token**, conforme a sua relação com a palavra a que pertence (Tabela 4):

palavra inteira o token cobre sozinho uma palavra (␣`banco`, ␣`de`);

início de palavra o primeiro token de uma palavra dividida em vários (␣`torn` em "tornou");

continuação um token que continua uma palavra já começada (`ou` em "tornou");

pontuação um token sem letras nem dígitos, mas com algum caractere visível (`,`, ␣`(`);

número um token só de dígitos; "1990" vira quatro tokens de número.

Tokens formados só por espaço não viram vértices: eles não têm conteúdo próprio e apareceriam em quase todo parágrafo.

O terceiro exemplo mostra um cuidado necessário na P4: "banco" entre parênteses vira `ban` + `co`, e "Banco" com maiúscula é outro tipo (␣`Banco`). Por isso as palavras ambíguas são contadas *só* no tipo minúsculo precedido de espaço, para que todas as ocorrências comparadas comecem do mesmo vetor de entrada.

O tokenizer do Qwen3 foi treinado sobretudo em inglês, chinês e código, e divide muito o português: no estudo preliminar, foram 1,78 tokens por palavra, e só 28% dos tokens de um texto corrido eram

Tabela 4: Exemplos reais do *tokenizer* do Qwen3-4B-Base e as categorias atribuídas. O símbolo ␣ marca o espaço que faz parte do token.

Texto	Tokens	Categoria	Palavra
"␣1990"	␣	só espaço (não é vértice)	–
	`1`, `9`, `9`, `0`	número	1990
"␣tornou-se"	␣`torn`	início de palavra	tornou
	`ou`	continuação	tornou
	`-se`	palavra inteira	se
"␣(banco)"	␣`(`	pontuação	–
	`ban`	início de palavra	banco
	`co`	continuação	banco
	`)`	pontuação	–

palavras inteiras. Por isso todos os resultados são separados por categoria de token, e as interpretações sobre sentido se limitam a palavras inteiras.

2.7 A amostra híbrida

Por que não usar só parágrafos inteiros. Antes de montar o experimento, um estudo de viabilidade simulou a amostragem num corpus preliminar. Ele mostrou que reunir cerca de 15 mil vértices é fácil (bastam de 100 a 160 parágrafos inteiros), mas que parágrafos inteiros não servem para a P4: pela lei de Zipf, quase nenhuma palavra de conteúdo se repete o bastante. Com 15 mil vértices tirados de parágrafos inteiros, só de 4 a 9 palavras de conteúdo apareciam pelo menos 10 vezes e em 3 temas, e nenhuma palavra ambígua chegava a 10 ocorrências em 2 temas. A solução foi uma **amostra híbrida**: um núcleo de parágrafos inteiros, para as perguntas sobre a rede como um todo, e três estratos de palavras escolhidas, sorteadas em outros parágrafos, para a P4.

A amostra limita cada tipo a $f_{\max} = 50$ ocorrências e usa uma semente fixa. Tem quatro estratos:

1. Núcleo (P1 a P3). Para cada tema, sorteamos 5 artigos e 2 parágrafos de cada um: 80 parágrafos. Todos os tokens desses parágrafos (menos os de só espaço) são vértices, inclusive pedaços de palavra, números e pontuação. Dois parágrafos por artigo fazem "artigo" e "parágrafo" serem rótulos diferentes na P3. O limite de 50 ocorrências por tipo é aplicado por sorteio uniforme depois de juntar todo o núcleo: dos 11.935 tokens dos 80 parágrafos, saíram 1.915 de 25 tipos muito frequentes (a vírgula passou de 483 para 50 ocorrências; ␣`de`, de 391 para 50). Assim as ocorrências mantidas de "de" se espalham por todos os parágrafos, em vez de serem as dos primeiros. O núcleo tem 10.020 vértices e é o único estrato em que o parágrafo aparece inteiro; por isso a P3 é analisada só nele.

2. Palavras-alvo (P4). Doze palavras com sentidos diferentes em temas diferentes, cada uma com uma **cota por tema de sentido**: 2 ou 3 temas, com 16 a 25 ocorrências em cada (Tabela 5). As ocorrências são sorteadas fora do núcleo, com no máximo 1 por parágrafo e 3 por artigo, para que um único artigo não domine uma palavra. Uma palavra que não chega a 10 ocorrências em pelo menos 2 temas sai da análise: foi o caso de *planta*, que teve só 5 ocorrências em Economia. Ficaram 11 alvos, com 477 vértices sorteados. Algumas cotas não foram cumpridas: *banco* teve 7 ocorrências em Geografia, *órgão* 7 em Política e *família* 11 em Política.

3. Controles (P4). Seis palavras de sentido estável: *ano*, *século*, *grande*, *primeiro*, *importante* e *água*. Elas têm a **mesma alocação** dos alvos (duas com três temas e cotas 17/17/16, quatro com dois temas e cotas 25/25), para que uma diferença entre alvos e controles não venha do desenho da amostra. São 277 vértices.

4. Palavras multitema (P4). 150 palavras de conteúdo que aparecem pelo menos 5 vezes em pelo menos 3 temas fora do núcleo, cada uma completada até 20 ocorrências, sorteadas em rodízio entre os temas. Exemplos: *metal*, *luz*, *guerra*, *material*, *forte*, *motor*, *banda*, *plano*. Elas estendem a P4 para além das 18 palavras escolhidas à mão, com palavras comuns a vários temas que não foram escolhidas por serem ambíguas. São 2.832 vértices. ("Multitema" tem aqui um sentido diferente do da Seção 2.4: lá, é uma *página* que pertence a mais de um tema e foi descartada; aqui, é uma *palavra* que aparece em vários temas.)

Tabela 5: Cotas por tema de sentido das palavras-alvo e de controle, como definidas no desenho (ocorrências por tema).

Alvo	Cotas	Controle	Cotas
banco	Economia 17, Computação 17, Geografia 16	ano	Economia 17, Esporte 17, Música 16
campo	Física 17, Esporte 17, Geografia 16	século	Física 17, Geografia 17, Política 16
órgão	Biologia 17, Música 17, Política 16	grande	Física 25, Biologia 25
estado	Física 25, Política 25	primeiro	Esporte 25, Computação 25
carga	Física 25, Economia 25	importante	Biologia 25, Economia 25
rede	Computação 25, Geografia 25	água	Biologia 25, Geografia 25
nota	Música 25, Economia 25		
capital	Economia 25, Política 25		
família	Biologia 25, Política 25		
massa	Física 25, Geografia 25		
matriz	Biologia 25, Computação 25		
planta	Biologia 25, Economia 25		

Nos três estratos de palavras escolhidas, o parágrafo da ocorrência também passa pelo modelo, mas só como contexto: o único vértice dele é a ocorrência sorteada. Ao todo, a amostra tem 13.606 vértices de 2.864 tipos, em 3.230 parágrafos de 1.172 artigos (Figura 1). Como o núcleo tem três quartos dos vértices, as medidas globais descrevem sobretudo texto corrido. Os estratos acrescentam palavras inteiras, e as palavras inteiras são 48% dos vértices, contra 28% num texto corrido.

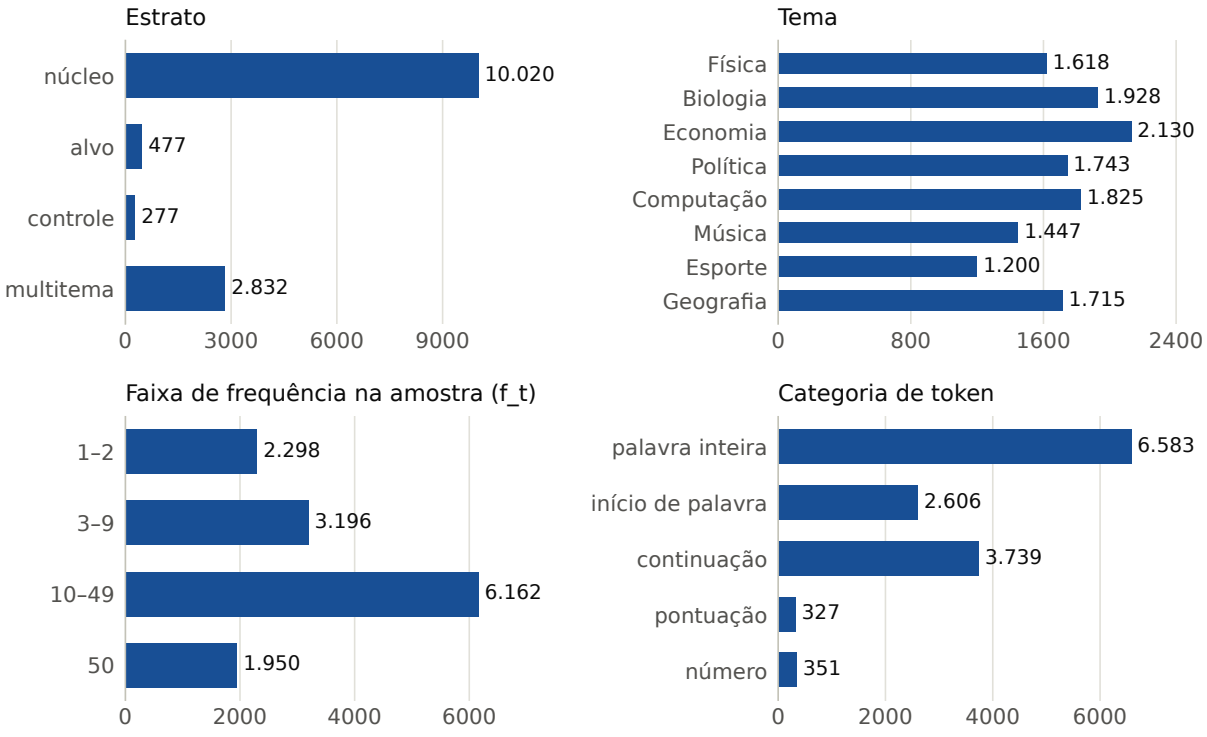


Figura 1: Composição da amostra: vértices por estrato, por tema, por faixa de frequência do tipo na amostra (f_t) e por categoria de token.

2.8 Anotação dos sentidos

O tema é só um indicador aproximado do sentido: um artigo de Computação pode citar o Banco Central. Para medir a separação por sentido de verdade, as 508 ocorrências das 11 palavras-alvo (inclusive as que caíram no núcleo) foram **anotadas pelo modelo de linguagem Claude Opus 5.5**, sem revisão humana. Cada ocorrência foi lida com o trecho do parágrafo em volta, sem o tema e sem o título do artigo, para que o rótulo registrasse o sentido e não o tema. Os sentidos de cada palavra (de 3 a 7) foram definidos durante a leitura; por exemplo, *órgão* tem os sentidos "órgão biológico", "instrumento musical" e "órgão institucional". Como o modelo analisado só vê o texto à esquerda da palavra, cada ocorrência recebeu também uma marca que diz se esse trecho à esquerda já decide o sentido (442 das 508). A separação por sentido é medida nos dois recortes. A anotação e o protocolo estão em `data/annotations/` no repositório.

3 Modelo e construção das redes

3.1 O modelo

O modelo analisado é o **Qwen3-4B-Base** [8], um Transformer de cerca de 4 bilhões de parâmetros, com 36 blocos e vetores de dimensão 2560, usado numa revisão fixa e com os pesos na precisão original (*bfloat16*). A versão *Base* é o modelo de linguagem puro, treinado só para prever o próximo token, sem o ajuste posterior para conversa; é ela que responde à pergunta de como um modelo de linguagem organiza o texto. Consideramos também o Tucano-2b4, treinado em português e com um tokenizer melhor para a nossa língua, e o GPT-2 small ajustado na Wikipédia em português, usado num piloto. Escolhemos o Qwen3 pela arquitetura atual e pela profundidade, que permite acompanhar 36 blocos; o custo é a fragmentação do português (Seção 2.6).

No Qwen3, a matriz de *embeddings* E da entrada é a mesma da saída [7]: a pontuação de cada candidato a próximo token é o produto interno entre a linha dele em E e a saída normalizada do bloco 36. Assim, a linha e_t de um token é, ao mesmo tempo, o vetor com que ele entra no modelo e a direção que o modelo usa para prevê-lo. Isso permite comparar os vetores internos com as linhas de E (Seção 5.6).

3.2 De um parágrafo aos vetores de cada ocorrência

Cada parágrafo passa **sozinho** pelo modelo, precedido do token especial `<|endoftext|>`, que separa documentos no treinamento do Qwen3 e nunca vira vértice. Por exemplo, um parágrafo de Economia em que *banco* foi sorteado entra como

posição	0	1	2	3	...
token	`<|endoftext|>`	`O`	`␣banco`	`␣central`	...

O modelo não recebe o título do artigo, os outros parágrafos nem o tema. A atenção do Qwen3 é causal: o vetor de uma posição depende só do seu token e dos tokens anteriores no parágrafo. Por isso o processamento é cortado logo depois da última posição sorteada no parágrafo; os tokens seguintes não mudariam nada.

Cada ocorrência i, de tipo t_i, recebe quatro vetores de dimensão 2560:

- `lex`: a linha e_{t_i} da matriz de *embeddings*. Ela não passa pelo modelo e é **igual para todas as ocorrências do mesmo tipo**;
- `L01`, `L18` e `L36`: o vetor da posição de i depois dos blocos 1, 18 e 36, isto é, a primeira mistura com o contexto, o meio do modelo e o último bloco. É a saída bruta de cada bloco, antes da normalização final que o modelo aplica antes de prever o próximo token. Os vetores são lidos por *hooks* do PyTorch, funções chamadas quando cada bloco termina.

Guardamos também a saída de todos os 36 blocos, para as curvas camada a camada; a saída normalizada

do bloco 36 (`L36n`), para a robustez; e o token que o modelo prevê depois de cada ocorrência, usado como rótulo na P3.

Dois vértices cujos parágrafos começam com os mesmos tokens até eles têm, matematicamente, os mesmos vetores em todas as camadas; o caso típico é "O" ou "A" no começo de vários parágrafos. Na prática, o arredondamento de contas feitas em sequências de comprimentos diferentes os deixa ligeiramente diferentes. Nesses 24 grupos, copiamos os vetores do primeiro membro para os demais, de modo que eles fiquem exatamente iguais e sejam tratados como empates (Seção 3.4).

3.3 As redes de vizinhos mais próximos

A semelhança entre dois vértices é o cosseno entre os seus vetores,

$$s_{ij} = \frac{x_i^\top x_j}{\|x_i\|\,\|x_j\|}. \tag{1}$$

Cada vértice i aponta para os $k = 10$ vértices de maior cosseno com ele, escolhidos entre os outros 13.606 menos um, de qualquer parágrafo, artigo ou tema. Chamamos esse conjunto de vizinhança $\mathcal{N}_i$. O resultado é uma **rede direcionada**: $i \to j$ não implica $j \to i$. Todo vértice tem grau de saída 10; o grau de entrada (quantos vértices escolheram i) varia, e os vértices escolhidos por muitos são os *hubs*. As arestas não têm peso. As quatro redes (`lex`, `L01`, `L18`, `L36`) têm os mesmos vértices e diferem só nos vetores usados, e portanto nas arestas (Figura 2).

Usamos três versões de cada rede:

- a **direcionada**, nas medidas de vizinhança (que dependem de $\mathcal{N}_i$), no grau de entrada e na reciprocidade;
- a **não direcionada por união**, com a aresta $\{i, j\}$ quando i escolhe j *ou* j escolhe i, na clusterização, nas distâncias, nos componentes e nas comunidades. Nela todo vértice tem grau pelo menos 10;
- a **mútua**, com a aresta só quando os dois se escolhem, como teste de robustez.

O cosseno é calculado em precisão dupla (*float64*), por causa da tolerância usada para decidir empates ($\varepsilon = 10^{-6}$, abaixo). Em precisão simples, o erro de arredondamento de um produto de 2560 termos fica entre 10^{-6} e 10^{-5}, da ordem da própria tolerância, e criaria empates falsos.

3.4 O tratamento dos empates

De onde vêm os empates. Na rede lexical, todas as ocorrências de um mesmo tipo têm o mesmo vetor, e o cosseno entre elas é exatamente 1. Considere uma ocorrência de `␣de`, um tipo com 50 ocorrências na amostra: as outras 49 são candidatas igualmente boas para as 10 vagas da vizinhança. Quais delas entram é uma escolha arbitrária. O mesmo acontece com tipos menos frequentes: se o tipo de i tem 4 ocorrências, as 3 outras entram com certeza, e as 7 vagas que sobram vão para as ocorrências do tipo mais próximo, que também são idênticas entre si e, portanto, também empatam. Na execução principal, **87,8% das linhas da rede lexical** têm um empate na fronteira da décima vaga, com blocos empatados de até 50 ocorrências. Nas camadas contextuais, os empates são raros (menos de 1% das linhas) e vêm só dos grupos de prefixo idêntico da Seção 3.2.

A regra. Seja $s_{i(k)}$ a k-ésima maior similaridade da linha i. Os candidatos se dividem nos que estão com certeza entre os k primeiros e no bloco empatado na fronteira,

$$F_i = \{\, j : s_{ij} > s_{i(k)} + \varepsilon \,\}, \qquad B_i = \{\, j : |s_{ij} - s_{i(k)}| \le \varepsilon \,\}, \tag{2}$$

com $\varepsilon = 10^{-6}$. Todos os vértices de F_i entram na vizinhança, e faltam $r_i = k - |F_i|$ vizinhos a escolher em B_i. Na configuração principal, esses r_i vizinhos são **sorteados** uniformemente em B_i. O sorteio é repetido com **20 sementes**, o que dá 20 versões de cada rede.

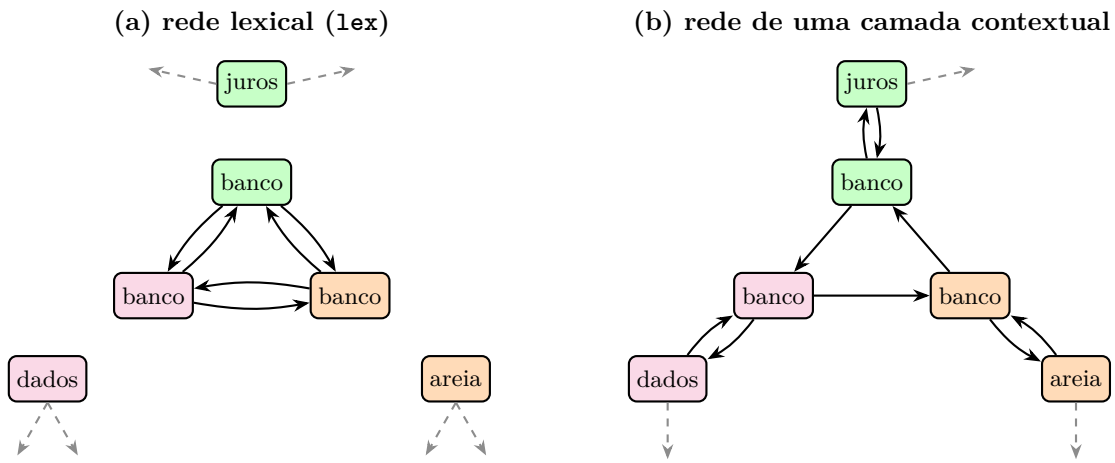


Figura 2: Exemplo ilustrativo (não são dados reais), com $k = 2$. Os vértices são seis ocorrências: *banco* em três parágrafos de temas diferentes (verde: Economia; rosa: Computação; laranja: Geografia) e uma palavra de cada um desses parágrafos. As setas tracejadas são arcos para vértices fora do desenho. (a) Na rede lexical, as três ocorrências de *banco* têm o mesmo vetor e apontam umas para as outras. (b) Numa camada contextual, cada *banco* passa a apontar também para uma palavra do seu contexto, e a vizinhança de cada ocorrência muda. As duas redes têm os mesmos vértices; só os arcos mudam, e é essa mudança que as medidas da Seção 4 quantificam.

Por que sortear. A alternativa óbvia, usada num piloto do projeto, é desempatar pela posição: ficar com os r_i candidatos de menor índice. Com 13.606 vértices, isso cria *hubs* artificiais: as 50 ocorrências de `␣de` escolheriam as mesmas 10 (as primeiras da lista), que receberiam cerca de 50 arcos cada, enquanto as demais quase não receberiam arcos de dentro do tipo. Com o sorteio, cada ocorrência escolhe 10 das 49 ao acaso, e os graus de entrada se espalham em torno de 10. Outras duas regras entram como robustez: (b) aceitar todos os empatados, $\mathcal{N}_i = F_i \cup B_i$, o que dá vizinhanças de tamanho variável; e (c) ignorar as ocorrências do próprio tipo e tomar como vizinhança os k *tipos* mais próximos.

Como os empates entram na análise. O sorteio torna a rede lexical em parte aleatória, e isso é tratado de três formas:

1. as métricas estruturais da rede lexical são a média e o desvio entre as 20 sementes. Elas variam muito pouco: o número de arestas da rede por união é 102.723 ± 73 e a clusterização varia na terceira casa decimal;
2. a troca de vizinhos entre duas redes lexicais com sementes diferentes mede a mudança produzida *só* pelo sorteio. Esse é o **piso de ruído** (Seção 4.2): uma mudança da rede lexical para uma camada só conta como reorganização se for maior que ele;
3. uma variante da medida de troca de vizinhos compara os vizinhos pelo tipo, e não pela ocorrência; ela não depende do sorteio.

Nas camadas contextuais, em que os empates são raros, as métricas estruturais e as comunidades usam a semente 0.

3.5 A rede do vocabulário

Além das redes de ocorrências, construímos uma rede de **tipos**: um vértice para cada token do vocabulário do modelo, representado pela sua linha em E, ligado aos seus 10 vizinhos pelo mesmo procedimento. São 151.643 vértices (todos os tokens, menos os 26 especiais). Essa rede descreve a geometria do espaço de entrada inteiro, sem depender da amostra. A maior parte do vocabulário nunca aparece num texto em português: metade dos tokens é de escrita latina, um quinto de chinês, japonês ou coreano, e muitos são pedaços de código; só 24.667 aparecem no nosso corpus. Também aqui há

empates: 1.903 tokens têm o vetor idêntico ao de outro, em 58 grupos (o maior com 524 tokens), provavelmente tokens que quase não foram vistos no treinamento; eles são desempatados por sorteio.

4 Medidas

Esta seção define as medidas usadas nos resultados e diz a que pergunta cada uma responde.

4.1 Métricas estruturais

Em cada rede calculamos as métricas usuais, com o igraph [2]: número de vértices n e de arestas m, grau médio $\langle k \rangle = 2m/n$, densidade, reciprocidade (a fração dos arcos $i \to j$ para os quais $j \to i$ também existe), clusterização global (a transitividade, 3× triângulos sobre trios conexos) e local média ($C_i = 2e_i/[k_i(k_i - 1)]$, com e_i o número de arestas entre os vizinhos de i), número de componentes conexos e fração de vértices no maior, distância média e diâmetro, por busca em largura exata a partir de todos os vértices do maior componente. As métricas não direcionadas usam a rede por união.

Duas observações ajudam a ler essas métricas numa rede k-NN. Primeiro, o número de arestas da rede por união fica entre $nk/2$ (todas as escolhas recíprocas) e nk (nenhuma recíproca), então o grau médio fica entre k e $2k$ e a densidade é baixíssima por construção; o que interessa é como esses valores variam entre as camadas. Segundo, como todo vértice tem grau de saída k, a informação sobre *hubs* está no **grau de entrada**. Reportamos a distribuição dele (a probabilidade $P(K \geq d)$ de um vértice ter grau de entrada pelo menos d) e a sua assimetria (*skewness*), a medida usual de *hubness* [9]: assimetria alta significa que poucos vértices são escolhidos por muitos.

4.2 Troca de vizinhos e piso de ruído (P1 e P2)

A vizinhança de uma ocorrência i nas redes a e b (por exemplo, `lex` e `L18`) é comparada pelo índice de Jaccard,

$$J_i(a,b) = \frac{|\mathcal{N}_i^{(a)} \cap \mathcal{N}_i^{(b)}|}{|\mathcal{N}_i^{(a)} \cup \mathcal{N}_i^{(b)}|}. \tag{3}$$

Com $k = 10$ vizinhos nas duas redes e c vizinhos em comum, $J_i = c/(20 - c)$: $J = 1$ quando nada muda, $J = 0{,}11$ quando sobram 2 vizinhos e $J = 0$ quando nenhum se mantém. A **mudança** é $M_i = 1 - J_i$.

Na rede lexical, parte dos vizinhos é sorteada entre empatados, e duas sementes diferentes já dão $J < 1$ sem nenhuma mudança de representação. O **piso de ruído** $J_i^{\text{ruído}}$ é o Jaccard médio entre redes lexicais de sementes diferentes (10 pares). Ele depende muito da frequência: para um tipo com 50 ocorrências, cada sorteio escolhe 10 de 49 cópias idênticas, e duas escolhas independentes têm em média só 2 em comum ($J^{\text{ruído}} = 0{,}12$); para tipos de 10 a 49 ocorrências, 0,39; para tipos raros, cerca de 0,75. A **mudança acima do piso** é $M_i^{+} = J_i^{\text{ruído}} - J_i(\text{lex}, \ell)$: a parte da troca de vizinhos que o sorteio não explica. Como complemento, o Jaccard por composição J^w compara quantos vizinhos de cada *tipo* a ocorrência tem nas duas redes; ele quase não depende do sorteio, porque trocar uma cópia idêntica por outra não muda a composição.

4.3 Dominância lexical (P1 e P2)

A **dominância lexical** de uma ocorrência é a fração dos seus vizinhos que são ocorrências do mesmo tipo,

$$D_i = \frac{|\{\, j \in \mathcal{N}_i : t_j = t_i \,\}|}{k}. \tag{4}$$

Na rede lexical, as outras ocorrências do tipo são as mais parecidas possíveis (cosseno 1), e D_i atinge o seu teto $\min(f_{t_i} - 1,\, k)/k$: uma ocorrência de um tipo com 4 ocorrências nunca passa de 0,3. Para comparar tipos de frequências diferentes, usamos também a dominância relativa ao teto, $\tilde{D}_i = D_i/\text{teto}$,

que vale 1 na rede lexical. O nível do acaso, se os vizinhos fossem sorteados, é $(f_{t_i} - 1)/(n - 1)$, no máximo $49/13.605 \approx 0{,}004$.

4.4 Comunidades e concordância com rótulos (P3)

As comunidades são encontradas na rede por união com o algoritmo de Leiden [11], que maximiza a modularidade [5]. Ele roda 10 vezes com sementes diferentes; fica a partição de maior modularidade, e a **estabilidade** é a concordância média entre as 10 partições. O Louvain [1] serve de checagem.

Para saber o que as comunidades representam, comparamos a partição com rótulos conhecidos dos vértices: o tipo de token, o tema, o artigo, o parágrafo, a sentença, o próximo token do texto, o token que o modelo prevê e a faixa de posição no parágrafo. A posição entra como controle: se ela explicasse as comunidades, o resultado seria um artefato da posição, e não contexto. A comparação usa a **informação mútua normalizada** (NMI), que vai de 0 (partições independentes) a 1 (iguais). O NMI cresce com o número de classes mesmo entre partições sem relação nenhuma [12], e os rótulos aqui vão de 4 classes (faixa de posição) a 2.780 (tipo de token). Por isso cada NMI é descontado de uma **linha de base**: o NMI médio com o rótulo embaralhado 20 vezes, que preserva o número e o tamanho das classes. A medida lida é NMI menos a linha de base. Reportamos também o índice de Rand ajustado [4], já corrigido pelo acaso.

A P3 é analisada **só nos 10.020 vértices do núcleo**, em que os parágrafos estão inteiros. As comunidades são as da rede inteira, restritas a esses vértices.

4.5 Separação das ocorrências de um mesmo tipo (P4)

Para cada tipo com pelo menos 10 ocorrências, separados em alvos, controles, multitema e palavras funcionais (artigos, preposições, pronomes. . .), medimos:

- a **autossimilaridade**, o cosseno médio entre as ocorrências do tipo (vale 1 na camada lexical) [3];
- a diferença **intra − entre**: o cosseno médio entre ocorrências do mesmo tema menos o cosseno médio entre ocorrências de temas diferentes. Se for positiva, as ocorrências se agrupam por tema; se for zero, o tema não importa;
- o **número efetivo de comunidades** ocupadas pelas ocorrências, e^H, com H a entropia da distribuição delas pelas comunidades. Vale 1 quando todas estão na mesma comunidade;
- o **NMI entre comunidade e tema** dentro do tipo, com a sua linha de base: as ocorrências não só se espalham, mas se espalham *segundo o tema*?

Nas palavras-alvo, as duas últimas medidas e a diferença intra − entre são repetidas com o **sentido anotado** no lugar do tema (Seção 2.8), em todas as ocorrências e só nas que o contexto à esquerda decide.

4.6 Vizinhos no vocabulário

Como o Qwen3 usa a mesma matriz E na entrada e na saída, podemos perguntar, para o vetor de uma ocorrência em cada bloco, quais linhas de E estão mais próximas dele. Ordenamos as 151.669 linhas pelo cosseno com o vetor e anotamos a posição do *próprio* token e a do *próximo* token do texto nessa ordem. É uma versão simples da "lente de *logits*" [6]. A pergunta é em que bloco a ocorrência deixa de se parecer com o próprio token e passa a se parecer com o seguinte. Duas checagens validam o cálculo: na camada lexical, o próprio token é sempre o primeiro; na saída normalizada do bloco 36, a linha de maior produto interno coincide com a previsão do próprio modelo em 100,0 % das ocorrências.

5 Resultados

Salvo indicação, os valores são da configuração principal: $k = 10$, desempate por sorteio, rede por união para as métricas estruturais e direcionada para as vizinhanças. A Seção 5.1 descreve as quatro redes; as Seções 5.2 a 5.5 respondem às perguntas, cada uma começando pela resposta; as Seções 5.6 e 5.7 trazem duas análises complementares.

Para as perguntas P2, P3 e P4, uma segunda execução repetiu as análises em todos os 36 blocos, com a mesma amostra e os mesmos vetores; as curvas camada a camada vêm dela.

5.1 Visão geral das quatro redes

A Tabela 6 traz as métricas estruturais das quatro redes de ocorrências e da rede do vocabulário. Cinco diferenças se destacam.

Tabela 6: Métricas estruturais das redes da configuração principal ($k = 10$, versão por união). Na rede lexical, média ± desvio entre as 20 sementes do desempate; nas camadas contextuais, semente 0. Reciprocidade e grau de entrada vêm da versão direcionada.

Métrica	`lex`	`L01`	`L18`	`L36`	vocab. ($k = 10$)
$\|V\|$	13.606	13.606	13.606	13.606	151.643
$\|E\|$	$102.723 \pm 73{,}1$	97.061	94.739	106.307	1.158.411
Grau médio $\langle k \rangle$	$15{,}10 \pm 0{,}01$	14,27	13,93	15,63	15,28
Densidade	0,00111	0,00105	0,00102	0,00115	$1{,}01 \times 10^{-4}$
Reciprocidade (direcionada)	$0{,}490 \pm 0{,}001$	0,573	0,607	0,437	0,472
Clusterização global	$0{,}532 \pm 0{,}001$	0,548	0,330	0,233	0,075
Clusterização local média	$0{,}563 \pm 0{,}001$	0,618	0,365	0,353	0,401
Componentes	44	40	2	2	1
Maior componente (fração)	$91{,}0\,\% \pm 0{,}0$	93,2 %	99,6 %	99,6 %	100,0 %
Distância média	$7{,}61 \pm 0{,}00$	7,08	5,12	5,28	5,30
Diâmetro	$17{,}6 \pm 0{,}5$	18	11	11	19
Grau de entrada máximo	$29{,}6 \pm 0{,}7$	60	55	247	1.756
Assimetria do grau de entrada	$-0{,}02 \pm 0{,}01$	1,02	1,36	4,91	22,57
Modularidade (Leiden)	$0{,}950 \pm 0{,}000$	0,916	0,764	0,768	0,813
Comunidades	$186{,}0 \pm 1{,}4$	178	58	44	171

Redes com $k = 10$, versão por união, desempate por sorteio (média ± desvio entre as 20 sementes na rede lexical, semente 0 nas demais); reciprocidade e grau de entrada vêm da versão direcionada.

Clusterização. As redes `lex` e `L01` são muito clusterizadas (clusterização local média de 0,56 e 0,62), e as redes `L18` e `L36` bem menos (0,37 e 0,35). Na rede lexical, a causa é a construção: uma ocorrência de um tipo frequente tem os seus 10 vizinhos entre as outras ocorrências do mesmo tipo, que também se escolhem entre si, o que forma grupos densos, cheios de triângulos. No bloco 1 esses grupos ainda estão lá. Nos blocos 18 e 36, as vizinhanças misturam tokens diferentes e os triângulos rareiam.

Componentes. A rede lexical por união tem 44 componentes, e o maior reúne 91% dos vértices. Os componentes pequenos são tipos frequentes: um tipo com mais de 10 ocorrências manda todos os seus arcos para dentro de si, e, se nenhum vértice de outro tipo escolher uma das suas ocorrências, o grupo fica isolado. Isso atinge justamente as palavras sorteadas com cotas de 50 e de 20 ocorrências. Nas redes `L18` e `L36` sobram 2 componentes, com 99,6% dos vértices no maior; o segundo é explicado abaixo.

Distâncias. A distância média cai de 7,6 (`lex`) e 7,1 (`L01`) para 5,1 (`L18`) e 5,3 (`L36`), e o diâmetro de 18 para 11. As redes contextuais têm atalhos: uma ocorrência passa a ter vizinhos de outros tipos,

e o caminho entre dois vértices quaisquer encurta. Na rede lexical, a distância é medida só no maior componente, que deixa de fora 9% dos vértices.

Hubs. A Figura 3 mostra a distribuição do grau de entrada. Na rede lexical ela é estreita (máximo de 30 arcos recebidos, assimetria próxima de zero), porque o sorteio espalha os arcos entre cópias idênticas. Nos blocos 1 e 18 a cauda cresce (máximos de 60 e 55, assimetria 1,0 e 1,4), e no bloco 36 ela fica pesada: um vértice recebe 247 arcos e a assimetria chega a 4,9. Os dez maiores *hubs* do bloco 36 são inícios e continuações de palavras e dígitos, todos depois da posição 17 no parágrafo (`␣apresent`, com 247 arcos; `ícul`, com 192; `2`, com 190). *Hubs* são comuns em espaços de alta dimensão [9], e aqui eles crescem junto com a anisotropia: o cosseno médio entre pares de vértices ao acaso sobe de 0,03 na camada lexical para 0,37 no bloco 1, 0,39 no bloco 18 e 0,58 no bloco 36, isto é, os vetores passam a compartilhar uma direção comum. A reciprocidade acompanha: ela sobe de 0,49 (`lex`) para 0,61 (`L18`) e cai para 0,44 no bloco 36, porque muitos vértices escolhem um *hub* que não os escolhe de volta.

Comunidades. O número de comunidades cai de 186 (`lex`) e 178 (`L01`) para 58 (`L18`) e 44 (`L36`), e a modularidade de 0,95 para 0,77: as comunidades ficam maiores e menos separadas. O que elas representam é o assunto da P3.

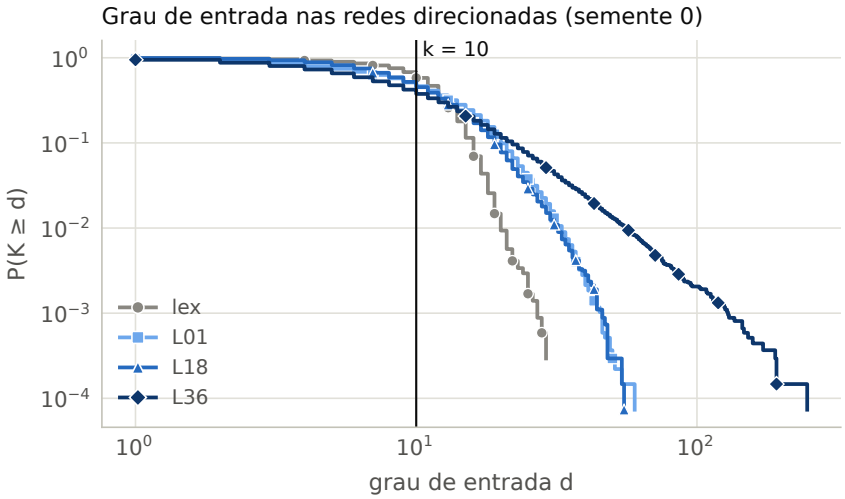


Figura 3: Distribuição do grau de entrada nas redes direcionadas: fração dos vértices com grau de entrada pelo menos d, em escala log-log. A linha vertical marca $k = 10$, a média comum a todas as redes. Quanto mais longa a cauda à direita, mais fortes os *hubs*.

Uma ilha de primeiros tokens. O segundo componente das redes `L18` e `L36` é formado pelo primeiro token de vários parágrafos do núcleo, quase sempre "O" ou "A". No bloco 18, os 80 vértices da posição 1 têm vetores com norma cerca de 50 vezes maior que a dos outros (mediana de 2.814 contra 55), um fenômeno conhecido em modelos grandes, as *ativações massivas* [10]. Esses vetores apontam para uma direção própria: no bloco 18, todos os vizinhos deles são outros vértices da posição 1 (87% no bloco 36), e o componente separado reúne 50 deles. O prefixo `<|endoftext|>` foi colocado para que nenhuma ocorrência ocupasse a posição 0, onde essas ativações costumam aparecer; neste modelo, a posição 1 também as tem. São 0,6% dos vértices, e retirá-los quase não muda as métricas globais.

5.2 P1: quanto e de que forma a organização muda

Resposta. A organização quase não muda no bloco 1 e muda muito nos blocos 18 e 36, mas a identidade do token não desaparece: no bloco 36, a fração de vizinhos do mesmo token ainda é muitas vezes maior que a do acaso.

Troca de vizinhos. O Jaccard médio entre a vizinhança lexical e a de cada camada é 0,35 no bloco 1, 0,16 no bloco 18 e 0,10 no bloco 36: no último bloco, uma ocorrência mantém em média menos de 2 dos seus 10 vizinhos lexicais (Tabela 7). Descontado o piso de ruído, a mudança é de 0,14, 0,34 e 0,40. A Figura 4 separa os vértices pela frequência do tipo e mostra por que o desconto importa. Para tipos com 10 ou mais ocorrências, o Jaccard entre `lex` e `L01` é igual ao piso (0,38 contra 0,39 na faixa de 10 a 49; 0,12 contra 0,12 na de 50): no bloco 1, os vizinhos dessas ocorrências continuam sendo as outras ocorrências do mesmo token, e a única diferença é *quais* cópias foram sorteadas. O Jaccard por composição de tipos, que ignora o sorteio, confirma: ele vale 0,98 entre `lex` e `L01` nessas faixas. Já os tipos raros (1 a 9 ocorrências) mudam desde o bloco 1 (Jaccard de 0,29 e 0,50, contra pisos de 0,73 e 0,76). Na rede lexical, os vizinhos deles eram ocorrências de outros tipos parecidos; o bloco 1, que já vê o token anterior, troca esses vizinhos. Nos blocos 18 e 36, todas as faixas ficam bem abaixo do piso.

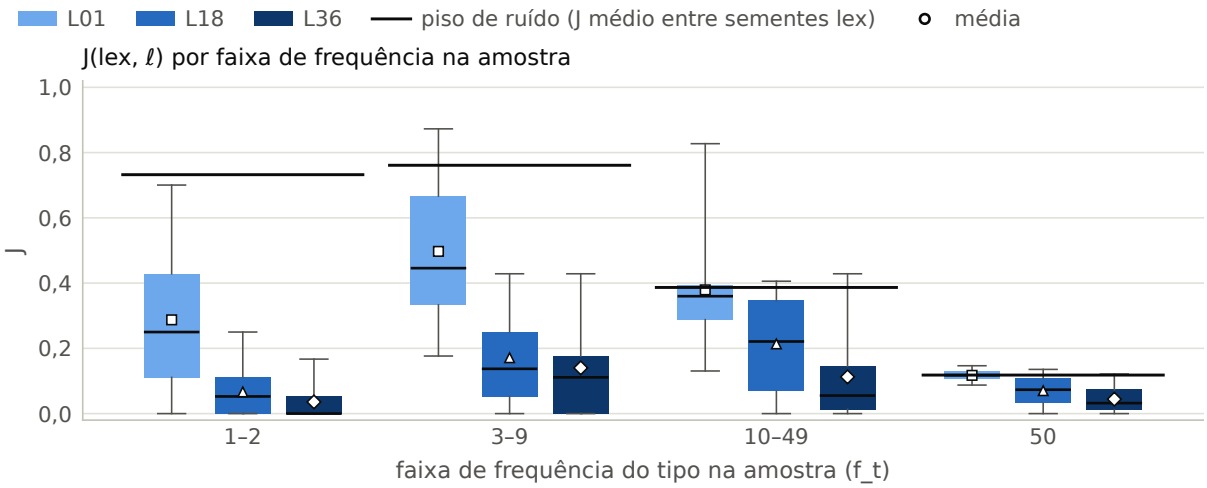


Figura 4: Jaccard entre a vizinhança de cada ocorrência na rede lexical e nas redes dos blocos 1, 18 e 36, por faixa de frequência do tipo na amostra. Caixas: quartis; marcadores: médias. A linha horizontal é o piso de ruído da faixa (o Jaccard médio entre duas redes lexicais de sementes diferentes): só a distância abaixo dela é reorganização.

Tabela 7: P1 por estrato da amostra e categoria de token: Jaccard com a rede lexical (J), mudança acima do piso de ruído (M^+), dominância lexical (D) e dominância relativa ao teto ($\tilde{D}$), em cada camada.

		L01				L18				L36			
Grupo	n	J	M^+	D	$\tilde{D}$	J	M^+	D	$\tilde{D}$	J	M^+	D	$\tilde{D}$
Todos	13.606	0,35	0,14	0,69	0,99	0,16	0,34	0,43	0,62	0,10	0,40	0,25	0,40
Estrato													
núcleo	10.020	0,37	0,19	0,58	0,99	0,12	0,44	0,26	0,51	0,10	0,46	0,20	0,40
alvo	477	0,13	0,00	1,00	1,00	0,12	0,01	0,94	0,94	0,07	0,06	0,54	0,54
controle	277	0,12	0,00	1,00	1,00	0,11	0,01	0,95	0,95	0,07	0,05	0,61	0,61
multitema	2.832	0,37	0,00	1,00	1,00	0,31	0,06	0,86	0,86	0,11	0,26	0,33	0,33
Categoria													
palavra inteira	6.583	0,32	0,05	0,86	1,00	0,21	0,16	0,66	0,76	0,08	0,29	0,30	0,35
início de palavra	2.606	0,42	0,32	0,34	0,99	0,17	0,56	0,23	0,73	0,19	0,55	0,28	0,79
continuação	3.739	0,39	0,20	0,61	0,98	0,07	0,52	0,14	0,29	0,07	0,52	0,13	0,25
pontuação	327	0,31	0,05	0,84	1,00	0,13	0,24	0,54	0,66	0,09	0,27	0,46	0,54
número	351	0,17	0,01	0,93	0,93	0,06	0,13	0,37	0,37	0,04	0,14	0,29	0,29

$J = J_i(\text{lex}, \ell)$; $M^+ = M - M^{\text{r}}$: mudança acima do piso de ruído (piso de J entre sementes lexicais menos J); D: dominância lexical; $\tilde{D}$: D sobre o teto $\min(f_t - 1, k)/k$ (só $f_t \geq 2$). Médias por vértice.

Dominância lexical. A fração de vizinhos do mesmo tipo é 0,70 na rede lexical (o teto, por construção), 0,69 no bloco 1, 0,43 no bloco 18 e 0,25 no bloco 36. Relativa ao teto, ela cai de 1 para 0,99, 0,62 e 0,40 (Figura 5). Mesmo no bloco 36, uma ocorrência de um tipo com 50 ocorrências tem em média 3,9 vizinhos do mesmo token, quando o acaso daria 0,04. A hipótese H1 se confirma: a dominância cai, mas fica muito acima do acaso.

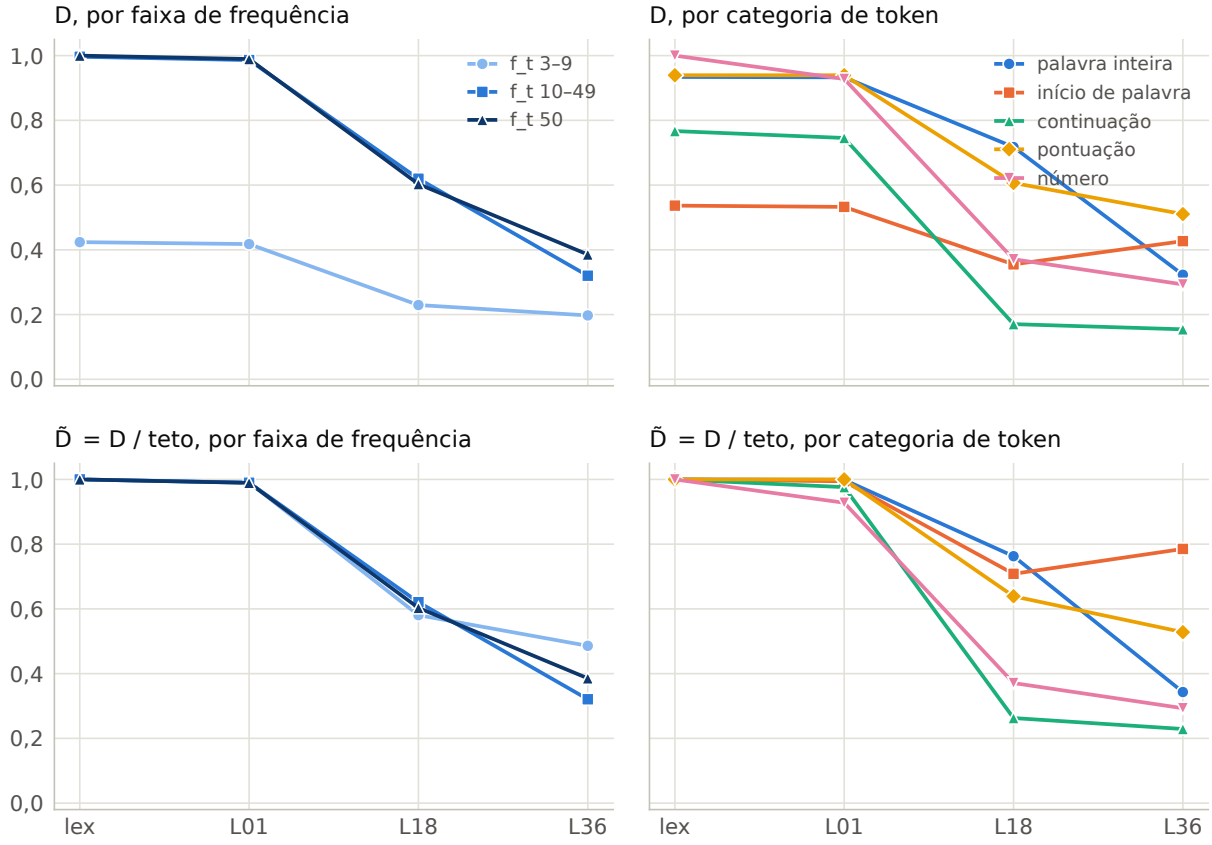


Figura 5: Dominância lexical D (em cima) e dominância relativa ao teto $\tilde{D}$ (embaixo), por camada, para tipos com pelo menos 3 ocorrências, por faixa de frequência (à esquerda) e por categoria de token (à direita).

Diferenças por categoria. A queda depende muito do tipo de token. No bloco 36, a dominância relativa ao teto é de 0,25 nas continuações de palavra, 0,29 nos números, 0,35 nas palavras inteiras, 0,54 na pontuação e 0,79 nos inícios de palavra. Os inícios de palavra são a exceção: eles mantêm a identidade até o fim, e a dominância deles até sobe entre os blocos 18 e 36 (de 0,73 para 0,79). Uma explicação provável é que o bloco 36 codifica o próximo token (Seção 5.6), e o próximo token depois do início de uma palavra é a continuação dela, que depende sobretudo do próprio início: duas ocorrências de `␣apresent` preveem continuações parecidas e por isso continuam próximas.

Diferenças por estrato. As palavras-alvo e de controle, sorteadas uma por parágrafo, mantêm quase toda a dominância até o bloco 18 (0,94 e 0,95) e perdem boa parte dela no bloco 36 (0,54 e 0,61). No núcleo, em que os tokens vêm de parágrafos inteiros e incluem muitos pedaços de palavra, a dominância relativa já cai para 0,51 no bloco 18.

Na escala global, a P1 se completa com o que a Seção 5.1 mostrou: os *hubs* aparecem no bloco 36, as distâncias encurtam e as comunidades ficam menos numerosas e, como mostra a P3, menos alinhadas ao token.

5.3 P2: em que camadas a mudança se concentra

Resposta. A mudança se espalha pelo modelo inteiro, com três momentos mais fortes: os primeiros blocos, a região dos blocos 22 a 25 e o último bloco. A ordem depende da categoria do token: continuações e números perdem a identidade nos primeiros blocos, palavras inteiras só no último terço.

Troca de vizinhos bloco a bloco. O painel da esquerda da Figura 6 mostra o Jaccard entre as vizinhanças de blocos consecutivos. Ele é baixo no começo (0,54 entre os blocos 1 e 2), sobe para cerca de 0,83 nos blocos 15 a 18 (cada bloco mantém uns 9 dos 10 vizinhos), cai para 0,67 no bloco 25, volta a cerca de 0,78 e despenca no último bloco (0,59). Os blocos do meio mudam pouco de cada vez, mas a mudança acumulada é grande, como a P1 mostrou.

Dominância bloco a bloco. O painel da direita mostra a dominância lexical. As continuações de palavra caem de 0,61 para 0,26 já no bloco 4, e os números de 0,93 para 0,60 no bloco 3. As palavras inteiras perdem a identidade devagar (0,86 no bloco 1, 0,80 no bloco 8, 0,64 no bloco 20) e caem mais rápido depois do bloco 28 (0,48 no bloco 30, 0,30 no 36). Os inícios de palavra ficam quase constantes (de 0,34 a 0,23 e de volta a 0,28).

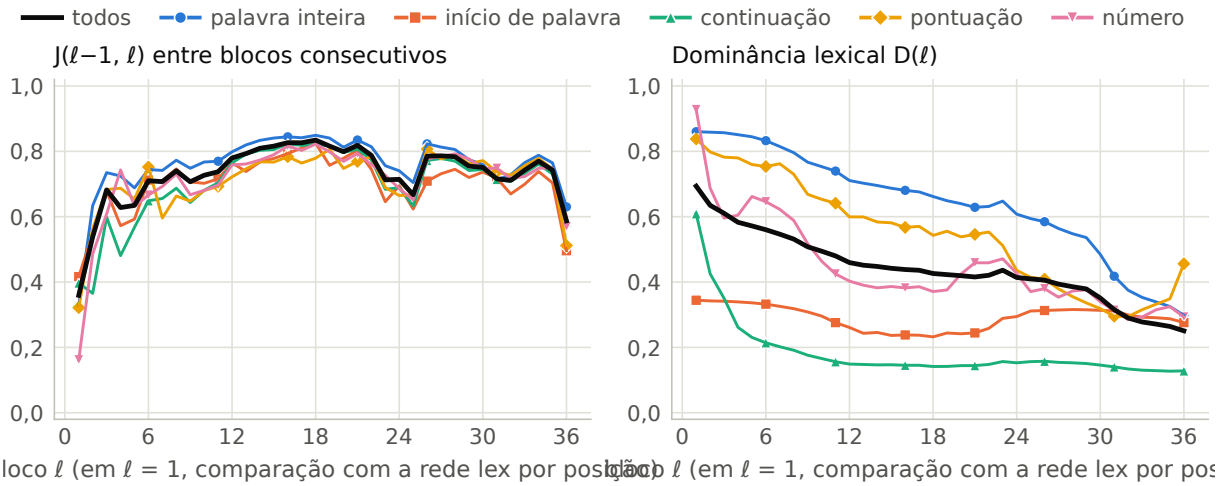


Figura 6: Curvas nos 36 blocos. À esquerda, o Jaccard entre as vizinhanças de blocos consecutivos (no bloco 1, a comparação é com a rede lexical); à direita, a dominância lexical D em cada bloco, por categoria de token.

Onde cada vértice muda mais. A Figura 7 conta, entre as transições lexical $\rightarrow$ 1, 1 $\rightarrow$ 18 e 18 $\rightarrow$ 36, em qual cada vértice perde mais vizinhos. A maioria muda mais entre os blocos 1 e 18 (48%) ou entre 18 e 36 (37%). As continuações de palavra mudam sobretudo entre os blocos 1 e 18 (78%), e as palavras inteiras entre 18 e 36 (50%). Os tipos com 50 ocorrências parecem mudar muito na transição lexical $\rightarrow$ 1 (40%), mas isso é só o sorteio dos empates: para eles, o Jaccard dessa transição é o próprio piso de ruído.

A hipótese H2 se confirma em parte: continuações e números mudam cedo, e palavras inteiras tarde. Os inícios de palavra não seguem a hipótese: eles quase não perdem a identidade.

5.4 P3: comunidades e contexto

Resposta. Sim. No núcleo, as comunidades das redes `lex` e `L01` seguem o token; as da rede `L18` seguem mais o texto de origem (artigo, parágrafo, sentença e tema) do que o token; no bloco 36, o texto perde peso e o próximo token ganha.

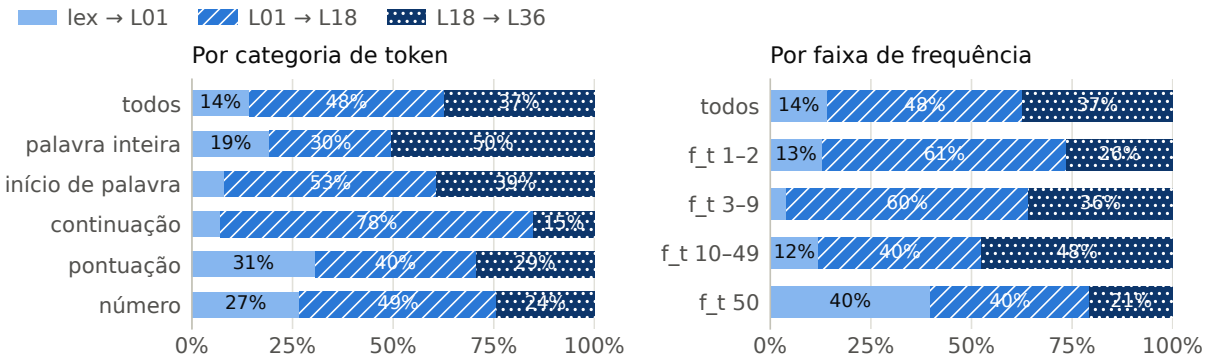


Figura 7: Fração dos vértices cuja maior troca de vizinhos acontece em cada transição, por categoria de token e por faixa de frequência.

As quatro redes. A Tabela 8 traz a concordância de cada rótulo com as comunidades. Medida pelo NMI menos a linha de base, a concordância com o token é 0,32 nas redes `lex` e `L01`, e a com qualquer rótulo de contexto fica abaixo de 0,05. No bloco 18 a ordem se inverte: artigo 0,25, parágrafo 0,24, sentença 0,21 e tema 0,20, contra 0,18 do token. No bloco 36, os rótulos de contexto caem para cerca da metade (tema 0,09, artigo 0,12), enquanto o próximo token sobe de 0,08 para 0,19 e o token previsto pelo modelo para 0,22. A faixa de posição nunca passa de 0,04: as comunidades não são um artefato da posição.

Os 36 blocos. A Figura 8 mostra as mesmas medidas em todos os blocos. A concordância com o contexto sobe devagar nos primeiros blocos, acelera a partir do bloco 9 e tem um primeiro máximo nos blocos 12 e 13 (artigo 0,27 e parágrafo 0,26 no bloco 12; tema 0,22 no bloco 13) e outro no bloco 19. Nos blocos 22 a 24 ela cai bruscamente (o tema vai a 0,08), volta no bloco 25 e depois diminui até o bloco 36. A concordância com o próximo token cresce a partir do bloco 21 e chega a 0,19 no bloco 34. O bloco 18, escolhido de antemão como "o meio do modelo", fica perto do máximo do contexto, mas o máximo vem um pouco antes. A queda dos blocos 22 a 24 coincide com a queda do Jaccard entre blocos consecutivos (Figura 6) e com o bloco em que o próximo token passa a ficar mais perto do vetor do que o próprio token (Seção 5.6); ela marca uma transição no modelo, que não investigamos mais a fundo.

Dois detalhes ajudam a ler esses números. O índice de Rand ajustado é baixo em todas as redes (no máximo 0,09), porque as comunidades são bem menos numerosas que as classes da maioria dos rótulos (56 comunidades no núcleo do bloco 18, contra 80 parágrafos e 2.780 tipos); o NMI menos a linha de base é a medida que compara melhor rótulos com números de classes tão diferentes. E a estabilidade do Leiden cai de 0,96 na rede lexical para 0,83 no bloco 36: as comunidades ficam menos nítidas nas últimas camadas, mas continuam reprodutíveis.

A hipótese H3 se confirma, com uma correção: a concordância com o contexto não cresce até o fim, ela tem um máximo nos blocos do meio e cede lugar ao próximo token nos últimos.

5.5 P4: separação das ocorrências de um mesmo token

Resposta. Sim. As ocorrências de um token, idênticas na camada lexical, se separam nos blocos 18 e 36, e as palavras ambíguas se separam mais do que as de controle, por tema e, mais ainda, pelo sentido anotado.

Os quatro grupos de palavras. A Figura 9 compara alvos, controles, multitema e palavras funcionais nos 36 blocos.

Tabela 8: P3 no núcleo: concordância entre as comunidades de cada rede e cada rótulo. "Classes": número de valores do rótulo; "Comun.": comunidades com vértices do núcleo; "Base": NMI médio com o rótulo embaralhado; ARI: índice de Rand ajustado; pureza: fração dos vértices que têm o rótulo mais comum da sua comunidade.

Rótulo	Classes	Repr.	Comun.	NMI	Base	NMI−base	ARI	Pureza
token	2.780	`lex`	179	0,795	0,471	0,323	0,233	0,368
		`L01`	166	0,752	0,429	0,323	0,150	0,285
		`L18`	56	0,490	0,310	0,180	0,025	0,073
		`L36`	43	0,483	0,295	0,188	0,019	0,083
tema	8	`lex`	179	0,041	0,019	0,022	0,003	0,238
		`L01`	166	0,037	0,017	0,019	0,002	0,225
		`L18`	56	0,204	0,007	0,197	0,087	0,415
		`L36`	43	0,095	0,006	0,089	0,018	0,280
artigo	40	`lex`	179	0,123	0,077	0,046	0,006	0,121
		`L01`	166	0,103	0,063	0,040	0,006	0,108
		`L18`	56	0,274	0,028	0,246	0,094	0,219
		`L36`	43	0,141	0,024	0,117	0,021	0,137
parágrafo	80	`lex`	179	0,169	0,129	0,041	0,006	0,088
		`L01`	166	0,143	0,104	0,039	0,005	0,081
		`L18`	56	0,287	0,048	0,239	0,066	0,150
		`L36`	43	0,156	0,043	0,113	0,016	0,097
sentença	256	`lex`	179	0,269	0,249	0,020	0,003	0,053
		`L01`	166	0,230	0,209	0,022	0,003	0,048
		`L18`	56	0,318	0,111	0,207	0,030	0,078
		`L36`	43	0,192	0,101	0,091	0,007	0,049
próximo token	2.455	`lex`	179	0,501	0,428	0,073	0,016	0,107
		`L01`	166	0,473	0,390	0,082	0,015	0,097
		`L18`	56	0,362	0,283	0,078	0,008	0,072
		`L36`	43	0,460	0,270	0,191	0,035	0,115
token previsto	2.228	`lex`	179	0,487	0,402	0,085	0,018	0,128
		`L01`	166	0,462	0,366	0,096	0,020	0,123
		`L18`	56	0,356	0,266	0,090	0,012	0,100
		`L36`	43	0,475	0,254	0,222	0,051	0,157
faixa de posição	4	`lex`	179	0,013	0,009	0,003	0,000	0,573
		`L01`	166	0,013	0,009	0,004	0,000	0,573
		`L18`	56	0,042	0,004	0,038	0,005	0,586
		`L36`	43	0,022	0,003	0,019	0,003	0,575

Comunidades do Leiden (modularidade, $\gamma = 1,0$) na rede por união com $k = 10$, semente 0; linha de base: NMI médio com o rótulo permutado (20 permutações).

- A **autossimilaridade** segue a mesma curva em todos os grupos: cai de 1 para 0,6 a 0,7 nos blocos 10 a 15 e volta a cerca de 0,78 no bloco 36. Ela não distingue palavras ambíguas de palavras estáveis, e a subida final acompanha a anisotropia geral dos vetores.
- A diferença **intra − entre temas** separa os grupos. Nos alvos, ela sobe a partir do bloco 4, tem o máximo nos blocos 11 e 12 (0,12) e vale 0,09 no bloco 18 e 0,05 no 36. Nos controles, não passa de 0,02 em nenhum bloco.
- O **NMI entre comunidade e tema** dentro do tipo é 0,27 nos alvos no bloco 18 e 0,41 no bloco 36, contra 0,04 e 0,17 nos controles; o valor esperado ao acaso é de cerca de 0,08. As palavras multitema ficam no meio (0,07 e 0,30).
- No bloco 36, as ocorrências de um alvo se espalham por 3,3 comunidades efetivas, e as de um controle por 2,7.

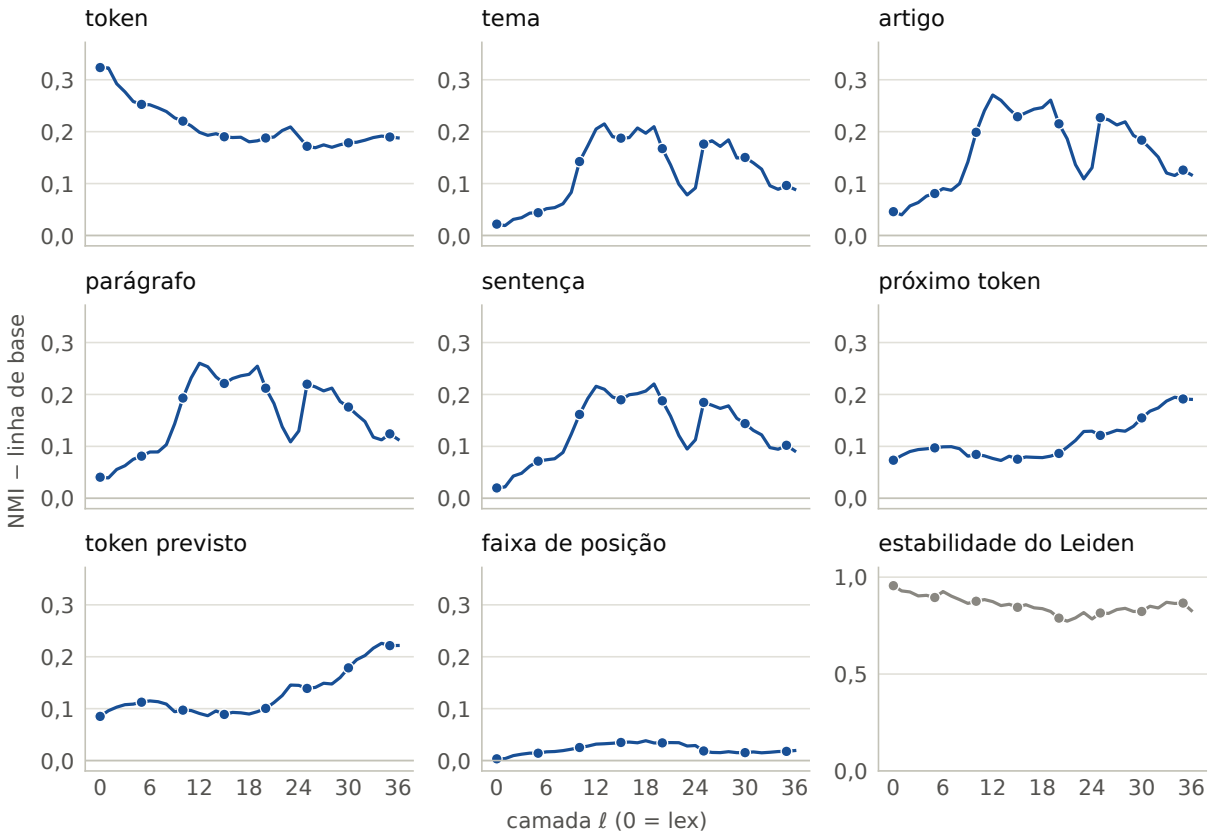


Figura 8: Concordância (NMI menos a linha de base) entre as comunidades de cada bloco e cada rótulo, nos vértices do núcleo; o bloco 0 é a rede lexical. O último painel mostra a estabilidade do Leiden (concordância média entre as 10 execuções). Execução com os 36 blocos, com a mesma amostra e os mesmos vetores da principal.

Palavra por palavra. A Tabela 9 mostra cada palavra no bloco 36. Todos os alvos têm diferença intra − entre temas positiva, de 0,024 (*massa*) a 0,094 (*órgão*). Nos controles ela fica perto de zero, com uma exceção: *primeiro* (0,044, com NMI de 0,31). O tema sozinho, sem mudança de sentido, também separa um pouco as ocorrências, e é por isso que a comparação com os controles é necessária.

Sentido e tema. Para todas as 11 palavras-alvo, a separação pelo sentido anotado é maior que pelo tema: *família*, por exemplo, tem diferença intra − entre de 0,118 pelo sentido e de 0,027 pelo tema; *carga*, de 0,091 e 0,046. O NMI entre comunidade e sentido vai de 0,33 (*banco*) a 0,70 (*matriz*), contra cerca de 0,13 ao acaso. Nas ocorrências em que o texto à esquerda já decide o sentido, os valores são parecidos ou maiores (*nota* chega a 0,84), o que indica que a separação não depende de informação à direita, que o modelo não vê.

Quais sentidos se separam, e onde. A Figura 10 mostra, para cada palavra, em que comunidades caem as ocorrências de cada sentido. No bloco 18, cinco palavras já se dividem pelo sentido: *órgão* (o instrumento musical fica numa comunidade própria), *família* (grupo familiar e grupo taxonômico), *capital* (recurso econômico e cidade sede), *matriz* (matriz matemática e substância envolvente) e *estado* (condição e entidade política). As outras seis, entre elas *banco*, *carga* e *rede*, ficam quase inteiras numa só comunidade. No bloco 36, todas as palavras se dividem, e as divisões seguem o sentido: a maior parte das ocorrências de *banco* de dados fica numa comunidade, e a maior parte das de *banco* como instituição financeira, em outras.

Na execução com os 36 blocos, as duas formas de medir a separação por sentido têm máximos em lugares diferentes. A diferença de cosseno entre sentidos é máxima nos blocos 11 e 12 (0,17 em média

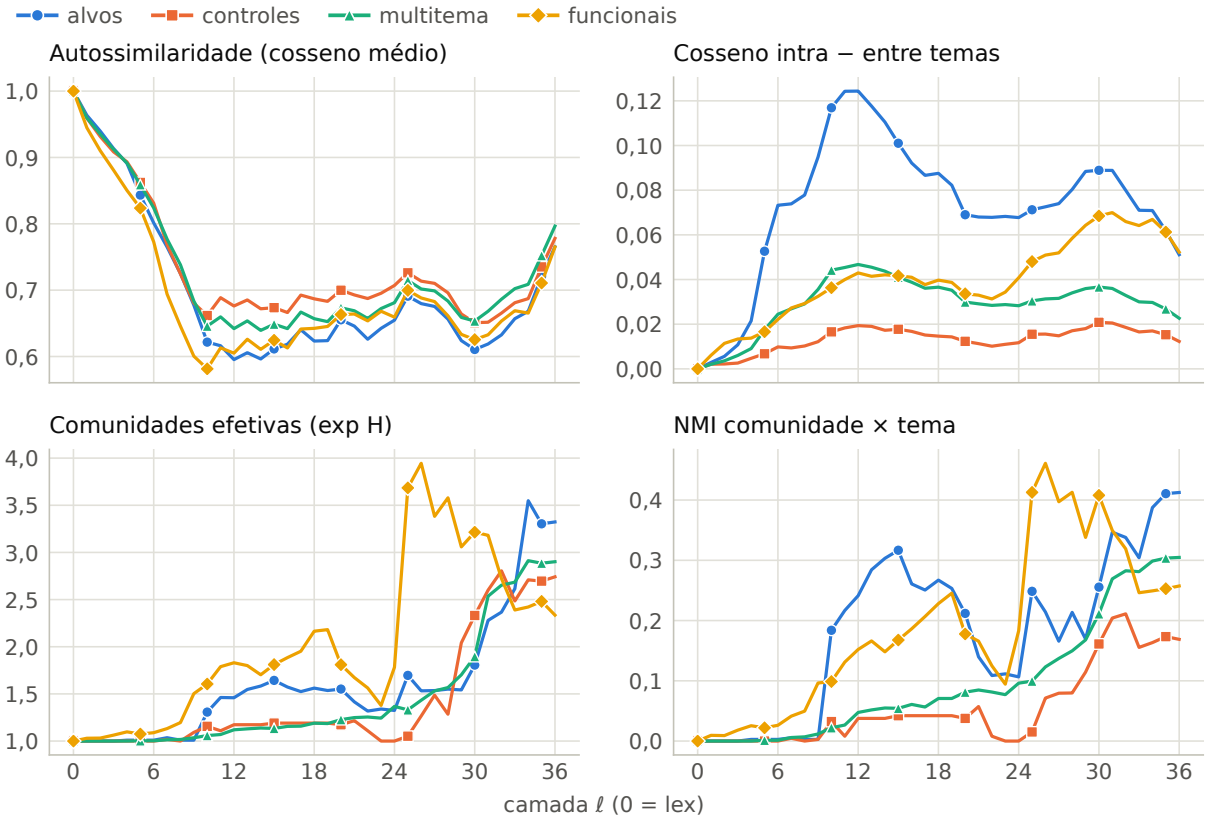


Figura 9: Separação das ocorrências de um mesmo tipo nos 36 blocos, para tipos com pelo menos 10 ocorrências: autossimilaridade, cosseno intra − entre temas, número efetivo de comunidades e NMI comunidade × tema (médias por grupo). Execução com os 36 blocos.

nos alvos) e cai para 0,08 no bloco 36. Já o NMI entre comunidade e sentido tende a subir até o fim (0,37 no bloco 18 e 0,56 no bloco 36, com linhas de base de 0,06 e 0,13). A geometria separa mais os sentidos no meio do modelo; a partição da rede segue mais o sentido no fim, quando as ocorrências de cada palavra se espalham por mais comunidades.

A hipótese H4 se confirma: as palavras-alvo se separam mais que as de controle em todas as medidas, nos blocos 18 e 36, e o sentido explica a separação melhor que o tema.

5.6 Vizinhos no vocabulário: do próprio token ao próximo

A Figura 11 mostra, bloco a bloco, a posição do próprio token e do próximo token entre as 151.669 linhas da matriz de *embeddings*, ordenadas pela semelhança com o vetor da ocorrência.

O próprio token sai cedo. No bloco 1, a linha mais próxima do vetor é a do próprio token em 90% das ocorrências; no bloco 3, em 55%; no bloco 5, em 16%. A posição mediana do próprio token passa de 1 para cerca de 800 no bloco 6, 10.000 no bloco 10 e 30.000 entre os blocos 13 e 22. Pela vizinhança no vocabulário, a identidade do token sai do vetor bem antes do que a dominância lexical sugere: as ocorrências de um token continuam perto umas das outras (P1) mesmo quando já não estão perto da linha do token em E.

O próximo token chega tarde. A posição mediana do próximo token fica entre 50.000 e 70.000 até o bloco 21 e depois cai depressa: cerca de 15.600 no bloco 25, 2.100 no bloco 30, 126 no 33, 13 no 34 e 5 no 36. No bloco 36, o próximo token é a linha mais próxima em 31% das ocorrências e está entre as 20 mais próximas em 69%. A partir do bloco 23, ele fica mais perto do vetor do que o próprio

Tabela 9: P4 palavra por palavra, no bloco 36: separação pelo tema e pelo sentido anotado, em todas as ocorrências e só nas que o contexto à esquerda decide.

							Tema		Sentido (todas)		Sentido (esq.)	
Palavra	Papel	f_t	Temas	Sentidos	Autossi-milaridade	Comunidades efetivas	Intra − entre	NMI	Intra − entre	NMI	Intra − entre	NMI
banco	alvo	43	4	4	0,78	3,1	0,055	0,36	0,068	0,33	0,085	0,38
campo	alvo	50	4	7	0,76	5,3	0,051	0,40	0,069	0,65	0,084	0,69
órgão	alvo	39	3	3	0,76	3,0	0,094	0,52	0,115	0,59	0,120	0,59
estado	alvo	50	3	4	0,76	3,5	0,052	0,48	0,058	0,49	0,068	0,54
carga	alvo	50	2	4	0,78	3,4	0,046	0,41	0,091	0,61	0,088	0,61
rede	alvo	50	2	5	0,77	2,6	0,051	0,50	0,055	0,50	0,068	0,65
nota	alvo	47	2	7	0,77	3,4	0,058	0,51	0,096	0,64	0,118	0,84
capital	alvo	42	2	4	0,77	2,7	0,030	0,15	0,065	0,39	0,072	0,40
família	alvo	37	3	4	0,69	4,0	0,027	0,32	0,118	0,63	0,120	0,62
massa	alvo	50	2	3	0,80	2,9	0,024	0,35	0,049	0,59	0,057	0,67
matriz	alvo	50	2	7	0,77	2,8	0,076	0,54	0,092	0,70	0,097	0,73
ano	controle	50	5	–	0,78	4,0	0,007	0,21	–	–	–	–
século	controle	50	5	–	0,87	1,6	−0,002	0,10	–	–	–	–
grande	controle	50	6	–	0,71	2,9	0,003	0,17	–	–	–	–
primeiro	controle	50	4	–	0,75	1,7	0,044	0,31	–	–	–	–
importante	controle	50	5	–	0,75	4,8	0,009	0,19	–	–	–	–
água	controle	50	3	–	0,81	1,4	0,013	0,03	–	–	–	–

Valores na rede `L36`. Autossimilaridade: cosseno médio entre as ocorrências do tipo; comunidades efetivas: $\exp H$ das comunidades ocupadas pelas ocorrências; intra − entre: cosseno médio entre ocorrências do mesmo tema (sentido) menos o entre temas (sentidos) diferentes; NMI: entre a comunidade das ocorrências e o seu tema (sentido). Sentido: o mesmo contraste pelo sentido anotado (Seção 2.8), em todas as ocorrências anotadas e só nas que o contexto à esquerda já decide. O NMI esperado ao acaso (média com os rótulos permutados dentro do tipo) é, em média nos alvos, 0,08 pelo tema, 0,13 pelo sentido (todas) e 0,14 pelo sentido (esq.); ele cresce com o número de rótulos. Na camada `lex`, em que as ocorrências de um tipo são o mesmo vetor, as palavras da tabela têm autossimilaridade 1,00, intra − entre 0,000, comunidades efetivas 1,0 e NMI 0,00.

token na maioria das ocorrências.

O resultado separa o modelo em três regiões. Nos primeiros blocos (até o 5, aproximadamente), o vetor ainda é "o token". Nos blocos do meio (cerca de 6 a 22), ele não se parece nem com o próprio token nem com o próximo; é aí que as comunidades seguem o texto (P3) e que os sentidos mais se afastam no cosseno (P4). No último terço, o vetor se aproxima do próximo token, as comunidades passam a seguir o que vem depois e aparecem os *hubs*.

5.7 A rede do vocabulário

A rede de tipos do vocabulário inteiro (151.643 vértices; última coluna da Tabela 6) descreve o espaço de entrada antes de qualquer contexto. Ela é conexa e tem distâncias curtas: dois tokens quaisquer estão, em média, a 5,3 passos, e o diâmetro é 19. A clusterização local média é 0,40.

***Hubs* de tokens raros.** O grau de entrada tem uma cauda extrema: o maior *hub* é escolhido por 1.756 tokens, e a assimetria é 22,6 (Figura 12). Os maiores *hubs* são caracteres isolados de escritas raras (lepcha, buginesa, silabários canadenses, mongol, formas de apresentação do árabe), todos no fim do vocabulário (ids acima de 149.000). São provavelmente tokens quase nunca vistos no treinamento, cujos vetores ficaram numa região comum, perto da qual caem muitos outros tokens pouco usados. A cauda vem sobretudo dos tokens de escritas não latinas; os de escrita latina têm uma cauda bem mais curta.

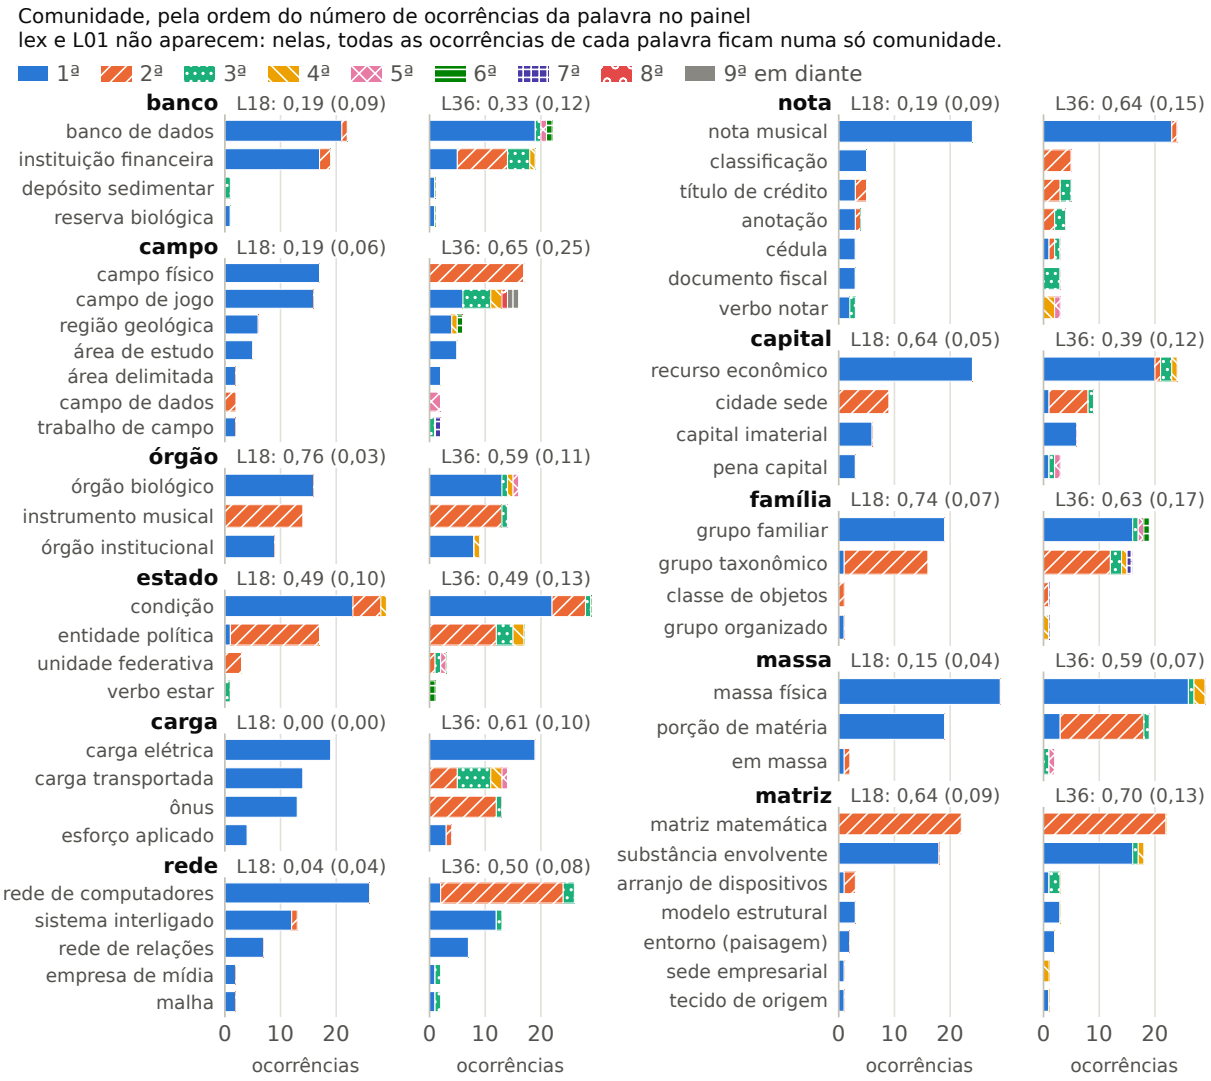


Figura 10: Sentidos anotados das palavras-alvo e as comunidades em que caem, nos blocos 18 e 36 (nas redes `lex` e `L01`, todas as ocorrências de cada palavra ficam numa só comunidade). Cada barra é um sentido, com comprimento igual ao número de ocorrências; os segmentos são as comunidades dessas ocorrências, numeradas em cada painel pela ordem do número de ocorrências da palavra (a mesma cor em painéis diferentes não indica a mesma comunidade). Um sentido que a rede separa é uma barra de uma só cor que as outras barras da palavra não usam. Acima de cada painel: o bloco, o NMI comunidade × sentido e, entre parênteses, o NMI esperado ao acaso.

Comunidades por significado, não por escrita. O Leiden encontra 171 comunidades (estabilidade 0,87), e elas quase não seguem a escrita: o NMI entre comunidade e classe de escrita é só 0,11. As comunidades misturam línguas; a terceira maior, por exemplo, tem 47% de tokens chineses, japoneses ou coreanos, e os tokens dela mais frequentes no nosso corpus são palavras portuguesas como `␣como`, `␣também` e `␣sua`. A Tabela 10 mostra o mesmo nas palavras-alvo: os vizinhos de cada uma são variantes de grafia (maiúscula, plural) e traduções para o inglês, o espanhol e o chinês. Quando os vizinhos indicam um sentido, é um só: as palavras chinesas vizinhas de *banco* significam banco como instituição financeira; as de *matriz*, matriz matemática; a de *órgão*, órgão do corpo; as de *estado*, estado como condição. Nada entre os vizinhos de *banco* lembra banco de dados ou banco de areia. Na entrada, uma palavra ambígua fica perto de um dos seus sentidos, e os outros só aparecem com o contexto.

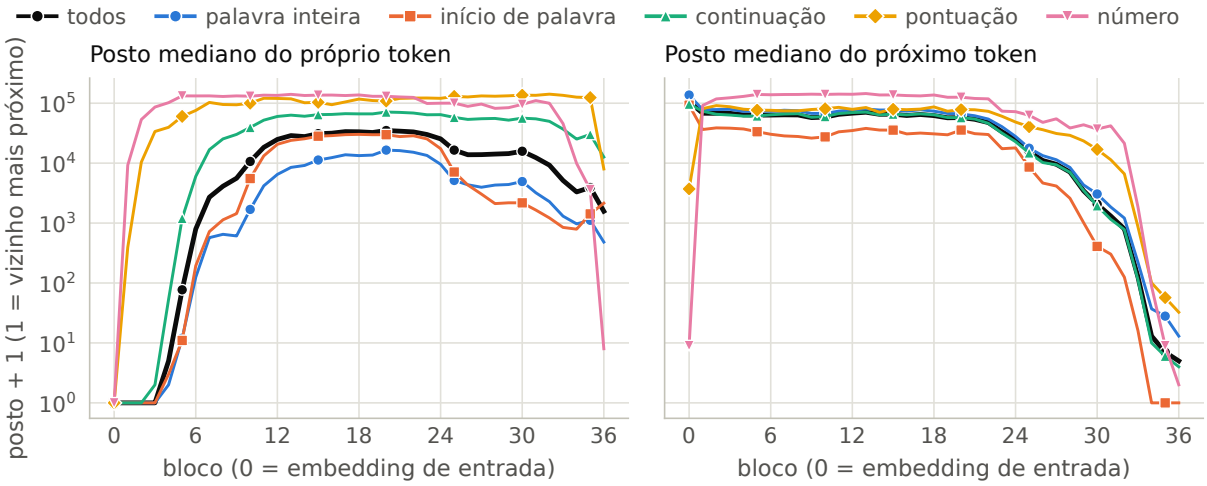


Figura 11: Posição mediana do próprio token (à esquerda) e do próximo token do texto (à direita) entre as linhas da matriz de *embeddings*, ordenadas pelo cosseno com o vetor da ocorrência, por bloco e categoria de token. O eixo vertical, em escala logarítmica, mostra a posição mais 1 (1 = a linha mais próxima).

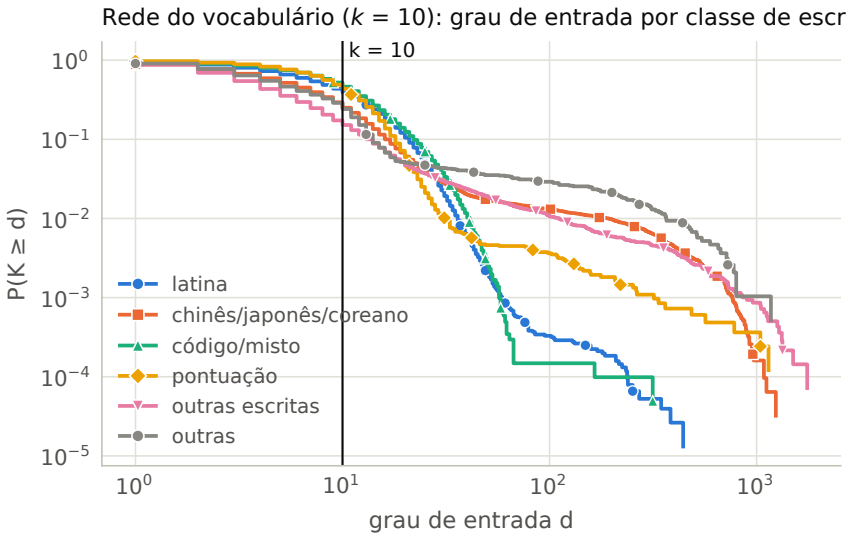


Figura 12: Rede do vocabulário: fração dos tokens com grau de entrada pelo menos d, por classe de escrita, em escala log-log.

Tabela 10: Os 10 vizinhos de cada palavra-alvo e de controle na rede do vocabulário, e quantos deles aparecem no corpus. ␣ marca o espaço inicial do token; [U+…] são caracteres que a fonte do relatório não tem (em geral, chinês, japonês, cirílico ou árabe).

Palavra	Papel	Vizinhos ($k = 10$, desempate por posição)	No corpus
banco	alvo	␣Banco ␣banc ␣bank _bank [U+9280 U+884C] .bank ␣BANK ␣banks [U+94F6 U+884C] Bank	4
campo	alvo	␣field campo \tfield Campo ␣campos (field _field ␣Campo ␣Field ␣FIELD	6
órgão	alvo	␣órg ␣[U+043E U+0440…] ␣organs [U+5668 U+5B98] ␣organización \torg ␣organ ␣Org	4(org Org
estado	alvo	estado Estado ␣Estado _estado .estado ␣estados [U+72B6 U+6001] \tstate [U+72C0 U+614B] ␣state	5
carga	alvo	␣cargar ␣carg \tload ␣load [U+52A0 U+8F7D] _load ␣Load ␣loading [U+8D1F U+8377] [U+8D1F U+8F7D]	2
rede	alvo	␣Rede rede ␣redes ␣redeem _red ␣redeemed ␣redemption (red -red Red	5
nota	alvo	nota Nota ␣notas ␣note (note _note -note ␣notes ␣Note note	6
capital	alvo	capital ␣Capital Capital [U+8D44 U+672C] ␣CAPITAL -capital ␣capitals ␣capitalize U+0430…]	4␣capitalized
família	alvo	␣familia ␣famille ␣family family ␣FAMILY ␣Familie Family ␣Family _family .family	2
massa	alvo	␣Mass ␣[U+043C U+0430…] ␣mass ␣masse mass Mass _mass ␣masses .mass ␣masa	4
matriz	alvo	␣matrix [U+77E9 U+9635] ␣Matrix \tmatrix ␣matrices _matrix Matrix matrix ␣MATRIX	3\tMatrix
planta	alvo	␣plant ␣plants ␣Plant Plant ␣Plants [U+690D U+7269] plants plant ␣plantation ␣pla	6nting
ano	controle	ano ANO ␣anos ␣año ␣anno anos anno ␣année _an .an	8
século	controle	␣siècle ␣century -century ␣década ␣[U+0627 U+0644…] ␣centuries ␣[U+0432 U+0435…] ␣Century [U+4E16 U+7EAA] [U+C101]	3
grande	controle	␣grandes ␣Grande ␣grandi ␣große ␣großen ␣grote ␣grands ␣enorme ␣large ␣[U+0431 U+043E…]	3
primeiro	controle	␣primeira ␣primero \tfirst ␣first _first first ␣ersten ␣primera .first ␣pierws	4
importante	controle	␣importantes ␣important important ␣Important [U+91CD U+8981…] [U+91CD U+8981] Important [U+91CD U+8981…] ␣[U+C911 U+C694…] [U+7684 U+91CD…]	2
água	controle	␣agua ␣water _water ␣WATER Water ␣Water ␣[U+0432 U+043E…] .water water -water	3

␣ marca o espaço inicial do token; [U+…] são caracteres que a fonte do relatório não tem (escritas não latinas ou pedaços de bytes).

6 Robustez

Os resultados só valem se não dependerem de uma escolha particular de construção. Refizemos as redes mudando uma escolha de cada vez e repetimos as métricas estruturais e a troca de vizinhos (Tabela 11). **Em nenhuma variação a conclusão qualitativa muda**: a clusterização é maior no bloco 1 que nos blocos 18 e 36, as distâncias encurtam a partir do bloco 18 e a troca de vizinhos em relação à rede lexical cresce do bloco 1 ao 36.

Tabela 11: Métricas-resumo em cada variação, ao lado da configuração principal. $\bar{C}$: clusterização local média; $\bar{\ell}$: distância média; Q: modularidade do Leiden; J: Jaccard médio com a rede lexical de mesmo k e mesma regra de empate. Cada linha muda uma escolha em relação à principal.

	`L01`				`L18`				`L36`			
Variação	$\bar{C}$	$\bar{\ell}$	Q	J	$\bar{C}$	$\bar{\ell}$	Q	J	$\bar{C}$	$\bar{\ell}$	Q	J
Principal ($k = 10$, união, sorteio)	0,618	7,08	0,916	0,354	0,365	5,12	0,764	0,158	0,353	5,28	0,768	0,096
$k = 5$	0,595	10,72	–	0,286	0,352	7,31	–	0,125	0,361	7,17	–	0,096
$k = 20$	0,625	5,14	–	0,510	0,339	3,95	–	0,215	0,346	4,21	–	0,095
Versão mútua	0,630	16,97	–	–	0,390	9,12	–	–	0,363	10,43	–	–
Desempate por posição	0,618	7,08	0,916	0,359	0,366	5,12	0,764	0,159	0,354	5,28	0,768	0,100
(b) todos os empatados	0,618	7,08	–	0,411	0,367	5,12	–	0,194	0,354	5,28	–	0,110
$\varepsilon = 1{,}0 \times 10^{-4}$	0,618	7,09	–	–	0,365	5,12	–	–	0,353	5,28	–	–
`L36n` (RMSNorm final)	–	–	–	–	–	–	–	–	0,343	5,33	0,770	0,094
Cosseno centrado	0,612	7,34	0,923	0,361	0,356	5,28	0,775	0,158	0,337	5,72	0,786	0,100
Leiden $\gamma = 0,5$	–	–	0,912	–	–	–	0,743	–	–	–	0,735	–
Leiden $\gamma = 2,0$	–	–	0,914	–	–	–	0,756	–	–	–	0,754	–
Louvain (checagem)	–	–	0,913	–	–	–	0,746	–	–	–	0,749	–

$\bar{C}$: clusterização local média; $\bar{\ell}$: distância média; Q: modularidade do Leiden (só nos grafos com comunidades); J: Jaccard médio com a rede `lex` de mesmo k e mesmo tratamento de empates. Cada linha muda uma dimensão em relação à principal; nas linhas `L36n` e centrada, cada coluna usa a variante da camada.

Número de vizinhos. Com $k = 5$ ou $k = 20$, os valores mudam na direção esperada (mais vizinhos, distâncias menores: no bloco 18, 7,3 com $k = 5$, 5,1 com $k = 10$ e 4,0 com $k = 20$), mas a ordem entre as camadas se mantém. A dominância relativa ao teto no bloco 36 fica entre 0,37 e 0,43 nos três valores de k.

Rede mútua. Na versão em que a aresta exige escolha dos dois lados, a rede se fragmenta e as distâncias crescem (17,0, 9,1 e 10,4 nos blocos 1, 18 e 36), mas a ordem entre as camadas é a mesma.

Empates. O desempate pela posição dá praticamente os mesmos valores que o sorteio (Jaccard de 0,359 contra 0,354 entre `lex` e `L01`). Aceitar todos os empatados (variante b) aumenta um pouco o Jaccard (0,41 no bloco 1), porque a vizinhança lexical fica maior e contém mais cópias do próprio token, mas mantém a ordem. Com uma tolerância de empate cem vezes maior ($\varepsilon = 10^{-4}$), as métricas não mudam na segunda casa decimal, e as vizinhanças de 2 a 4% das linhas das redes contextuais mudam. A Figura 13 separa as variantes por faixa de frequência. Duas delas completam a leitura da P1: o Jaccard por composição de tipos (J^w), que ignora o sorteio, fica perto de 1 entre `lex` e `L01` para os tipos frequentes, o que confirma que o bloco 1 mantém os vizinhos do mesmo token; e a variante (c), que ignora o próprio tipo e compara só quais *outros* tipos estão por perto, mostra que esses outros tipos já mudam no bloco 1 (Jaccard entre 0,3 e 0,4 em todas as faixas).

Normalização final e centragem. A saída normalizada do bloco 36 (`L36n`), que é o que o modelo usa para prever o próximo token, dá redes quase iguais às da saída bruta (clusterização 0,343 contra 0,353; Jaccard com a lexical 0,094 contra 0,096). Subtrair dos vetores a média de todas as ocorrências,

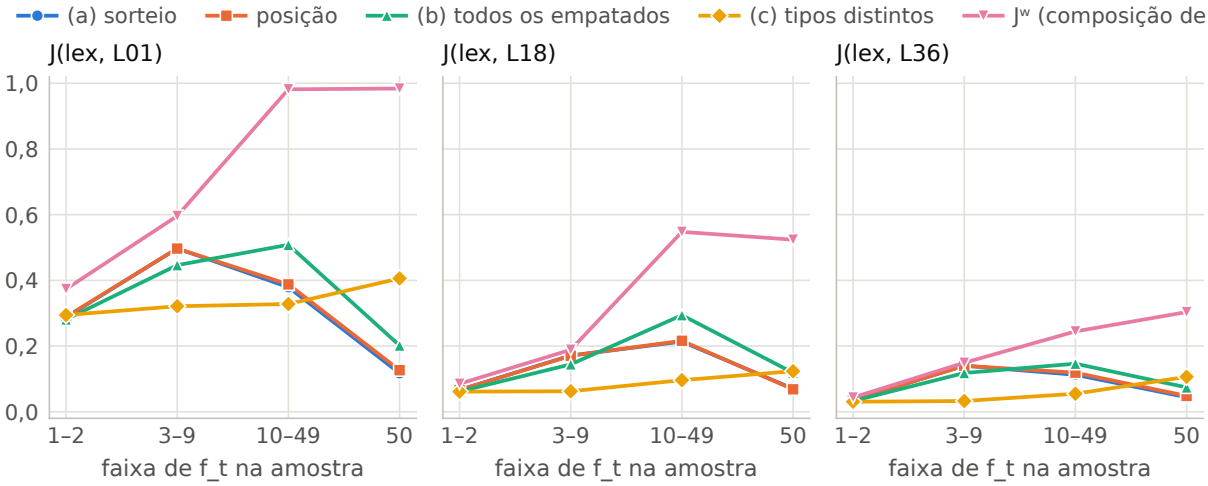


Figura 13: Jaccard médio entre a rede lexical e cada camada nas regras de empate (sorteio, posição, todos os empatados e tipos distintos) e Jaccard por composição de tipos (J^w), por faixa de frequência.

o que remove a direção comum (a anisotropia), também muda pouco (no bloco 36, distância média de 5,72 contra 5,28). A direção comum não é o que produz os resultados.

Comunidades. Com resoluções 0,5 e 2 do Leiden, e com o Louvain, a modularidade das redes `L18` e `L36` fica entre 0,73 e 0,76, perto da principal (0,76 e 0,77).

O que não foi testado. As concordâncias da P3 e a separação da P4 foram medidas só na configuração principal (e nos 36 blocos), e não nas variações acima. Uma rede construída só com os vértices do núcleo, prevista no plano, não foi feita: ela exige refazer o k-NN, porque o k-NN de um subconjunto não é um recorte do k-NN completo (quando os vizinhos de fora saem, cada vértice precisa escolher outros).

7 Discussão

A Tabela 12 junta as respostas às quatro perguntas.

Tabela 12: As hipóteses e o que os resultados mostram.

Hipótese	Resultado	Evidência principal
H1. A dominância lexical cai, mas fica acima do acaso; surgem *hubs*; as comunidades se alinham menos ao token.	confirmada	Dominância de 0,70 para 0,25 (acaso abaixo de 0,004); assimetria do grau de entrada de 0 para 4,9; concordância das comunidades com o token de 0,32 para 0,19.
H2. Pedaços de palavra mudam antes das palavras inteiras.	em parte	Continuações e números perdem a identidade até o bloco 4; palavras inteiras, aos poucos e sobretudo depois do bloco 28; inícios de palavra quase não perdem.
H3. As comunidades passam do token ao contexto e, no fim, ao próximo token.	confirmada, com correção	O contexto tem máximo nos blocos 12 a 19 e cai depois; o próximo token sobe a partir do bloco 21.
H4. Palavras ambíguas se separam mais que as de controle.	confirmada	NMI comunidade × tema de 0,41 contra 0,17 no bloco 36; separação maior pelo sentido do que pelo tema em todas as 11 palavras.

Três regiões do modelo. Juntas, as medidas descrevem o Qwen3-4B-Base em três regiões. Nos primeiros blocos (até o 5, aproximadamente), o vetor de uma ocorrência ainda é basicamente o seu token: a rede do bloco 1 é a rede lexical com os empates desfeitos, e a linha mais próxima na matriz de *embeddings* é a do próprio token. Nos blocos do meio (de 6 a 22, aproximadamente), o vetor deixa de se parecer com o próprio token e ainda não se parece com o próximo; é nessa região que as comunidades seguem o artigo, o parágrafo e o tema, e que os sentidos de uma palavra ambígua mais se afastam. No último terço, o vetor se aproxima do token que vem depois, as comunidades passam a segui-lo, a anisotropia cresce e surgem *hubs* fortes. A transição entre as duas últimas regiões não é suave: nos blocos 22 a 25, a troca de vizinhos entre blocos, a concordância com o contexto e a distância ao próximo token mudam ao mesmo tempo. Essa divisão é coerente com análises do tipo "lente de *logits*" [6], em que as previsões do modelo só se formam nas camadas finais.

O que as redes mostram além das médias de pares. A autossimilaridade, a medida clássica de quanto um token ficou contextual [3], cai até o meio do modelo e volta a subir no fim, igual para palavras ambíguas e estáveis. Sozinha, ela sugeriria que o último bloco é "menos contextual" que o do meio. As redes mostram outra coisa: a troca de vizinhos continua até o último bloco, as comunidades mudam de natureza (do texto para o próximo token), e a separação das palavras ambíguas pela rede cresce até o fim. A subida da autossimilaridade acompanha a anisotropia, uma direção comum a todos os vetores, e não um retorno à organização lexical.

A identidade do token é persistente. A linha do próprio token em E deixa de ser a mais próxima já no bloco 5, mas as ocorrências de um mesmo token continuam vizinhas umas das outras muito depois: a dominância lexical das palavras inteiras ainda é 0,64 no bloco 20. O modelo mantém as ocorrências de um token juntas numa direção que não é mais o seu *embedding* de entrada.

O papel da fragmentação. O tokenizer do Qwen3 divide muito o português, e isso aparece nos resultados. Uma continuação de palavra (`co` em "ban co") não significa nada sozinha e perde a identidade logo nos primeiros blocos, quando o modelo junta os pedaços. Um início de palavra mantém a identidade até o fim, provavelmente porque o próximo token, a continuação da palavra, depende sobretudo dele. Com um tokenizer que preservasse mais palavras inteiras, a curva média de reorganização provavelmente seria diferente.

Conclusão. Redes k-NN sobre as mesmas ocorrências, uma por camada, permitem acompanhar a reorganização das representações de um Transformer vértice a vértice e em várias escalas. No Qwen3-4B-Base e em texto enciclopédico em português, essa reorganização é grande, não monótona e dependente do tipo de token: a identidade lexical cede espaço aos poucos, o contexto do texto domina o meio do modelo e o próximo token domina o fim, e as palavras ambíguas separam os seus sentidos. A rede do vocabulário completa o quadro do lado da entrada: ela é organizada por significado entre línguas, e não por escrita, e os seus *hubs* são tokens raros, provavelmente pouco treinados.

8 Limitações

Cada limitação abaixo diz o que pode distorcer os resultados e o que foi feito a respeito.

Os temas são recortes, e não áreas inteiras. A busca por categorias para em 600 títulos e abre as subcategorias em ordem alfabética (Seção 2.2). Cada tema é, portanto, o conjunto de artigos próximos da sua categoria raiz e alfabeticamente primeiros, com artigos pouco típicos (prêmios em Física, canções em Futebol). O mesmo corte limita o descarte de páginas multitema: uma página só é reconhecida como multitema se estiver na lista truncada de dois temas. A comparação entre camadas

não é afetada, porque os vértices são os mesmos em todas as redes; as análises que usam o tema como rótulo (P3 e P4) herdam o recorte.

No núcleo, o tema significa coisas diferentes em temas diferentes. Os 5 artigos do núcleo de cada tema foram sorteados entre todos os artigos do tema, incluindo os das categorias extras. Em Economia e Biologia, os 5 vieram de categorias extras, e em Computação e Geografia, 2 de 5; ao todo, 39% dos vértices do núcleo vêm de artigos de categorias extras. Um desses artigos ("Frank Costello", alcançado por Direito tributário) é uma biografia que escapou do filtro de caixas de informação. Para ver se isso muda a P3, refizemos a concordância com o tema só nos vértices de artigos da categoria raiz: no bloco 18, ela vai de 0,197 para 0,205, e nas outras camadas muda menos de 0,01. O efeito sobre os números é pequeno, mas a leitura "tema = área" vale menos para Economia e Biologia. O código tem uma opção para sortear o núcleo só na categoria raiz, que não foi usada nesta execução.

O tema é só um indicador do sentido, e os sentidos foram anotados por um modelo de linguagem. Um artigo de Computação pode falar do Banco Central, e por isso a P4 usa também o sentido anotado. A anotação foi feita pelo Claude Opus 5.5, sem revisão humana e sem segundo anotador, então não há medida de concordância entre anotadores. O próprio anotador definiu os rótulos de cada palavra, e com outra granularidade (juntar ou separar sentidos próximos) a separação mediria outra coisa. A marca de "contexto à esquerda decide" foi dada já sabendo o sentido. A comparação com os controles, que não dependem da anotação, aponta na mesma direção.

O Qwen3 fragmenta o português. Boa parte dos vértices é pedaço de palavra, cuja vizinhança lexical reflete a grafia e não o significado. As palavras-alvo ficaram restritas às que são um token só, e quatro candidatas saíram por isso (*corrente*, *onda*, *célula* e *núcleo*); *planta* saiu por falta de ocorrências. Os resultados são sempre separados por categoria de token, e as interpretações sobre sentido usam só palavras inteiras. Não testamos modelos com tokenizers melhores para o português.

A amostra é desenhada. As frequências na amostra refletem as cotas (50 e 20 ocorrências), e parte da estrutura da rede lexical vem disso: os componentes isolados e os grupos muito clusterizados são justamente os tipos com cotas. O núcleo tem três quartos dos vértices, e as métricas globais descrevem sobretudo texto corrido. Por isso as análises por tipo exigem pelo menos 3 ocorrências (10 na P4) e a P3 é feita só no núcleo.

Os primeiros tokens formam uma ilha. Os 80 vértices da posição 1 têm ativações enormes no bloco 18 e só se ligam entre si (Seção 5.1). Eles quase não mudam as métricas globais, mas podem formar uma comunidade própria no núcleo; esse efeito sobre a P3 não foi medido.

Precisão numérica. O modelo roda em *bfloat16*, com 8 bits de mantissa, e os vetores são guardados nessa precisão. O cosseno em precisão dupla é exato para os vetores guardados, mas eles já carregam o arredondamento do modelo. Dentro de um grupo de prefixo, a maior diferença numa coordenada foi de 448,0, numa das coordenadas gigantes dos vetores da posição 1 no bloco 18; a cópia dos vetores dentro dos grupos remove esse ruído onde ele mais importa, e a tolerância maior de empate ($\varepsilon = 10^{-4}$) não mudou os resultados.

A Wikipédia provavelmente está no treinamento do modelo. O Qwen3 foi treinado em cerca de 36 trilhões de tokens de fontes não detalhadas [8], e a Wikipédia em português quase certamente faz parte delas. O modelo pode ter visto os parágrafos analisados, o que pode tornar as previsões do próximo token mais acertadas do que seriam em texto novo.

A limpeza deixa algumas frases incompletas. A primeira frase de muitos artigos usa predefinições para pronúncia, etimologia ou datas ("X (em grego: ...) é..."), que são descartadas. A limpeza tira os restos visíveis, mas algumas frases ficam mais curtas ou pouco naturais. O efeito atinge só as primeiras posições de alguns parágrafos.

Um modelo, uma língua, um tipo de texto. Os resultados são de um único modelo, numa revisão fixa, em texto enciclopédico em português. Não sabemos se as três regiões descritas na Seção 7 aparecem nos mesmos blocos em outros modelos.

Material complementar

- Código, configurações e dados: https://github.com/annwith/gender-representation-networks. Cada etapa do pipeline roda com `uv run gender-networks <etapa> -config configs/experiment.yaml`; a execução com os 36 blocos usa `configs/all-layers.yaml`.
- Relatório técnico, com o método completo, as alternativas descartadas, os problemas encontrados e todas as figuras e tabelas: https://github.com/annwith/gender-representation-networks/tree/main/report/relatorio.
- Estudo de viabilidade feito antes do pipeline: PDF no repositório.
- Página interativa da coleta, do corpus, da amostra e da construção das redes: https://annwith.github.io/gender-representation-networks/coleta/.
- As redes da entrega parcial em GraphML, com os atributos dos vértices: `data/graphml/` no repositório.
- A anotação dos sentidos e o seu protocolo: `data/annotations/` no repositório.

Referências

[1] V. D. Blondel, J.-L. Guillaume, R. Lambiotte e E. Lefebvre. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, P10008, 2008.

[2] G. Csárdi e T. Nepusz. The igraph software package for complex network research. *InterJournal, Complex Systems*, 1695, 2006.

[3] K. Ethayarajh. How contextual are contextualized word representations? Comparing the geometry of BERT, ELMo, and GPT-2 embeddings. Em *Proceedings of EMNLP-IJCNLP*, 2019.

[4] L. Hubert e P. Arabie. Comparing partitions. *Journal of Classification*, 2(1):193–218, 1985.

[5] M. E. J. Newman. Modularity and community structure in networks. *Proceedings of the National Academy of Sciences*, 103(23):8577–8582, 2006.

[6] nostalgebraist. Interpreting GPT: the logit lens. *LessWrong*, 2020.

[7] O. Press e L. Wolf. Using the output embedding to improve language models. Em *Proceedings of EACL*, 2017.

[8] Qwen Team. Qwen3 technical report. *arXiv:2505.09388*, 2025.

[9] M. Radovanović, A. Nanopoulos e M. Ivanović. Hubs in space: popular nearest neighbors in high-dimensional data. *Journal of Machine Learning Research*, 11:2487–2531, 2010.

[10] M. Sun, X. Chen, J. Z. Kolter e Z. Liu. Massive activations in large language models. *arXiv:2402.17762*, 2024.

[11] V. A. Traag, L. Waltman e N. J. van Eck. From Louvain to Leiden: guaranteeing well-connected communities. *Scientific Reports*, 9:5233, 2019.

[12] N. X. Vinh, J. Epps e J. Bailey. Information theoretic measures for clusterings comparison: variants, properties, normalization and correction for chance. *Journal of Machine Learning Research*, 11:2837–2854, 2010.