

MO438 – Redes Complexas: Entrega Parcial (Redes Direcionadas)

Da rede lexical à rede contextual: reorganização das representações internas de Transformers com Redes Complexas

Juliana Midlej do Espirito Santo (RA 200208)

1. Introdução

Na entrada de um Transformer, todas as ocorrências de um mesmo token têm o mesmo *embedding*; ao atravessar as camadas, essas representações incorporam o contexto e se reorganizam. O projeto descreve essa transformação como uma sequência de redes complexas sobre **os mesmos vértices**: cada vértice é uma *ocorrência* de um token em um texto, e cada ocorrência aponta para as k ocorrências mais semelhantes a ela. Comparando as redes camada a camada, medimos quanto a vizinhança deixa de ser determinada pela identidade do token e passa a refletir o contexto. Esta versão analisa as redes **direcionadas**, que são o objeto produzido diretamente pelo k-NN.

Dados do projeto: <https://github.com/annwith/gender-representation-networks>. As redes estão em [data/graphml/](#), em GraphML (*rede_k10_directed.graphml*), com os atributos dos vértices descritos em [data/graphml/README.md](#); os arcos não têm atributos. Esta versão é gerada por `scripts/partial_delivery/export_networks.py`, com a opção `--sym directed`. A visualização das redes é entregue em um arquivo separado, [entrega-parcial-visualizacao.pdf](#). A página interativa <https://annwith.github.io/gender-representation-networks/coleta/> mostra, passo a passo, como as redes foram construídas.

2. Origem dos dados e construção das redes

As redes são originais, construídas por nós a partir de duas fontes públicas: a **Wikipédia em português** (<https://pt.wikipedia.org>, CC BY-SA), obtida pela API MediaWiki a partir de 8 categorias temáticas, com a revisão de cada artigo em `data/corpus/manifest.csv`; e o modelo **Qwen3-4B-Base** (36 blocos, revisão 906bfd4), cujo *tokenizer* também define os tokens. Na página interativa, as abas **Rede**, **Amostra** e **Construção** ilustram a coleta, a amostra de vértices e a construção dos arcos.

Coleta. Em cada tema, uma busca em largura percorre as subcategorias até a profundidade 2, para em 600 títulos e sorteia 150 artigos. A busca para antes de abrir todas as subcategorias (de 7 de 79 em computação a 98 de 439 em música), e, como a API as lista em ordem alfabética, o corte não é aleatório: os temas são “artigos próximos da categoria raiz”, e não a área inteira, o que basta para o nosso uso (temas bem separados). Outras 16 categorias ligadas a temas (profundidade 1, até 60 artigos cada) reforçam sentidos raros das palavras-alvo (*nota* como *cédula*, *banco* de areia).

Vértices. Cada vértice é uma *ocorrência*: um token do Qwen3, que pode ser só um pedaço de palavra, numa posição de um parágrafo. São 13.606 ocorrências de 2.864 tipos de token, em 3.230 parágrafos de 1.172 artigos (o corpus tem 17.066 parágrafos de 2.153 artigos), com no máximo 50 ocorrências por tipo. O **núcleo** (10.020 vértices, 74%) reúne *todos* os tokens de 80 parágrafos sorteados, 10 por tema, inclusive fragmentos, números e pontuação. Como 80 parágrafos quase não repetem palavras de conteúdo, três estratos acrescentam palavras inteiras sorteadas em outros parágrafos, nos quais o resto do texto serve só de contexto: 11 palavras polissêmicas (**alvos**, 477 ocorrências, com uma cota por tema de sentido, como *banco* em economia, computação e geografia), 6 palavras sem ambiguidade forte (**controles**, 277) e 150 palavras presentes em ao menos 3 temas (**multitemáticas**, 2.832). Como o núcleo tem três quartos dos vértices, as medidas globais descrevem sobretudo texto corrido.

Vetores. Cada parágrafo, precedido do separador `<|endoftext|>`, passa sozinho pelo Qwen3, sem o título nem os outros parágrafos do artigo. O vetor **lex** é a linha do token na matriz de *embeddings*, igual para todas as ocorrências do token; **L01**, **L18** e **L36** são as saídas brutas (antes da normalização final) dos blocos 1, 18 e 36, de dimensão 2560, lidas por *hooks* do PyTorch na posição de cada ocorrência. Como a atenção é causal, o vetor de uma posição depende só do seu token e dos anteriores.

Arcos. Cada ocorrência i aponta, entre as outras 13.605, de qualquer parágrafo, artigo ou tema, para as $k = 10$ de maior cosseno (calculado em `float64`) com o seu vetor x_i : $i \rightarrow j$ para $j \in N_i$, o conjunto desses vizinhos. A comparação entre parágrafos diferentes acontece só no espaço dos vetores, e as quatro redes diferem apenas em x_i . Em *lex*, as ocorrências de um mesmo token são idênticas, e os empates são desfeitos ao acaso. Os arcos não têm peso: não guardam o valor do cosseno.

3. Definições para a rede direcionada

Clusterização (Fagiolo, 2007). Com $S = A + A^\top$, o número de triângulos dirigidos que passam por i é $t_i = \frac{1}{2}(S^3)_{ii}$, e o máximo possível é $D_i = d_i^{\text{tot}}(d_i^{\text{tot}} - 1) - 2d_i^{\leftrightarrow}$, em que $d_i^{\text{tot}} = d_i^{\text{in}} + d_i^{\text{out}}$ e $d_i^{\leftrightarrow}$ é o número de vizinhos recíprocos. A clusterização local é $C_i^{\rightarrow} = t_i/D_i$, definida só quando $D_i > 0$, isto é, quando i tem ao menos 2 vizinhos distintos (aqui, sempre, pois o grau de saída é 10). Os coeficientes globais são a média $\bar{C}^{\rightarrow}$ sobre esses vértices e a transitividade dirigida $T^{\rightarrow} = \sum_i t_i / \sum_i D_i$; com A simétrica, eles se reduzem aos não direcionados.

Componentes. Há duas noções: *fracas*, ignorando o sentido dos arcos (são as componentes da rede não direcionada), e *fortes*, em que há caminho de i para j e de j para i .

Distâncias. $d(i, j)$ é o número de arcos do menor caminho dirigido de i a j ; não é simétrica e vale ∞ quando não há caminho. Como nenhuma das redes é fortemente conexa, a média sobre todos os pares e o diâmetro são ∞ . Reportamos, com a fração de pares ordenados que têm caminho, três substitutos finitos: (a) média e máximo só sobre os pares com caminho; (b) média e diâmetro na maior componente forte; (c) a eficiência global $E = \frac{1}{|V|(|V|-1)} \sum_{i \neq j} 1/d(i, j)$, com $1/\infty = 0$, e sua inversa $1/E$.

4. Análise inicial

Tabela 1: Métricas das quatro redes direcionadas ($k = 10$). Distâncias exatas, por busca em largura a partir de cada vértice. As duas últimas linhas comparam as redes; o Jaccard é $|A \cap A'|/|A \cup A'|$, com A os arcos da rede e A' os da coluna anterior.

Métrica	lex	L01	L18	L36
Vértices	13.606	13.606	13.606	13.606
Arcos	136.060	136.060	136.060	136.060
Grau médio de entrada = de saída	10	10	10	10
Grau de entrada máximo	29	60	55	247
Vértices com grau de entrada 0	0,7%	3,6%	0,7%	5,4%
Reciprocidade (arcos com arco inverso)	49,1%	57,3%	60,7%	43,7%
Densidade ($\times 10^{-4}$)	7,350	7,350	7,350	7,350
Transitividade dirigida $T^{\rightarrow}$	0,440	0,510	0,325	0,230
Clusterização local média $\bar{C}^{\rightarrow}$	0,437	0,534	0,331	0,296
Componentes fracas	44	40	2	2
Componentes fortes	1.059	1.768	173	1.517
Maior componente forte (vértices)	2.640 (19,4%)	3.862 (28,4%)	12.997 (95,5%)	10.930 (80,3%)
Pares ordenados com caminho	17,7%	25,4%	95,1%	80,2%
(a) Distância média entre pares com caminho	10,37	11,28	6,97	9,96
(a) Maior distância finita	33	39	20	50
(b) Distância média na maior comp. forte	9,80	10,36	6,95	9,73
(b) Diâmetro da maior comp. forte	30	37	20	50
(c) Eficiência global E	0,020	0,027	0,147	0,100
(c) Distância harmônica $1/E$	49,41	36,86	6,79	9,98
Arcos entre ocorrências do mesmo token	70,1%	69,4%	42,6%	25,1%
Jaccard dos arcos com a rede anterior	—	0,316	0,181	0,162

Tamanho, grau e densidade. As quatro redes têm 13.606 vértices e 136.060 arcos. Todo vértice tem grau de saída exatamente $k = 10$, então o grau médio de entrada e de saída é 10, e a densidade $\rho = |A|/(|V|(|V| - 1)) = k/(|V| - 1) = 7,35 \times 10^{-4}$ é fixada pela construção. A informação está no grau de entrada d_i^{in} (quantos escolheram i), cuja distribuição (Fig. 1) diferencia as redes: em lex o máximo é 29; em L36 ele chega a 247, e 5,4% dos vértices não são escolhidos por ninguém (*hubness*).

Clusterização. $T^{\rightarrow}$ e $\bar{C}^{\rightarrow}$ são altas em lex e L01 (0,44–0,53) e menores em L18 e L36 (0,23–0,33). A distribuição de $C_i^{\rightarrow}$ em L18 e L36 se concentra perto de 0,2. Em lex ela tem dois picos (perto de 0,18 e de 0,45).

Componentes (Fig. 2). As componentes fortes são muito mais numerosas (1.059 em lex, 1.768 em L01, 173 em L18 e 1.517 em L36) que as fracas (44, 40, 2 e 2). Em lex, 58% das ocorrências têm os 10 vizinhos do próprio token: os grupos de ocorrências de um token frequente apontam só para dentro e formam “ralos” de onde nenhum arco sai (388 componentes, 64% dos vértices). Em L36, os tamanhos-1 vêm sobretudo dos vértices que ninguém escolhe.

Distâncias (Fig. 3). Os pares sem caminho são 82% em lex, 75% em L01, 5% em L18 e 20% em





Figura 1: À esquerda, a distribuição dos graus de entrada, $P(K \geq d)$ em escala log-log. À direita, a da clusterização local dirigida $C_i^{\rightarrow}$.




Figura 2: Distribuição dos tamanhos das componentes fortes (o título dá o número de componentes e o rótulo, o tamanho da maior).




Figura 3: Distâncias dirigidas: fração de *todos* os pares ordenados a cada distância finita. A área sob cada curva é a fração de pares com caminho (Tabela 1); os demais têm $d = \infty$.

L36, e cada substituto distorce a comparação: (a) compara médias sobre populações diferentes (10,4 em lex, sobre 18% dos pares, e 7,0 em L18, sobre 95%) e não é monótona, pois remover um arco pode *diminuir* a média; (b) compara subconjuntos diferentes (a maior componente forte de lex tem só 19% dos vértices); (c) mistura alcance com distância ($1/E$ dá 49 em lex contra 6,8 em L18, sobretudo porque lex tem muitos pares sem caminho). Em L36, a maior distância finita chega a 50.

Comparação entre as redes. As duas últimas linhas da Tabela 1 comparam as redes arco a arco. A fração dos arcos entre ocorrências do mesmo token é de 70% em lex e 69% em L01 e cai para 43% em L18 e 25% em L36. O Jaccard com a rede anterior é 0,18 de L01 para L18 e 0,16 de L18 para L36: os arcos mudam tanto entre os blocos 18 e 36 quanto entre os blocos 1 e 18. Entre lex e L01 (0,32), ele subestima a semelhança: em lex, o desempate sorteia quais cópias idênticas se ligam.

Síntese. A versão direcionada confirma a reorganização lex/L01 $\rightarrow$ L18/L36 (clusterização menor, componente forte gigante, *hubs* em L36) e mostra, arco a arco, que ela continua entre os blocos 18 e 36. Os grupos fechados por token em lex e os vértices não escolhidos em L36 deixam muitos pares sem caminho.