

MO438 – Redes Complexas: Entrega Parcial (Redes Direcionadas)

Da rede lexical à rede contextual: reorganização das representações internas de Transformers com Redes Complexas

Juliana Midlej do Espirito Santo (RA 200208)

1. Introdução

Na entrada de um Transformer, todas as ocorrências de um mesmo token têm o mesmo *embedding*; ao atravessar as camadas, essas representações incorporam o contexto e se reorganizam. O projeto descreve essa transformação como uma sequência de redes complexas sobre **os mesmos vértices**: cada vértice é uma *ocorrência* de um token em um texto, e cada ocorrência aponta para as k ocorrências mais semelhantes a ela. Comparando as redes camada a camada, medimos quanto a vizinhança deixa de ser determinada pela identidade do token e passa a refletir o contexto. Esta versão analisa as redes **direcionadas**, que são o objeto produzido diretamente pelo k-NN.

Dados do projeto: <https://github.com/annwith/gender-representation-networks>. As redes, em GraphML, estão em [data/graphml/](https://github.com/annwith/gender-representation-networks/blob/main/data/graphml/). Esta versão é gerada pelo script `export_networks.py`, em `scripts/partial_delivery/`, com a opção `--sym directed`. A visualização das redes (item 9) é entregue em um arquivo separado, [entrega-parcial-visualizacao.pdf](#).

2. Origem dos dados e construção das redes

As redes são originais, construídas por nós a partir de duas fontes públicas: a **Wikipédia em português** (<https://pt.wikipedia.org>, CC BY-SA), obtida pela API MediaWiki a partir de 8 categorias temáticas, com a revisão de cada artigo em `data/corpus/manifest.csv`; e o modelo **Qwen3-4B-Base** (36 blocos, revisão 906bfd4), cujo *tokenizer* também define os tokens.

Coleta: em cada tema, uma busca em largura percorre as subcategorias até a profundidade 2 e para em 600 títulos, entre os quais são sorteados 150 artigos. Como a API lista as subcategorias em ordem alfabética, o corte não é aleatório: os oito temas atingiram o limite tendo aberto só parte das subcategorias (de 7 de 79 em computação a 98 de 439 em música), e, nas listas de subcategorias por país de música e futebol, só as do começo do alfabeto foram abertas. Os temas são, portanto, “artigos próximos da categoria raiz”, e não a área inteira, o que basta para o uso que fazemos deles (temas bem separados). Para reforçar sentidos raros dos alvos (*nota* como cédula, *banco* de areia), entram também 16 categorias extras ligadas a temas (profundidade 1, até 60 artigos cada; `configs/experiment.yaml`), com 475 dos 1.172 artigos e 38% dos vértices.

Vértices: Cada vértice é uma *ocorrência*: um token do *tokenizer* do Qwen3, que pode ser só um pedaço de palavra, numa posição de um parágrafo. A rede não cobre o corpus inteiro (17.066 parágrafos de 2.153 artigos). São 13.606 ocorrências de 2.864 tipos de token, em 3.230 parágrafos de 1.172 artigos, escolhidas em quatro estratos com no máximo 50 ocorrências por tipo (`configs/experiment.yaml`, semente 438):

- **Núcleo** (10.020 vértices, 74%): em cada um dos 8 temas, sorteamos 5 artigos e 2 parágrafos de cada um, 80 parágrafos ao todo (0,5% do corpus). Nesses parágrafos *todos* os tokens são vértices: palavras, fragmentos, números e pontuação. Das 11.935 ocorrências, o teto retira ao acaso 1.915, de 25 tipos frequentes (vírgula, ponto, *de*, *que*, *-ão*...).
- **Alvos** (477): 11 palavras polissêmicas (*banco*, *campo*, *nota*...), com uma cota por tema de sentido (*banco* em economia, computação e geografia). *Planta* saiu da amostra por não chegar a 10 ocorrências em dois temas.
- **Controles** (277): 6 palavras frequentes sem ambiguidade forte (*ano*, *água*...), com cotas iguais às dos alvos.
- **Multitemáticas** (2.832): 150 palavras de conteúdo presentes em ao menos 3 temas, até 20 ocorrências cada.

Os três últimos estratos sorteiam palavras inteiras nos demais parágrafos, no máximo uma ocorrência da mesma palavra por parágrafo e três por artigo. Nesses 3.150 parágrafos, só as posições sorteadas são vértices, e o resto do texto serve apenas de contexto (2.762 deles têm um único vértice). O núcleo dá uma amostra de texto corrido. Os demais estratos existem porque 80 parágrafos quase não repetem

palavras de conteúdo, e sem repetição não há como comparar a mesma palavra em contextos diferentes. Por construção, todos os fragmentos, números, sinais de pontuação e palavras funcionais vêm do núcleo. No total são 6.583 palavras inteiras, 6.345 fragmentos de palavra (início ou continuação), 351 números e 327 sinais de pontuação. Como o núcleo reúne três quartos dos vértices, as medidas globais descrevem sobretudo texto corrido. O sorteio de 10 parágrafos por tema, feito com uma única semente, pesa no vocabulário: 2.780 dos 2.864 tipos aparecem no núcleo.

Extração dos vetores: cada parágrafo é tokenizado, recebe na frente o separador de documentos `<|endoftext|>` e passa sozinho pelo Qwen3, numa chamada própria e sem *cache*: o modelo não vê o título nem os outros parágrafos do artigo, e não há contexto compartilhado entre parágrafos ou artigos. A sequência é cortada logo depois da última ocorrência sorteada no parágrafo. Dentro do modelo, cada posição carrega um vetor de dimensão 2560 (o fluxo residual), que cada um dos 36 blocos atualiza com atenção e MLP; como a atenção é causal, o vetor de uma posição depende só do seu token e dos anteriores. O vetor **lex** não passa pelo modelo: é a linha do token na matriz de *embeddings*, igual para todas as ocorrências do token. **L01**, **L18** e **L36** são capturados durante a chamada por *hooks* do PyTorch nos blocos 1, 18 e 36: quando o bloco termina, o *hook* recebe a sua saída bruta (antes da normalização final), com uma linha por posição, e guarda só as linhas das posições sorteadas. Assim, as ocorrências de um mesmo parágrafo saem da mesma chamada, cada uma lida na sua posição, com o mesmo resultado que teriam em chamadas separadas. As linhas são reunidas numa matriz 13.606×2560 por representação.

Arcos: cada ocorrência i recebe um vetor x_i e aponta, entre as outras 13.605 ocorrências (de qualquer parágrafo, artigo ou tema), para os $k = 10$ vizinhos N_i de maior cosseno ($i \rightarrow j$ para $j \in N_i$). O modelo nunca processa dois parágrafos juntos: a comparação entre ocorrências de parágrafos diferentes acontece só no espaço dos vetores. As redes diferem só em x_i : **lex**, o *embedding* de entrada (ocorrências do mesmo token são idênticas; empates desfeitos ao acaso, semente 0), e **L01**, **L18** e **L36**, a saída dos blocos 1, 18 e 36. Os arcos não têm peso: registram só que j está entre os k mais próximos de i , sem o valor do cosseno. **Arquivos:** *rede_k10_directed.graphml* (cerca de 19 MB cada); cada vértice traz token, palavra e posição do token nela, tema, artigo, contexto textual e as medidas abaixo, e os arcos não têm atributos (descrição dos atributos em *data/graphml/README.md*).

3. Definições para a rede direcionada

Graus e densidade. Todo vértice tem grau de saída exatamente k , então a informação está no grau de entrada d_i^{in} (quantos escolheram i). A densidade $\rho = |A|/(|V|(|V| - 1)) = k/(|V| - 1)$ é fixada pela construção e é igual nas quatro redes.

Clusterização (Fagiolo, 2007). Com $S = A + A^T$, o número de triângulos dirigidos que passam por i é $t_i = \frac{1}{2}(S^3)_{ii}$, e o máximo possível é $D_i = d_i^{\text{tot}}(d_i^{\text{tot}} - 1) - 2d_i^{\leftrightarrow}$, em que $d_i^{\text{tot}} = d_i^{\text{in}} + d_i^{\text{out}}$ e $d_i^{\leftrightarrow}$ é o número de vizinhos recíprocos. A clusterização local é $C_i^{\rightarrow} = t_i/D_i$, definida só quando $D_i > 0$, isto é, quando i tem ao menos 2 vizinhos distintos. Os dois coeficientes globais são a média $\bar{C}^{\rightarrow}$ sobre esses vértices e a transitividade dirigida $T^{\rightarrow} = \sum_i t_i / \sum_i D_i$. Aqui todos entram na média, pois o grau de saída é $k = 10$. Se A for simétrica, elas se reduzem às definições não direcionadas. Conferimos os valores com `networkx.clustering`.

Componentes. Há duas noções: *fracas*, ignorando o sentido dos arcos (são as componentes da rede não direcionada), e *fortes*, em que há caminho de i para j e de j para i .

Distâncias. $d(i, j)$ é o número de arcos do menor caminho dirigido de i a j . Ela não é simétrica e vale ∞ quando não há caminho. Como nenhuma das quatro redes é fortemente conexa, a média sobre todos os pares e o diâmetro são ∞ . Reportamos três substitutos finitos, que respondem a perguntas diferentes, junto com a fração de pares ordenados que têm caminho: (a) média e máximo só sobre os pares com caminho; (b) média e diâmetro dentro da maior componente forte; (c) a eficiência global $E = \frac{1}{|V|(|V|-1)} \sum_{i \neq j} 1/d(i, j)$, com $1/\infty = 0$, e sua inversa $1/E$ (distância harmônica).

4. Análise inicial

Tamanho, grau e densidade (itens 1, 6 e 7). As quatro redes têm 13.606 vértices, 136.060 arcos, grau médio de entrada e de saída igual a 10 e densidade $7,35 \times 10^{-4}$. A distribuição dos graus de entrada (Fig. 1) diferencia as redes: em **lex** o máximo é 29; em **L36** ele chega a 247, e 5,4% dos vértices não são

Tabela 1: Métricas das quatro redes direcionadas ($k = 10$). Distâncias exatas, por busca em largura a partir de cada vértice. As duas últimas linhas comparam as redes; o Jaccard é $|A \cap A'|/|A \cup A'|$, com A os arcos da rede e A' os da coluna anterior.

Métrica	lex	L01	L18	L36
Vértices	13.606	13.606	13.606	13.606
Arcos	136.060	136.060	136.060	136.060
Grau médio de entrada = de saída	10	10	10	10
Grau de entrada máximo	29	60	55	247
Vértices com grau de entrada 0	0,7%	3,6%	0,7%	5,4%
Reciprocidade (arcos com arco inverso)	49,1%	57,3%	60,7%	43,7%
Densidade ($\times 10^{-4}$)	7,350	7,350	7,350	7,350
Transitividade dirigida $T^{\rightarrow}$	0,440	0,510	0,325	0,230
Clusterização local média $\bar{C}^{\rightarrow}$	0,437	0,534	0,331	0,296
Componentes fracas	44	40	2	2
Componentes fortes	1.059	1.768	173	1.517
Maior componente forte (vértices)	2.640 (19,4%)	3.862 (28,4%)	12.997 (95,5%)	10.930 (80,3%)
Pares ordenados com caminho	17,7%	25,4%	95,1%	80,2%
(a) Distância média entre pares com caminho	10,37	11,28	6,97	9,96
(a) Maior distância finita	33	39	20	50
(b) Distância média na maior comp. forte	9,80	10,36	6,95	9,73
(b) Diâmetro da maior comp. forte	30	37	20	50
(c) Eficiência global E	0,020	0,027	0,147	0,100
(c) Distância harmônica $1/E$	49,41	36,86	6,79	9,98
Arcos entre ocorrências do mesmo token	70,1%	69,4%	42,6%	25,1%
Jaccard dos arcos com a rede anterior	—	0,316	0,181	0,162

escolhidos por ninguém (*hubness*).




Figura 1: À esquerda, a distribuição dos graus de entrada, como $P(K \geq d)$ em escala log-log (item 7; o grau de saída é 10 para todos). À direita, a distribuição da clusterização local dirigida $C_i^{\rightarrow}$ (item 3), em faixas de largura 0,025.

Clusterização (itens 2 e 3). $T^{\rightarrow}$ e $\bar{C}^{\rightarrow}$ seguem a mesma tendência da rede não direcionada: altas em lex e L01 (0,44–0,53) e menores em L18 e L36 (0,23–0,33). A distribuição de $C_i^{\rightarrow}$ em L18 e L36 se concentra perto de 0,2. Em lex ela tem dois picos (perto de 0,18 e de 0,45).

Componentes (item 8, Fig. 2). As componentes fracas são as mesmas da rede não direcionada (44, 40, 2 e 2), mas as fortes são muito mais numerosas: 1.059 em lex, 1.768 em L01, 173 em L18 e 1.517 em L36. A maior componente forte reúne 19% dos vértices em lex e 95% em L18. Em lex, 58% das ocorrências têm os 10 vizinhos do próprio token: os grupos de ocorrências de um token frequente apontam só para dentro e formam “ralos” de onde nenhum arco sai (388 componentes, 64% dos vértices). Em L36, os tamanhos-1 vêm sobretudo dos vértices que ninguém escolhe.

Distâncias (itens 4 e 5, Fig. 3). Os pares sem caminho são 82% em lex, 75% em L01, 5% em L18 e 20% em L36. Por isso os três substitutos não concordam, e cada um distorce a comparação de um jeito:




Figura 2: Distribuição dos tamanhos das componentes fortes (item 8; o título dá o número de componentes e o rótulo, o tamanho da maior). As componentes fracas são 44, 40, 2 e 2.




Figura 3: Distâncias dirigidas (itens 4 e 5). À esquerda, a fração de *todos* os pares ordenados a cada distância finita (a área sob cada curva é a fração de pares com caminho); à direita, a fração de pares sem caminho, para os quais $d = \infty$.

- **(a) Só pares com caminho.** Lex fica com 10,4 e L18 com 7,0, mas as médias são tomadas sobre 18% e 95% dos pares, ou seja, sobre populações diferentes. Essa medida não é monótona: remover um arco pode *diminuir* a média, se ele desconectar pares distantes.
- **(b) Maior componente forte.** Em lex ela tem só 19% dos vértices; a comparação vira entre subconjuntos de vértices diferentes em cada rede.
- **(c) Eficiência.** Ela é bem definida e monótona, mas mistura alcance com distância: $1/E$ dá 49 em lex contra 6,8 em L18, sobretudo porque lex tem muitos pares sem caminho, e não porque seus caminhos sejam longos.

Também há efeitos que a versão não direcionada não mostra: em L36 a maior distância finita é 50 (11 na rede de união), e a média (a) sobe de 7,0 em L18 para 10,0 em L36, ao passo que na rede de união as duas camadas ficam próximas (5,1 e 5,3).

Comparação entre as redes. As duas últimas linhas da Tabela 1 comparam as redes arco a arco. Como todo vértice tem k arcos de saída, a fração dos arcos entre ocorrências do mesmo token é a média, sobre os vértices, da fração dos seus vizinhos que são do mesmo token: 70% em lex, 69% em L01, 43% em L18 e 25% em L36. O índice de Jaccard com a rede anterior é 0,18 de L01 para L18 e 0,16 de L18 para L36, ou seja, os arcos mudam tanto entre os blocos 18 e 36 quanto entre os blocos 1 e 18. Entre lex e L01 (0,32), o índice subestima a semelhança, porque em lex as ocorrências de um token são idênticas, e quais delas se ligam é decidido pelo sorteio do desempate.

Síntese. A versão direcionada confirma a reorganização lex/L01 $\rightarrow$ L18/L36 (clusterização menor, componente forte gigante, *hubs* em L36) e mostra, arco a arco, que ela continua entre os blocos 18 e 36. Mas suas distâncias medem sobretudo *alcançabilidade*: os grupos fechados por token em lex e os vértices não escolhidos em L36 tornam a maioria ou uma parte grande dos pares inalcançável. Por isso, no restante do projeto, as distâncias serão comparadas na rede não direcionada por união, e a versão direcionada será usada para grau de entrada, reciprocidade e alcançabilidade.