

MO438 – Redes Complexas: Entrega Parcial (Visualização)

Da rede lexical à rede contextual: reorganização das representações internas de Transformers com Redes Complexas

Juliana Midlej do Espirito Santo (RA 200208)

1. As redes

A coleta dos dados, a construção das redes e as métricas estão nos documentos da entrega parcial.

Dados: <https://github.com/annwith/gender-representation-networks>; as redes, em GraphML, estão em [data/graphml/](https://github.com/annwith/graphml). **Versão interativa,** com todos os vértices, busca por palavra, a lista de vizinhos de cada ocorrência e outras cores (categoria do token, estrato da amostra, comunidade): <https://annwith.github.io/gender-representation-networks/redes/>.

2. Como as figuras foram feitas

Cada rede tem o seu próprio layout, calculado pelo UMAP do `igraph` (`layout_umap`, sem pesos, `min_dist = 0,1`, 500 épocas). O UMAP aproxima vértices ligados e afasta os não ligados. A distância no desenho só reflete a estrutura da rede de forma aproximada, e a posição e a orientação absolutas não têm significado: não dá para comparar posições entre os quatro desenhos. Cada painel mostra o disco, centrado na posição mediana, que contém 99% dos vértices; os 137 restantes de cada rede, grupos pequenos empurrados para a periferia, ficam de fora (eles aparecem na versão interativa). As arestas são traços finos e transparentes: onde há muitas, o fundo escurece. A ordem em que os vértices são desenhados é sorteada, para que nenhuma cor fique sempre por cima.

A Fig. 1 colore os vértices pelo tema do artigo (o tema Esporte vem da categoria Futebol). A Fig. 2 usa os mesmos layouts e colore os vértices pela posição do token na palavra: *continua* quando a palavra segue no token seguinte (o token é o início ou o meio de uma palavra de vários tokens), e *termina* nos demais casos (último ou único token da palavra, ou pontuação, que não pertence a nenhuma palavra). O *tokenizer* separa os números em dígitos, então todo dígito que não é o último do número também é *continua*. São 4.004 vértices *continua* (29% do total). As figuras e a Tabela 1 são geradas por `scripts/partial_delivery/draw_networks.py`, a partir dos arquivos GraphML.

3. O que as figuras mostram

Tabela 1: O que as arestas ligam nas quatro redes (união, $k = 10$). As assortatividades são o coeficiente de Newman para um atributo categórico: vale 1 quando toda aresta liga vértices da mesma classe e 0 quando as arestas se distribuem entre as classes como ao acaso.

Medida	lex	L01	L18	L36
Arestas entre ocorrências do mesmo token	68,1%	63,6%	38,9%	20,8%
Arestas entre ocorrências do mesmo tema	20,4%	22,5%	52,4%	43,9%
Assortatividade por tema	0,087	0,111	0,454	0,357
Arestas entre <i>continua</i> e <i>termina</i>	14,6%	10,7%	10,4%	2,6%
Assortatividade por posição na palavra	0,621	0,741	0,749	0,938

Por tema (Fig. 1). Em lex e L01, a rede se espalha em centenas de grupos pequenos, em geral as ocorrências de um mesmo token, com temas misturados: em lex, 68% das arestas ligam ocorrências do mesmo token e só 20% ligam ocorrências do mesmo tema (Tabela 1). Em L18, os grupos se fundem num bloco central com regiões dominadas por um tema: as arestas entre ocorrências do mesmo tema sobem para 52%, e a assortatividade por tema passa de 0,09 em lex para 0,45. Em L36, elas caem para 44% (assortatividade 0,36), e a rede se divide em dois blocos.

Por posição na palavra (Fig. 2). Em lex, as ocorrências de um mesmo token têm o mesmo vetor, e 68% das arestas as ligam entre si (Tabela 1). Como a posição na palavra quase sempre se repete entre as ocorrências de um token (*Des* sempre *continua*), a assortatividade por posição na palavra já é 0,62 só por isso. Depois, as arestas entre *continua* e *termina*, cerca de 40% ao acaso, caem para 10,4% em L18 e 2,6% em L36, e a assortatividade sobe para 0,75 e 0,94. Em L36, onde só 21% das arestas ligam ocorrências do mesmo token, a rede agrupa tokens diferentes pela posição na palavra: o bloco menor do desenho é o das ocorrências *continua*.




Figura 1: As quatro redes, cada uma com o seu layout UMAP, com os vértices coloridos pelo tema do artigo. Em cada painel ficam de fora os 137 vértices mais afastados do centro.




Figura 2: Os mesmos desenhos da Fig. 1, com os vértices coloridos pela posição do token na palavra: em azul, as ocorrências em que a palavra continua no token seguinte (*continua*); em cinza, as demais (*termina*).