

MO438 – Redes Complexas: Entrega Parcial

Da rede lexical à rede contextual: reorganização das representações internas de Transformers com Redes Complexas

Juliana Midlej do Espirito Santo (RA 200208)

1. Introdução

Na entrada de um Transformer, todas as ocorrências de um mesmo token têm o mesmo *embedding*; ao atravessar as camadas, essas representações incorporam o contexto e se reorganizam. O projeto descreve essa transformação como uma sequência de redes complexas sobre **os mesmos vértices**: cada vértice é uma *ocorrência* de um token em um texto, e cada ocorrência se liga às k ocorrências mais semelhantes a ela. Comparando as redes camada a camada, queremos medir quanto a vizinhança deixa de ser determinada pela identidade do token e passa a refletir o contexto (perguntas P1–P4 da proposta: reorganização local e global, camadas em que ela se concentra, comunidades contextuais e separação das ocorrências de um mesmo token).

Dados do projeto: <https://github.com/annwith/gender-representation-networks>. As quatro redes analisadas aqui estão em GraphML em [data/graphml/](#); o script que as gera, junto com esta análise, é [scripts/partial_delivery/export_networks.py](#). A visualização das redes (item 9) é entregue em um arquivo separado, [entrega-parcial-visualizacao.pdf](#).

2. Origem dos dados e construção das redes

As redes são originais, construídas por nós; não foram baixadas de um repositório de redes. As duas fontes usadas são públicas:

- **Textos:** Wikipédia em português (<https://pt.wikipedia.org>, licença CC BY-SA), obtida pela API MediaWiki a partir de 8 categorias temáticas: física, biologia, economia, política, computação, música, futebol (tema “esporte” nos dados) e geografia. A identificação e a revisão de cada artigo estão em [data/corpus/manifest.csv](#), o que permite baixar de novo exatamente o mesmo texto.
- **Modelo:** [Qwen3-4B-Base](#) (Hugging Face, 36 blocos, revisão 906bfd4), cujo *tokenizer* também define os tokens.

Coleta. Em cada tema, uma busca em largura percorre as subcategorias até a profundidade 2 e para em 600 títulos, entre os quais são sorteados 150 artigos. Como a API lista as subcategorias em ordem alfabética, o corte não é aleatório: os oito temas atingiram o limite tendo aberto só parte das subcategorias (de 7 de 79 em computação a 98 de 439 em música), e, nas listas de subcategorias por país de música e futebol, só as do começo do alfabeto foram abertas. Os temas são, portanto, “artigos próximos da categoria raiz”, e não a área inteira, o que basta para o uso que fazemos deles (temas bem separados). Para reforçar sentidos raros dos alvos (*nota* como *cédula*, *banco* de areia), entram também 16 categorias extras ligadas a temas (profundidade 1, até 60 artigos cada; [configs/experiment.yaml](#), com 475 dos 1.172 artigos e 38% dos vértices).

Vértices. Cada vértice é uma *ocorrência*: um token do *tokenizer* do Qwen3, que pode ser só um pedaço de palavra, numa posição de um parágrafo. A rede não cobre o corpus inteiro (17.066 parágrafos de 2.153 artigos). São 13.606 ocorrências de 2.864 tipos de token, em 3.230 parágrafos de 1.172 artigos, escolhidas em quatro estratos com no máximo 50 ocorrências por tipo ([configs/experiment.yaml](#), semente 438):

- **Núcleo** (10.020 vértices, 74%): em cada um dos 8 temas, sorteamos 5 artigos e 2 parágrafos de cada um, 80 parágrafos ao todo (0,5% do corpus). Nesses parágrafos *todos* os tokens são vértices: palavras, fragmentos, números e pontuação. Das 11.935 ocorrências, o teto retira ao acaso 1.915, de 25 tipos frequentes (vírgula, ponto, *de*, *que*, *-ão*...).
- **Alvos** (477): 11 palavras polissêmicas (*banco*, *campo*, *nota*...), com uma cota por tema de sentido (*banco* em economia, computação e geografia). *Planta* saiu da amostra por não chegar a 10 ocorrências em dois temas.
- **Controles** (277): 6 palavras frequentes sem ambiguidade forte (*ano*, *água*...), com cotas iguais às dos alvos.
- **Multitemáticas** (2.832): 150 palavras de conteúdo presentes em ao menos 3 temas, até 20 ocorrências

cada.

Os três últimos estratos sorteiam palavras inteiras nos demais parágrafos, no máximo uma ocorrência da mesma palavra por parágrafo e três por artigo. Nesses 3.150 parágrafos, só as posições sorteadas são vértices, e o resto do texto serve apenas de contexto (2.762 deles têm um único vértice). O núcleo dá uma amostra de texto corrido. Os demais estratos existem porque 80 parágrafos quase não repetem palavras de conteúdo, e sem repetição não há como comparar a mesma palavra em contextos diferentes. Por construção, todos os fragmentos, números, sinais de pontuação e palavras funcionais vêm do núcleo. No total são 6.583 palavras inteiras, 6.345 fragmentos de palavra (início ou continuação), 351 números e 327 sinais de pontuação. Como o núcleo reúne três quartos dos vértices, as medidas globais descrevem sobretudo texto corrido. O sorteio de 10 parágrafos por tema, feito com uma única semente, pesa no vocabulário: 2.780 dos 2.864 tipos aparecem no núcleo.

Extração dos vetores. Cada parágrafo é tokenizado, recebe na frente o separador de documentos `<|endoftext|>` e passa sozinho pelo Qwen3, numa chamada própria e sem *cache*: o modelo não vê o título nem os outros parágrafos do artigo, e não há contexto compartilhado entre parágrafos ou artigos. A sequência é cortada logo depois da última ocorrência sorteadada no parágrafo. Dentro do modelo, cada posição carrega um vetor de dimensão 2560 (o fluxo residual), que cada um dos 36 blocos atualiza com atenção e MLP; como a atenção é causal, o vetor de uma posição depende só do seu token e dos anteriores. O vetor **lex** não passa pelo modelo: é a linha do token na matriz de *embeddings*, igual para todas as ocorrências do token. **L01**, **L18** e **L36** são capturados durante a chamada por *hooks* do PyTorch nos blocos 1, 18 e 36: quando o bloco termina, o *hook* recebe a sua saída bruta (antes da normalização final), com uma linha por posição, e guarda só as linhas das posições sorteadas. Assim, as ocorrências de um mesmo parágrafo saem da mesma chamada, cada uma lida na sua posição, com o mesmo resultado que teriam em chamadas separadas. As linhas são reunidas numa matriz 13.606×2560 por representação.

Arestas. Cada ocorrência i recebe um vetor x_i e escolhe, entre as outras 13.605 ocorrências (de qualquer parágrafo, artigo ou tema), os $k = 10$ vizinhos de maior similaridade de cosseno (calculada em `float64`). O modelo nunca processa dois parágrafos juntos: a comparação entre ocorrências de parágrafos diferentes acontece só no espaço dos vetores. As quatro redes diferem apenas em x_i : **lex**, o *embedding* de entrada do token (ocorrências do mesmo token são idênticas, e os empates são desfeitos ao acaso, semente 0); **L01**, **L18** e **L36**, a saída dos blocos 1, 18 e 36 (inicial, intermediário e final). A relação k-NN é direcionada; as redes entregues e analisadas são as versões **não direcionadas por união**, com aresta $\{i, j\}$ quando j está entre os vizinhos de i ou i entre os de j . Por isso todo vértice tem grau $\geq k$. As redes não são ponderadas: a aresta só registra que um vértice está entre os k mais próximos do outro, sem o valor do cosseno. Usamos a união por dois motivos. Primeiro, clusterização, distâncias, componentes e comunidades são definidas para grafos não direcionados; na versão direcionada, a maioria dos pares não tem caminho (82% dos pares ordenados em *lex*), e a distância média fica infinita. Segundo, a união preserva todas as relações de vizinhança, enquanto a versão mútua (aresta só quando i e j se escolhem) descartaria de 39% a 56% dos arcos e fragmentaria *lex* em 1.497 componentes. A versão direcionada continua sendo usada para os graus de entrada (*hubs*) e a reciprocidade.

Arquivos. `rede_k10_union.graphml`, com *rede* em *lex*, L01, L18 e L36 (cerca de 17 MB cada). Cada vértice traz o token, a palavra de origem e a posição do token nela, o tema, o artigo, o contexto textual e as medidas desta análise (grau, clusterização local, componente e comunidade Leiden); as arestas não têm atributos. Os atributos estão descritos em `data/graphml/README.md`. Todas as métricas abaixo foram calculadas com *igraph* a partir dos próprios arquivos GraphML relidos do disco.

3. Análise inicial

Tamanho, grau e densidade (itens 1 e 6). As redes têm os mesmos 13.606 vértices e entre 94,7 mil e 106,3 mil arestas, com grau médio entre 13,9 e 15,6. Esse valor fica acima de $k = 10$ porque um vértice também ganha arestas de quem o escolheu como vizinho. As redes são muito esparsas: densidade $\rho = 2|E|/(|V|(|V| - 1)) \approx 10^{-3}$.

Clusterização global (item 2). Reportamos os dois coeficientes:

- a **transitividade**, $C = 3 \times (\text{nº de triângulos})/(\text{nº de triplas conexas})$;

Tabela 1: Métricas das quatro redes ($k = 10$, união). *Calculadas de forma exata sobre todos os pares de vértices da maior componente. As duas últimas linhas comparam as redes; o Jaccard é $|E \cap E'|/|E \cup E'|$, com E as arestas da rede e E' as da coluna anterior.

Métrica	lex	L01	L18	L36
Vértices	13.606	13.606	13.606	13.606
Arestas	102.656	97.061	94.739	106.307
Grau médio	15,09	14,27	13,93	15,63
Grau mínimo / máximo	10 / 37	10 / 60	10 / 55	10 / 247
Densidade ($\times 10^{-3}$)	1,109	1,049	1,024	1,149
Transitividade (clusterização global)	0,531	0,548	0,330	0,233
Clusterização local média	0,562	0,618	0,365	0,353
Componentes	44	40	2	2
Maior componente (vértices)	12.388 (91,0%)	12.677 (93,2%)	13.555 (99,6%)	13.556 (99,6%)
Distância média*	7,61	7,08	5,12	5,28
Diâmetro*	18	18	11	11
Arestas entre ocorrências do mesmo token	68,1%	63,6%	38,9%	20,8%
Jaccard das arestas com a rede anterior	—	0,371	0,194	0,163

- a **clusterização local média**, $\bar{C} = \frac{1}{|V_{\geq 2}|} \sum_{i \in V_{\geq 2}} C_i$, com $C_i = 2T_i/(d_i(d_i - 1))$, em que T_i é o número de triângulos que passam por i e d_i é o grau de i . C_i não é definido quando $d_i < 2$, então a média (e a distribuição de C_i) usa só o conjunto $V_{\geq 2}$ dos vértices de grau ≥ 2 . Aqui $V_{\geq 2} = V$, pois o grau mínimo é 10.

Os dois coeficientes são altos nas redes lexical e inicial (0,53–0,62) e caem pela metade nas camadas intermediária e final (0,23–0,37). Ainda assim, ficam duas ordens de grandeza acima da densidade, que é a clusterização esperada em um grafo aleatório com o mesmo número de vértices e de arestas. Na rede lex, as ocorrências de um mesmo token são idênticas e tendem a formar grupos quase completos, o que eleva a clusterização.




Figura 1: À esquerda, a distribuição de graus em escala log-log, como distribuição acumulada complementar $P(K \geq d)$ (item 7). À direita, a distribuição do coeficiente de clusterização local C_i (item 3), em 40 faixas de largura 0,025.

Clusterização local (item 3, Fig. 1). Em lex e L01 a distribuição de C_i se concentra entre 0,5 e 0,85, com um excesso em $C_i = 1$ (vértices cuja vizinhança é um grupo completo). Em L18 e L36 ela se desloca para um pico perto de 0,2 e uma cauda longa. A mudança atinge a maioria dos vértices; não é efeito de um grupo pequeno.

Distribuição de graus (item 7, Fig. 1). O grau mínimo é sempre $k = 10$. Em lex a cauda é curta (máximo 37); em L01 e L18 ela se alonga (máximos 60 e 55); em L36 ela se torna pesada, com máximo 247. Esse é o fenômeno de *hubness*: na camada final, poucas ocorrências são escolhidas como vizinhas por muitas outras. O fenômeno será estudado na rede direcionada (grau de entrada) no restante do projeto.

Componentes (item 8, Fig. 2). As redes lex e L01 têm 44 e 40 componentes. Além da gigante (91%




Figura 2: Distribuição dos tamanhos das componentes conexas (item 8). Os rótulos dão o tamanho da maior componente; os dois eixos estão em escala logarítmica.

e 93% dos vértices), há dezenas de componentes de 10 a 50 vértices, cada uma formada por ocorrências de 1 a 5 tipos de token: por exemplo, as 50 ocorrências de “ão” em lex e as 50 de “para” em L01. Nelas a identidade lexical isola grupos inteiros de ocorrências. Em L18 e L36 restam só 2 componentes: a gigante (99,6%) e uma de cerca de 50 vértices, formada por 50 das 80 ocorrências na primeira posição da sequência (em L18, com mais uma); as outras 30 ficam na gigante. Nessas camadas, a representação dessas 50 ocorrências é muito diferente da das demais.




Figura 3: Distribuição das distâncias entre os pares de vértices da maior componente (itens 4 e 5). A distância média é a média dessa distribuição, e o diâmetro é o maior valor com frequência positiva.

Distância média e diâmetro (itens 4 e 5, Fig. 3). Como lex e L01 não são conexas, as distâncias são calculadas na maior componente, sobre todos os pares, por busca em largura a partir de cada vértice. A distância média cai de 7,6 (lex) e 7,1 (L01) para 5,1–5,3 (L18 e L36), e o diâmetro cai de 18 para 11. Para comparação, um grafo aleatório com o mesmo tamanho e grau médio teria distância média em torno de $\ln |V| / \ln \langle d \rangle \approx 3,5$. As redes contextuais combinam, portanto, clusterização muito acima da aleatória com distâncias mais curtas que as da rede lexical.

Comparação entre as redes. Como os vértices são os mesmos, as redes podem ser comparadas aresta a aresta (fim da Tabela 1). As arestas entre ocorrências do mesmo token caem de 68% em lex para 64% em L01, 39% em L18 e 21% em L36. E cada rede guarda poucas arestas da anterior: o Jaccard é 0,19 entre L01 e L18 e 0,16 entre L18 e L36, embora estas duas tenham métricas globais parecidas. Entre lex e L01 (0,37), ele subestima a semelhança, porque em lex o desempate sorteia quais ocorrências idênticas de um token se ligam.

Síntese. Já nas métricas globais, a passagem lex/L01 → L18/L36 aparece como uma reorganização: a clusterização cai, as distâncias encolhem, as componentes isoladas por token se fundem na componente gigante e surgem *hubs*. Lex e L01 são muito parecidas. Depois do bloco 1, a reorganização é grande e continua até o último bloco: L18 e L36 têm métricas globais próximas, mas as arestas mudam tanto entre os blocos 18 e 36 quanto entre os blocos 1 e 18. O restante do projeto mede essa reorganização vértice a vértice (Jaccard das vizinhanças, dominância lexical), com as comunidades (NMI com tipo de token e com contexto) e com a robustez a k , à simetria e ao desempate.