

MO438 – Redes Complexas: Entrega Parcial

Da rede lexical à rede contextual: reorganização das representações internas de Transformers com Redes Complexas

Juliana Midlej do Espirito Santo (RA 200208)

1. Introdução

Na entrada de um Transformer, todas as ocorrências de um mesmo token têm o mesmo *embedding*; ao atravessar as camadas, essas representações incorporam o contexto e se reorganizam. O projeto descreve essa transformação como uma sequência de redes complexas sobre **os mesmos vértices**: cada vértice é uma *ocorrência* de um token em um texto, e cada ocorrência se liga às k ocorrências mais semelhantes a ela. Comparando as redes camada a camada, queremos medir quanto a vizinhança deixa de ser determinada pela identidade do token e passa a refletir o contexto (perguntas P1–P4 da proposta).

Dados do projeto: <https://github.com/annwith/gender-representation-networks>. As quatro redes analisadas aqui estão em [data/graphml/](#), em GraphML (*rede_k10_union.graphml*, cerca de 17 MB cada), com os atributos dos vértices descritos em [data/graphml/README.md](#); as arestas não têm atributos. O script `scripts/partial_delivery/export_networks.py` gera os arquivos e calcula todas as métricas abaixo com `igraph`, a partir dos arquivos relidos do disco. A visualização das redes (item 9) é entregue em um arquivo separado, [entrega-parcial-visualizacao.pdf](#).

2. Origem dos dados e construção das redes

As redes são originais, construídas por nós a partir de duas fontes públicas. Os textos vêm da **Wikipédia em português** (<https://pt.wikipedia.org>, CC BY-SA), obtida pela API MediaWiki a partir de 8 categorias temáticas: física, biologia, economia, política, computação, música, futebol (tema “esporte” nos dados) e geografia. A revisão de cada artigo está em `data/corpus/manifest.csv`. O modelo é o **Qwen3-4B-Base** (36 blocos, revisão 906bfd4), cujo *tokenizer* também define os tokens.

Coleta. Em cada tema, uma busca em largura percorre as subcategorias até a profundidade 2, para em 600 títulos e sorteia 150 artigos. A busca para antes de abrir todas as subcategorias (de 7 de 79 em computação a 98 de 439 em música), e, como a API as lista em ordem alfabética, o corte não é aleatório: os temas são “artigos próximos da categoria raiz”, e não a área inteira, o que basta para o nosso uso (temas bem separados). Outras 16 categorias ligadas a temas (profundidade 1, até 60 artigos cada) reforçam sentidos raros das palavras-alvo (*nota* como cédula, *banco* de areia).

Vértices. Cada vértice é uma *ocorrência*: um token do Qwen3, que pode ser só um pedaço de palavra, numa posição de um parágrafo. São 13.606 ocorrências de 2.864 tipos de token, em 3.230 parágrafos de 1.172 artigos (o corpus tem 17.066 parágrafos de 2.153 artigos), com no máximo 50 ocorrências por tipo (semente 438). O **núcleo** (10.020 vértices, 74%) reúne *todos* os tokens de 80 parágrafos sorteados, 10 por tema, inclusive fragmentos, números e pontuação. Como 80 parágrafos quase não repetem palavras de conteúdo, três estratos acrescentam palavras inteiras sorteadas em outros parágrafos, nos quais o resto do texto serve só de contexto: 11 palavras polissêmicas (**alvos**, 477 ocorrências, com uma cota por tema de sentido, como *banco* em economia, computação e geografia), 6 palavras sem ambiguidade forte (**controles**, 277) e 150 palavras presentes em ao menos 3 temas (**multitemáticas**, 2.832). No total são 6.583 palavras inteiras, 6.345 fragmentos de palavra, 351 números e 327 sinais de pontuação. Como o núcleo tem três quartos dos vértices, as medidas globais descrevem sobretudo texto corrido.

Vetores. Cada parágrafo, precedido do separador `<|endoftext|>`, passa sozinho pelo Qwen3, sem o título nem os outros parágrafos do artigo. O vetor **lex** é a linha do token na matriz de *embeddings*, igual para todas as ocorrências do token; **L01**, **L18** e **L36** são as saídas brutas (antes da normalização final) dos blocos 1, 18 e 36, de dimensão 2560, lidas por *hooks* do PyTorch na posição de cada ocorrência. Como a atenção é causal, o vetor de uma posição depende só do seu token e dos anteriores.

Arestas. Cada ocorrência i escolhe, entre as outras 13.605, de qualquer parágrafo, artigo ou tema, as $k = 10$ de maior cosseno (calculado em `float64`) com o seu vetor x_i ; a comparação entre parágrafos diferentes acontece só no espaço dos vetores. As quatro redes diferem apenas em x_i . Em *lex*, as ocorrências de um mesmo token são idênticas, e os empates são desfeitos ao acaso (semente 0). A relação k -NN é direcionada; as redes entregues e analisadas são as versões **não direcionadas por união**, com aresta $\{i, j\}$ quando j está entre os vizinhos de i ou i entre os de j , de modo que todo vértice

tem grau $\geq k$. As redes não são ponderadas: a aresta não guarda o valor do cosseno. Usamos a união porque clusterização, distâncias e componentes são definidas para grafos não direcionados (na versão direcionada, 82% dos pares ordenados de lex não têm caminho) e porque ela preserva todas as relações de vizinhança, enquanto a versão mútua (aresta só quando i e j se escolhem) descartaria de 39% a 56% dos arcos. A versão direcionada continua sendo usada para os graus de entrada (*hubs*) e a reciprocidade.

3. Análise inicial

Tabela 1: Métricas das quatro redes ($k = 10$, união). *Calculadas de forma exata sobre todos os pares de vértices da maior componente. As duas últimas linhas comparam as redes; o Jaccard é $|E \cap E'|/|E \cup E'|$, com E as arestas da rede e E' as da coluna anterior.

Métrica	lex	L01	L18	L36
Vértices	13.606	13.606	13.606	13.606
Arestas	102.656	97.061	94.739	106.307
Grau médio	15,09	14,27	13,93	15,63
Grau mínimo / máximo	10 / 37	10 / 60	10 / 55	10 / 247
Densidade ($\times 10^{-3}$)	1,109	1,049	1,024	1,149
Transitividade (clusterização global)	0,531	0,548	0,330	0,233
Clusterização local média	0,562	0,618	0,365	0,353
Componentes	44	40	2	2
Maior componente (vértices)	12.388 (91,0%)	12.677 (93,2%)	13.555 (99,6%)	13.556 (99,6%)
Distância média*	7,61	7,08	5,12	5,28
Diâmetro*	18	18	11	11
Arestas entre ocorrências do mesmo token	68,1%	63,6%	38,9%	20,8%
Jaccard das arestas com a rede anterior	—	0,371	0,194	0,163

Tamanho, grau e densidade (itens 1 e 6). As redes têm os mesmos 13.606 vértices e entre 94,7 mil e 106,3 mil arestas, com grau médio entre 13,9 e 15,6. Esse valor fica acima de $k = 10$ porque um vértice também ganha arestas de quem o escolheu como vizinho. As redes são muito esparsas: densidade $\rho = 2|E|/(|V|(|V| - 1)) \approx 10^{-3}$.

Clusterização global (item 2). Reportamos a **transitividade** $C = 3T/\tau$, em que T é o número de triângulos e τ o de triplas conexas, e a **clusterização local média** $\bar{C} = \frac{1}{|V_{\geq 2}|} \sum_{i \in V_{\geq 2}} C_i$, com $C_i = 2T_i/(d_i(d_i - 1))$, em que T_i é o número de triângulos que passam por i e d_i é o grau de i . C_i não é definido quando $d_i < 2$, então a média (e a distribuição de C_i) usa só o conjunto $V_{\geq 2}$ dos vértices de grau ≥ 2 ; aqui $V_{\geq 2} = V$, pois o grau mínimo é 10. Os dois coeficientes são altos nas redes lexical e inicial (0,53–0,62) e caem pela metade nas camadas intermediária e final (0,23–0,37). Ainda assim, ficam duas ordens de grandeza acima da densidade, que é a clusterização esperada em um grafo aleatório com o mesmo número de vértices e de arestas. Na rede lex, as ocorrências de um mesmo token são idênticas e tendem a formar grupos quase completos, o que eleva a clusterização.




Figura 1: À esquerda, a distribuição de graus em escala log-log, como distribuição acumulada complementar $P(K \geq d)$ (item 7). À direita, a distribuição do coeficiente de clusterização local C_i (item 3), em 40 faixas de largura 0,025.

Clusterização local (item 3, Fig. 1). Em lex e L01 a distribuição de C_i se concentra entre 0,5 e 0,85, com um excesso em $C_i = 1$ (vértices cuja vizinhança é um grupo completo). Em L18 e L36 ela se

desloca para um pico perto de 0,2 e uma cauda longa; a mudança atinge a maioria dos vértices.

Distribuição de graus (item 7, Fig. 1). O grau mínimo é sempre $k = 10$. Em lex a cauda é curta (máximo 37); em L01 e L18 ela se alonga (máximos 60 e 55); em L36 ela se torna pesada, com máximo 247. É o fenômeno de *hubness*: na camada final, poucas ocorrências são escolhidas por muitas outras.




Figura 2: Distribuição dos tamanhos das componentes conexas (item 8). Os rótulos dão o tamanho da maior componente; os dois eixos estão em escala logarítmica.

Componentes (item 8, Fig. 2). Lex e L01 têm 44 e 40 componentes: além da gigante (91% e 93% dos vértices), dezenas de componentes de 10 a 50 vértices, cada uma com ocorrências de 1 a 5 tipos de token (por exemplo, as 50 ocorrências de “ão” em lex e as 50 de “para” em L01), que a identidade lexical isola. L18 e L36 têm só 2: a gigante (99,6%) e uma de cerca de 50 vértices, formada por 50 das 80 ocorrências na primeira posição da sequência (em L18, com mais uma; as outras 30 ficam na gigante), cuja representação nessas camadas é muito diferente da das demais.




Figura 3: Distribuição das distâncias entre os pares de vértices da maior componente (itens 4 e 5). A distância média é a média dessa distribuição, e o diâmetro é o maior valor com frequência positiva.

Distância média e diâmetro (itens 4 e 5, Fig. 3). Como lex e L01 não são conexas, as distâncias são calculadas na maior componente, sobre todos os pares, por busca em largura a partir de cada vértice. A distância média cai de 7,6 (lex) e 7,1 (L01) para 5,1–5,3 (L18 e L36), e o diâmetro, de 18 para 11. Um grafo aleatório com o mesmo tamanho e grau médio teria distância média em torno de $\ln |V| / \ln \langle d \rangle \approx 3,5$; as redes contextuais combinam clusterização muito acima da aleatória com distâncias menores.

Comparação entre as redes. Como os vértices são os mesmos, as redes podem ser comparadas aresta a aresta (fim da Tabela 1). As arestas entre ocorrências do mesmo token caem de 68% em lex para 64% em L01, 39% em L18 e 21% em L36. E cada rede guarda poucas arestas da anterior: o Jaccard é 0,19 entre L01 e L18 e 0,16 entre L18 e L36, embora estas duas tenham métricas globais parecidas. Entre lex e L01 (0,37), ele subestima a semelhança: em lex, o desempate sorteia quais cópias idênticas se ligam.

Síntese. Já nas métricas globais, a passagem lex/L01 → L18/L36 aparece como uma reorganização: a clusterização cai, as distâncias encolhem, as componentes isoladas por token se fundem na componente gigante e surgem *hubs*. Lex e L01 são muito parecidas; depois do bloco 1, a reorganização é grande e continua até o último bloco, pois as arestas mudam tanto entre os blocos 18 e 36 quanto entre os blocos 1 e 18. O restante do projeto mede essa reorganização vértice a vértice (Jaccard das vizinhanças, dominância lexical), com as comunidades (NMI com tipo de token e com contexto) e com a robustez a k , à simetrização e ao desempate.