

MO438 – Redes Complexas: Entrega Parcial

Da rede lexical à rede contextual: reorganização das representações internas de Transformers com Redes Complexas

Juliana Midlej do Espirito Santo (RA 200208)

1. Introdução

Na entrada de um Transformer, todas as ocorrências de um mesmo token têm o mesmo *embedding*; ao atravessar as camadas, essas representações incorporam o contexto e se reorganizam. O projeto descreve essa transformação como uma sequência de redes complexas sobre **os mesmos vértices**: cada vértice é uma *ocorrência* de um token em um texto, e cada ocorrência se liga às k ocorrências mais semelhantes a ela. Comparando as redes camada a camada, queremos medir quanto a vizinhança deixa de ser determinada pela identidade do token e passa a refletir o contexto (perguntas P1–P4 da proposta: reorganização local e global, camadas em que ela se concentra, comunidades contextuais e separação das ocorrências de um mesmo token).

Dados do projeto: <https://github.com/annwith/gender-representation-networks>. As quatro redes analisadas aqui estão em GraphML em [data/graphml/](#) (ramo `main-run-results`); o script que as gera, junto com esta análise, é `scripts/partial_delivery/export_networks.py`.

2. Origem dos dados e construção das redes

As redes são originais, construídas por nós; não foram baixadas de um repositório de redes. As duas fontes usadas são públicas:

- **Textos:** Wikipédia em português (<https://pt.wikipedia.org>, licença CC BY-SA), obtida pela API MediaWiki a partir de 8 categorias temáticas (física, biologia, economia, política, computação, música, futebol, geografia). A identificação e a revisão de cada artigo estão em `data/corpus/manifest.csv`, o que permite baixar de novo exatamente o mesmo texto.
- **Modelo:** [Qwen3-4B-Base](#) (Hugging Face, 36 blocos, revisão 906bfd4), cujo *tokenizer* também define os tokens.

Coleta. Em cada tema, uma busca em largura percorre as subcategorias até a profundidade 2 e para em 600 títulos, entre os quais são sorteados 150 artigos. Como a API lista as subcategorias em ordem alfabética, o corte não é aleatório: os oito temas atingiram o limite tendo aberto só parte das subcategorias (de 7 de 79 em computação a 98 de 439 em música), e, nas listas de subcategorias por país de música e futebol, só as do começo do alfabeto foram abertas. Os temas são, portanto, “artigos próximos da categoria raiz”, e não a área inteira, o que basta para o uso que fazemos deles (temas bem separados).

Vértices. 13.606 ocorrências de 2.864 tipos de token, sorteadas em 3.230 parágrafos de 1.172 artigos, com no máximo 50 ocorrências por tipo. São 6.583 palavras inteiras, 6.345 fragmentos de palavra (início ou continuação), 351 números e 327 sinais de pontuação.

Arestas. Cada ocorrência i recebe um vetor x_i e escolhe os $k = 10$ vizinhos de maior similaridade de cosseno (calculada em `float64`). As quatro redes diferem apenas em x_i : **lex**, o *embedding* de entrada do token (ocorrências do mesmo token são idênticas, e os empates são desfeitos ao acaso, semente 0); **L01**, **L18** e **L36**, a saída dos blocos 1, 18 e 36 (inicial, intermediário e final). A relação k-NN é direcionada; as redes entregues e analisadas são as versões **não direcionadas por união**, com aresta $\{i, j\}$ quando j está entre os vizinhos de i ou i entre os de j . Por isso todo vértice tem grau $\geq k$. Usamos a união por dois motivos. Primeiro, clusterização, distâncias, componentes e comunidades são definidas para grafos não direcionados; na versão direcionada, a maioria dos pares não tem caminho (82% dos pares ordenados em `lex`), e a distância média fica infinita. Segundo, a união preserva todas as relações de vizinhança, enquanto a versão mútua (aresta só quando i e j se escolhem) descartaria de 39% a 56% dos arcos e fragmentaria `lex` em 1.497 componentes. A versão direcionada continua sendo usada para os graus de entrada (*hubs*) e a reciprocidade.

Arquivos. `rede_k10_union.graphml`, com `rede` em `lex`, `L01`, `L18` e `L36` (cerca de 16 MB cada). Cada vértice traz o token, a palavra de origem, o tema, o artigo, o contexto textual e as medidas desta análise (grau, clusterização local, componente e comunidade Leiden). Todas as métricas abaixo foram calculadas

com **igraph** a partir dos próprios arquivos GraphML relidos do disco.

3. Análise inicial

Tabela 1: Métricas das quatro redes ($k = 10$, união). *Calculadas de forma exata sobre todos os pares de vértices da maior componente.

Métrica	lex	L01	L18	L36
Vértices	13.606	13.606	13.606	13.606
Arestas	102.656	97.061	94.739	106.307
Grau médio	15,09	14,27	13,93	15,63
Grau mínimo / máximo	10 / 37	10 / 60	10 / 55	10 / 247
Densidade ($\times 10^{-3}$)	1,109	1,049	1,024	1,149
Transitividade (clusterização global)	0,531	0,548	0,330	0,233
Clusterização local média	0,562	0,618	0,365	0,353
Componentes	44	40	2	2
Maior componente (vértices)	12.388 (91,0%)	12.677 (93,2%)	13.555 (99,6%)	13.556 (99,6%)
Distância média*	7,61	7,08	5,12	5,28
Diâmetro*	18	18	11	11

Tamanho, grau e densidade (itens 1 e 6). As redes têm os mesmos 13.606 vértices e entre 94,7 mil e 106,3 mil arestas, com grau médio entre 13,9 e 15,6. Esse valor fica acima de $k = 10$ porque um vértice também ganha arestas de quem o escolheu como vizinho. As redes são muito esparsas: densidade $\rho = 2|E|/(|V|(|V| - 1)) \approx 10^{-3}$.

Clusterização global (item 2). Reportamos os dois coeficientes:

- a **transitividade**, $C = 3 \times (\text{n}^\circ \text{ de triângulos})/(\text{n}^\circ \text{ de triplas conexas})$;
- a **clusterização local média**, $\bar{C} = \frac{1}{|V|} \sum_i C_i$, com $C_i = 2T_i/(d_i(d_i - 1))$, em que T_i é o número de triângulos que passam por i e d_i é o grau de i . Vértices de grau menor que 2 contariam como $C_i = 0$, mas aqui não há nenhum, pois o grau mínimo é 10.

Os dois coeficientes são altos nas redes lexical e inicial (0,53–0,62) e caem pela metade nas camadas intermediária e final (0,23–0,37). Ainda assim, ficam duas ordens de grandeza acima da densidade, que é a clusterização esperada em um grafo aleatório com o mesmo número de vértices e de arestas. Na rede lex, as ocorrências de um mesmo token são idênticas e tendem a formar grupos quase completos, o que eleva a clusterização.




Figura 1: À esquerda, a distribuição de graus em escala log-log, como distribuição acumulada complementar $P(K \geq d)$ (item 7). À direita, a distribuição do coeficiente de clusterização local C_i (item 3), em 40 faixas de largura 0,025.

Clusterização local (item 3, Fig. 1). Em lex e L01 a distribuição de C_i se concentra entre 0,5 e 0,85, com um excesso em $C_i = 1$ (vértices cuja vizinhança é um grupo completo). Em L18 e L36 ela se desloca para um pico perto de 0,2 e uma cauda longa. A mudança atinge a maioria dos vértices; não é efeito de um grupo pequeno.

Distribuição de graus (item 7, Fig. 1). O grau mínimo é sempre $k = 10$. Em lex a cauda é curta (máximo 37); em L01 e L18 ela se alonga (máximos 60 e 55); em L36 ela se torna pesada, com máximo 247. Esse é o fenômeno de *hubness*: na camada final, poucas ocorrências são escolhidas como vizinhas por muitas outras. O fenômeno será estudado na rede direcionada (grau de entrada) no restante do projeto.




Figura 2: Distribuição dos tamanhos das componentes conexas (item 8). Os rótulos dão o tamanho da maior componente; os dois eixos estão em escala logarítmica.

Componentes (item 8, Fig. 2). As redes lex e L01 têm 44 e 40 componentes. Além da gigante (91% e 93% dos vértices), há dezenas de componentes de 10 a 50 vértices, cada uma formada por ocorrências de 1 a 5 tipos de token: por exemplo, as 50 ocorrências de “ão” em lex e as 50 de “para” em L01. Nelas a identidade lexical isola grupos inteiros de ocorrências. Em L18 e L36 restam só 2 componentes: a gigante (99,6%) e uma de cerca de 50 vértices formada pelas ocorrências na primeira posição da sequência, cuja representação nessas camadas é muito diferente das demais.




Figura 3: Distribuição das distâncias entre os pares de vértices da maior componente (itens 4 e 5). A distância média é a média dessa distribuição, e o diâmetro é o maior valor com frequência positiva.

Distância média e diâmetro (itens 4 e 5, Fig. 3). Como lex e L01 não são conexas, as distâncias são calculadas na maior componente, sobre todos os pares, por busca em largura a partir de cada vértice. A distância média cai de 7,6 (lex) e 7,1 (L01) para 5,1–5,3 (L18 e L36), e o diâmetro cai de 18 para 11. Para comparação, um grafo aleatório com o mesmo tamanho e grau médio teria distância média em torno de $\ln |V| / \ln \langle d \rangle \approx 3,5$. As redes contextuais combinam, portanto, clusterização muito acima da aleatória com distâncias mais curtas que as da rede lexical.

Síntese. Já nas métricas globais, a passagem lex/L01 → L18/L36 aparece como uma reorganização: a clusterização cai, as distâncias encolhem, as componentes isoladas por token se fundem na componente gigante e surgem *hubs*. Lex e L01 são muito parecidas, o que sugere que a mudança se concentra entre os blocos 1 e 18. Essa hipótese será testada no restante do projeto com as medidas por vértice (Jaccard das vizinhanças, dominância lexical), com as comunidades (NMI com tipo de token e com contexto) e com a robustez a k , à simetrização e ao desempate.