MO438 – Redes Complexas (Unicamp)

Da rede lexical à rede contextual

Estudo de viabilidade

Juliana Midlej

O que é este documento. O projeto representa a passagem das representações lexicais às contextuais do Qwen3-4B-Base como uma sequência de redes k-NN, em que os vértices são *ocorrências* de tokens em parágrafos da Wikipédia em português. Uma das perguntas, a P4, compara as ocorrências de uma mesma palavra em temas diferentes (por exemplo, *banco* em Economia e em Computação), e por isso exige palavras repetidas o bastante em vários temas. Este estudo foi feito antes do pipeline, para dimensionar a amostra e escolher o modelo. Ele está congelado: os números são de planejamento, vêm de um corpus simplificado e não mudam com as execuções. O método e os resultados do experimento estão no relatório técnico, no repositório (https://github.com/annwith/gender-representation-networks).

Notação. f_t é o número de vértices do tipo (token) t na amostra, e $f_{\max}$ é o limite de vértices por tipo.

Antes de implementar o pipeline, um estudo rápido (scripts em `scripts/feasibility/`) respondeu a três perguntas: (i) a meta de cerca de 15 mil vértices é alcançável com parágrafos inteiros? (ii) Parágrafos inteiros deixam palavras repetidas suficientes, em temas diferentes, para a P4? (iii) Que tokenizer, e portanto que modelo, usar?

Dados do estudo. O `fetch_wiki.py` baixou uma versão simplificada do corpus: os mesmos oito temas, busca até a profundidade 2, 120 artigos por tema, limpeza só com `strip_code` e os mesmos filtros de parágrafo. Resultaram **958 artigos** e **7.876 parágrafos** (Biologia 965, Computação 1.034, Economia 1.147, Esporte 836, Física 948, Geografia 785, Música 1.032, Política 1.129), com **1,28 milhão de tokens** do Qwen3 (1.276.475) e cerca de 23 mil tipos distintos. Três tokenizers foram comparados: o do Qwen3-4B (idêntico ao do Qwen3-4B-Base, 151.669 ids), o do Tucano-2b4 (treinado em português) e o do GPT-2 small português (o modelo do piloto).

Amostragem natural. O `simulate_sample.py` simula a amostragem mais simples: parágrafos inteiros, em rodízio entre os temas, com todos os tokens como vértices e um limite $f_{\max}$ por tipo, até chegar a 15 mil vértices. Também simula uma variante "direcionada", que começa pelos parágrafos que contêm as palavras-alvo (até 12 por palavra e tema) e depois segue a ordem natural. As saídas estão em `sim_<modelo>.txt`.

Desenho híbrido. O `sim_hybrid.py` simula a alternativa adotada: um *núcleo* denso de parágrafos inteiros mais estratos esparsos de ocorrências escolhidas (palavras-alvo, controles e palavras de conteúdo presentes em vários temas), em que só as posições sorteadas viram vértices e o resto do parágrafo é contexto. As saídas estão em `hyb_<modelo>.txt`.

Nas contagens a seguir, *palavra de conteúdo* é um tipo cuja categoria mais comum é palavra inteira, só com letras, com pelo menos 3 letras e fora de uma lista de palavras funcionais. O critério da P4 é ter $f_t \geq 10$ na amostra e pelo menos 3 ocorrências em pelo menos 3 temas.

A Tabela 1 e a Figura 1 mostram três coisas.

A meta de vértices é fácil. Com qualquer tokenizer, 15 mil vértices saem de 100 a 160 parágrafos (de 18 a 21 mil tokens), uma fração pequena do *pool*. Com $f_{\max} = 20$ bastam de 127 a 177 parágrafos.

Parágrafos inteiros não servem para a P4. Mesmo com 15 mil vértices, só de 4 a 9 palavras de conteúdo têm $f_t \geq 10$ com ocorrências espalhadas por 3 temas, e *nenhuma* palavra-alvo chega a 10 ocorrências em 2 temas. O motivo é a lei de Zipf: num trecho pequeno de texto, só palavras funcionais e pontuação se repetem muito; palavras de conteúdo aparecem uma ou duas vezes. Começar pelos

Tabela 1: Estudo de viabilidade: tokenizers e amostragem natural até 15 mil vértices com $f_{\max} = 50$. Fontes: linha `pool:` e bloco `f_max=50, amostragem natural` de `scripts/feasibility/sim_<modelo>.txt`.

	Qwen3-4B	**Tucano-2b4**	**GPT-2 small PT**
Tokens no *pool* de 7.876 parágrafos	1.276.475	953.290	939.895
Tokens por palavra	1,78	1,33	1,31
Palavras-alvo candidatas que são um token só	12 de 16	16 de 16	16 de 16
Parágrafos para chegar a 15 mil vértices	101	134	160
Tipos distintos na amostra	3.693	6.144	6.213
Vértices com $f_t \leq 2$	19%	40%	39%
Vértices que são palavras inteiras	28%	54%	72%
Tipos com $f_t \geq 10$	293	183	170
Conteúdo com $f_t \geq 10$ e ≥ 3 oc. em ≥ 3 temas	4	5	9
Alvos com ≥ 10 oc. em ≥ 2 temas	0	0	0
Variante direcionada (alvos primeiro), $f_{\max} = 50$			
Conteúdo com $f_t \geq 10$ e ≥ 3 oc. em ≥ 3 temas	10	10	21
Alvos com ≥ 10 oc. em ≥ 2 temas	2	1	2

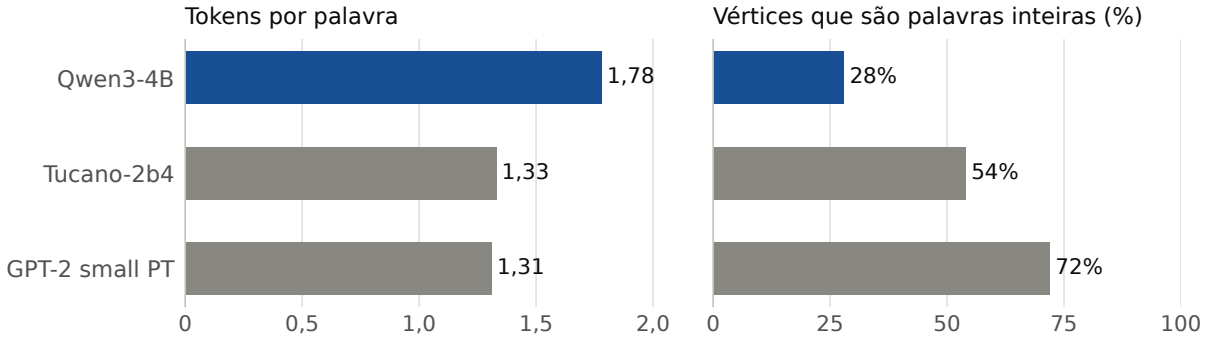


Figura 1: Comparação dos tokenizers no *pool* do estudo de viabilidade: tokens por palavra e fração dos vértices que são palavras inteiras na amostragem natural ($f_{\max} = 50$). O Qwen3 (em destaque) é o tokenizer do modelo escolhido. Fonte: `scripts/feasibility/sim_<modelo>.txt`.

parágrafos que contêm as palavras-alvo (variante direcionada) melhora pouco (de 10 a 21 palavras de conteúdo, 1 ou 2 alvos).

O Qwen3 fragmenta muito o português. São 1,78 tokens por palavra, contra 1,33 do Tucano e 1,31 do GPT-2 português, e só 28% dos vértices são palavras inteiras (54% e 72% nos outros). Quatro das 16 palavras-alvo candidatas não são um token só no Qwen3 (*corrente*, *onda*, *célula* e *núcleo*; por exemplo, "␣célula" vira ␣`cél` + `ula`) e saíram da lista, que ficou com 12. Essa foi a principal desvantagem pesada contra o Qwen3 na escolha do modelo (relatório técnico, seção "Escolha do modelo").

Tabela 2: Estudo de viabilidade: desenho híbrido com 15 mil vértices e $f_{\max} = 50$ (núcleo de parágrafos inteiros, 12 ou 16 alvos, 6 controles e 150 palavras multitema com 20 ocorrências cada). Fonte: `scripts/feasibility/hyb_<modelo>.txt`.

	Qwen3-4B	**Tucano-2b4**	**GPT-2 small PT**
Vértices	15.104	15.002	15.099
núcleo	11.251	10.954	11.045
alvos	553	748	754
controles	300	300	300
multitema	3.000	3.000	3.000
Parágrafos inteiros no núcleo	78	93	107
Vértices por parágrafo do núcleo (média)	144	118	103
Parágrafos tocados no total	2.894	2.943	3.017
Tokens a processar no modelo	329.555	243.959	248.579
Tipos distintos	3.257	4.904	4.856
Vértices com $f_t \leq 2$	17%	32%	30%
Tipos com $f_t \geq 10$	354	274	286
Conteúdo com $f_t \geq 10$ e ≥ 3 oc. em ≥ 3 temas	169	172	173
Alvos com ≥ 10 oc. em ≥ 2 temas	3 de 12	7 de 16	7 de 16
Alvos com ≥ 5 oc. em ≥ 3 temas	11 de 12	14 de 16	14 de 16

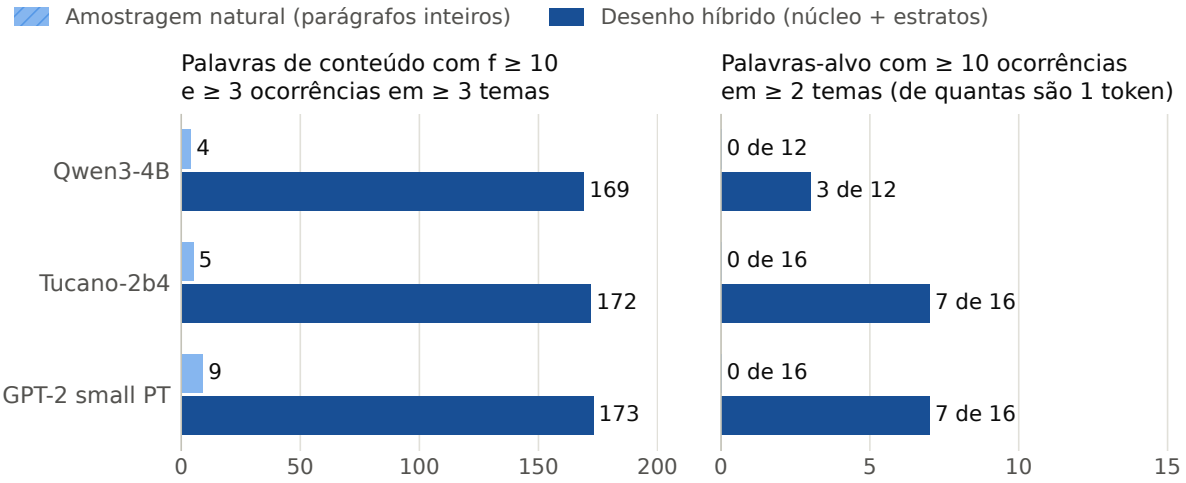


Figura 2: Amostragem natural (parágrafos inteiros, $f_{\max} = 50$) contra o desenho híbrido, nas duas contagens que decidem a P4: palavras de conteúdo repetidas em vários temas e palavras-alvo com ocorrências suficientes em dois temas. Fontes: `scripts/feasibility/sim_<modelo>.txt` e `hyb_<modelo>.txt`.

O desenho híbrido resolve. Com o mesmo número de vértices, o núcleo continua com cerca de 11 mil vértices em 78 a 107 parágrafos inteiros (o bastante para a P3 e para as métricas globais), e o número de palavras de conteúdo com $f_t \geq 10$ espalhadas por 3 temas sobe de 4–9 para cerca de 170 (Tabela 2 e Figura 2). O custo é processar mais texto no modelo: cerca de 330 mil tokens com o Qwen3, porque cada ocorrência esparsa exige o parágrafo até a posição dela.

Na simulação, os alvos ainda ficaram fracos (3 de 12 com ≥ 10 ocorrências em 2 temas), mas por uma razão corrigível: as 50 ocorrências de cada alvo foram sorteadas em rodízio entre os *oito* temas, e não concentradas nos temas em que a palavra tem sentidos diferentes. A Tabela 3 mostra que o

pool tem ocorrências suficientes para cotas por *tema de sentido* na maioria dos casos, e onde faltam (*banco* em Geografia, *órgão* em Biologia, *nota* e *carga* em Economia, *planta* em Economia, *matriz* em Computação), entram as categorias extras do corpus final (relatório técnico, seção "Corpus"). A simulação também tinha dois defeitos de desenho, corrigidos no desenho final (relatório técnico, problema "Limite por ordem de chegada e artigo igual a parágrafo na simulação"): o limite por tipo do núcleo era aplicado por ordem de chegada, e cada parágrafo do núcleo vinha de um artigo diferente.

Tabela 3: Ocorrências das palavras-alvo e de controle no *pool* inteiro do estudo de viabilidade (tokenizer do Qwen3, sem limite por tipo), por tema. Em negrito, os temas de sentido usados nas cotas do desenho final (relatório técnico, tabela de cotas da seção "Amostra híbrida"). Fonte: bloco `pool inteiro` de `scripts/feasibility/sim_Qwen3-4B.txt`.

	Total	**Bio**	**Comp**	**Econ**	**Esp**	**Fís**	**Geo**	**Mús**	**Pol**
banco	66	9	**19**	**24**	6	0	**4**	3	1
campo	335	34	26	22	**74**	**82**	**72**	11	14
órgão	57	**6**	1	6	9	0	0	**25**	**10**
estado	282	24	39	28	13	**84**	19	20	**55**
carga	53	9	4	**6**	0	**22**	0	3	9
rede	133	4	**71**	15	2	11	**15**	3	12
nota	41	2	5	**7**	0	2	0	**24**	1
capital	271	1	0	**201**	18	1	9	6	**35**
família	70	**10**	10	4	4	13	2	13	**14**
massa	140	2	3	10	3	**59**	**39**	14	10
matriz	27	**10**	**3**	2	0	5	0	6	1
planta	35	**25**	0	**0**	0	0	9	0	1
ano	310	13	15	**36**	**82**	35	30	**65**	34
século	356	29	12	31	11	**86**	**66**	59	**62**
grande	527	**58**	48	67	66	**88**	49	77	74
primeiro	510	24	**52**	39	**134**	63	48	92	58
importante	247	**53**	20	**47**	9	24	23	36	35
água	249	**102**	0	24	2	47	**65**	1	8

Os números do estudo são aproximados por construção: o corpus do estudo não removia páginas multitema nem biografias, a limpeza ainda deixava restos de referências e as contagens ignoram os limites por parágrafo e por artigo do desenho final. Eles serviram para escolher o desenho e o modelo; a composição real da amostra está na seção "Amostra híbrida" do relatório técnico.