

MO438 – Redes Complexas

Proposta de Projeto

1. Título

Da rede lexical à rede contextual: reorganização das representações internas de Transformers com Redes Complexas

2. Breve descrição do projeto

Transformers representam tokens por vetores em espaços de alta dimensão. Na entrada do modelo, ocorrências de um mesmo token possuem o mesmo *embedding* lexical. À medida que atravessam as camadas do Transformer, essas representações incorporam informações do contexto e podem se reorganizar no espaço vetorial.

Este projeto propõe representar essa transformação como uma sequência de redes complexas. Os vértices corresponderão a tokens ou ocorrências de tokens, e as arestas conectarão representações semelhantes. A comparação das redes permitirá investigar em que medida a estrutura permanece organizada pela identidade lexical e em que medida passa a refletir o contexto ao longo das camadas.

A hipótese central não é que a identidade lexical desapareça, mas que exista uma reorganização progressiva das vizinhanças e comunidades, cuja intensidade possa ser quantificada por ferramentas de Redes Complexas.

3. Objetivo geral do projeto

Caracterizar, por meio de redes complexas, como a estrutura de similaridade entre representações de tokens se transforma entre o espaço lexical de entrada e as representações contextuais produzidas pelas diferentes camadas de um Transformer.

4. Objetivos específicos do projeto

- Construir uma **rede lexical de tipos**, conectando tokens com embeddings de entrada semelhantes.
- Construir uma **rede lexical por ocorrência** e redes contextuais com aproximadamente 1.5×10^4 ocorrências, mantendo os mesmos vértices em todas as redes para permitir comparação direta.
- Quantificar quanto a **identidade lexical** determina a vizinhança de cada ocorrência em diferentes camadas.
- Verificar a hipótese de que as vizinhanças se reorganizam ao longo das camadas à medida que as representações incorporam informação contextual.
- Identificar e comparar comunidades nas diferentes redes, verificando se sua organização permanece associada aos tipos lexicais ou passa a refletir diferentes contextos.
- Analisar tokens com múltiplas ocorrências, especialmente aqueles encontrados em contextos distintos, buscando identificar separações estruturais entre suas representações.
- Calcular e comparar as principais propriedades das redes: $|V|$, $|E|$, grau médio, distribuição de graus, densidade, clusterização global e local, distância média, diâmetro, componentes conexos e distribuição de seus tamanhos.
- Visualizar a evolução da estrutura das redes ao longo das camadas do Transformer.

5. Origem dos dados

Será utilizada uma amostra de textos reais em português, inicialmente obtida da Wikipédia. Os textos serão processados utilizando o tokenizer do próprio Transformer analisado.

A análise principal utilizará aproximadamente 1.5×10^4 ocorrências de tokens. A frequência por tipo será controlada para impedir que tokens muito frequentes dominem artificialmente a topologia. Tokens especiais serão excluídos e, quando apropriado, a análise será concentrada em tokens de conteúdo.

6. Como os objetivos serão atingidos?

Será utilizado um Transformer aberto, preferencialmente entre 4B e 8B parâmetros. Para cada ocorrência i , serão extraídos seu embedding lexical e_{t_i} e os estados internos $h_i^{(\ell)}$ de camadas representativas do

início, meio e fim do modelo.

Serão construídos três tipos de rede:

1. **Rede lexical de tipos:** um vértice para cada tipo de token, representado por seu embedding de entrada e_t .
2. **Rede lexical por ocorrência:** os vértices são as ocorrências analisadas, mas cada ocorrência i é representada por $x_i = e_{t_i}$. Assim, ocorrências de um mesmo token possuem inicialmente representações idênticas.
3. **Redes contextuais:** os mesmos vértices são representados pelos estados $x_i = h_i^{(\ell)}$ em cada camada ℓ analisada.

A similaridade entre dois vértices será medida pelo cosseno,

$$s_{ij} = \frac{x_i^\top x_j}{\|x_i\| \|x_j\|},$$

e cada vértice será conectado aos seus k vizinhos mais próximos, formando redes k-NN esparsas. O mesmo k e a mesma regra de simetrização serão utilizados em todas as camadas. Diferentes valores de k serão testados como análise de robustez.

A reorganização das vizinhanças será medida pela similaridade de Jaccard entre os conjuntos de vizinhos de uma mesma ocorrência em diferentes camadas. A dominância lexical será medida pela fração de vizinhos de uma ocorrência que correspondem ao mesmo tipo de token.

7. Como os resultados serão avaliados?

O cumprimento dos objetivos será avaliado em três níveis. Primeiro, será verificado se todas as redes propostas puderam ser construídas com escala superior a 10^4 vértices e se as métricas estruturais requeridas pela disciplina foram calculadas.

Segundo, serão comparadas quantitativamente as redes entre camadas. A evolução da dominância lexical indicará quanto a identidade do token continua determinando sua vizinhança, enquanto a similaridade de Jaccard permitirá medir a intensidade da reorganização local. As comunidades e métricas globais mostrarão se essa transformação também ocorre em escalas maiores da rede.

Por fim, serão analisados tokens individuais com múltiplas ocorrências para verificar se representações inicialmente equivalentes passam a ocupar regiões distintas da rede em função do contexto. Os resultados serão testados para diferentes valores de k e limites de frequência.

8. Planejamento e cronograma

- **Semanas 1–2:** seleção do modelo e corpus, definição da amostragem e extração dos embeddings e estados internos.
- **Semanas 2–3:** construção da rede lexical de tipos, da rede lexical por ocorrência e das redes contextuais.
- **Semanas 3–4:** cálculo das métricas estruturais, persistência de vizinhança e dominância lexical.
- **Semanas 4–5:** detecção de comunidades, análise intra-token, visualizações e testes de robustez.
- **Semanas 5–6:** consolidação dos resultados e redação do relatório final.