

MO438 – Redes Complexas

Proposta de Projeto (versão revisada)

1. Título

Da rede lexical à rede contextual: reorganização das representações internas de Transformers com Redes Complexas

2. Breve descrição do projeto

Transformers representam tokens por vetores em espaços de alta dimensão. Na entrada do modelo, todas as ocorrências de um mesmo tipo de token possuem o mesmo *embedding* lexical. À medida que atravessam as camadas do Transformer, essas representações incorporam informações do contexto e podem se reorganizar no espaço vetorial.

Este projeto propõe representar essa transformação como uma sequência de redes complexas. Os vértices corresponderão a tipos de token ou a ocorrências de tokens (Seção 5), e as arestas conectarão representações semelhantes. A comparação das redes permitirá investigar em que medida a estrutura permanece organizada pela identidade lexical e em que medida passa a refletir o contexto ao longo das camadas.

A hipótese central não é que a identidade lexical desapareça, mas que exista uma reorganização progressiva das vizinhanças e comunidades, cuja intensidade possa ser quantificada por ferramentas de Redes Complexas.

3. Objetivo geral do projeto

Caracterizar, por meio de redes complexas, quanto e de que forma a estrutura de similaridade entre representações de tokens se transforma entre o espaço lexical de entrada e as representações contextuais produzidas pelas camadas inicial, intermediária e final de um Transformer.

4. Objetivos específicos do projeto

O projeto buscará responder às seguintes perguntas:

- P1. Quanto e de que forma a organização da rede muda?** Quantificar a reorganização local, pela similaridade de Jaccard entre as vizinhanças de uma mesma ocorrência e pela dominância lexical, e a reorganização global, pela distribuição de graus de entrada (surgimento ou desaparecimento de *hubs*), pela clusterização, pelas distâncias e pelas comunidades. Isso permitirá distinguir uma mudança que apenas troca vizinhos locais de uma mudança que altera a organização em escala maior.
- P2. As mudanças concentram-se em determinadas camadas?** Comparar as transições lexical $\rightarrow$ inicial, inicial $\rightarrow$ intermediária e intermediária $\rightarrow$ final, identificando qual delas concentra a maior queda de Jaccard e de dominância lexical, e verificar se essa resposta depende da faixa de frequência do token e de ele ser uma palavra inteira ou uma subpalavra.
- P3. Surgem comunidades associadas a contextos semelhantes?** Verificar se as comunidades deixam de ser explicadas pelo tipo de token e passam a ser explicadas pelo contexto de origem (documento, sentença ou tema), usando medidas de concordância entre partições e inspeção qualitativa das comunidades.
- P4. Ocorrências de um mesmo token separam-se conforme o contexto?** Para tipos com múltiplas ocorrências, especialmente os encontrados em contextos distintos, verificar se representações inicialmente idênticas passam a ocupar comunidades ou regiões diferentes da rede.

Para responder a essas perguntas, serão realizadas as seguintes etapas:

- Construir uma **rede lexical de tipos**, uma **rede lexical por ocorrência** e **redes contextuais** com aproximadamente 1.5×10^4 ocorrências, mantendo os mesmos vértices em todas as redes por ocorrência para permitir comparação direta.
- Calcular e comparar as principais propriedades das redes: $|V|$, $|E|$, grau médio, distribuição de graus (de entrada e de saída na versão direcionada), densidade, clusterização global e local, distância média,

diâmetro, componentes conexos e distribuição de seus tamanhos.

- Reportar os resultados por faixa de frequência e por categoria de token (palavra inteira ou subpalavra), avaliando sua robustez ao tratamento de empates, ao valor de k e à regra de simetrização.
- Visualizar a evolução da estrutura das redes ao longo das camadas.

5. Terminologia: palavras, tokens e ocorrências

Para permitir a interpretação dos resultados, serão distinguidos:

- **Palavra:** unidade do texto delimitada por espaços e pontuação, antes da tokenização.
- **Token:** unidade produzida pelo tokenizador do modelo, que pode corresponder a uma palavra inteira, a um fragmento de palavra (subpalavra) ou a um sinal de pontuação. No piloto, por exemplo, a palavra “praca” foi dividida nos tokens “pra” e “ca”.
- **Tipo de token:** um elemento do vocabulário (`token_id`), denotado por t . Seu número de ocorrências na amostra é f_t .
- **Ocorrência:** uma instância posicional de um tipo de token em um texto, denotada por i , com tipo t_i .

Cada ocorrência será rotulada como *palavra inteira* (a palavra corresponde a um único token), *início de palavra fragmentada*, *continuação de palavra* ou *pontuação*. As interpretações semânticas e contextuais serão feitas preferencialmente sobre tokens que são palavras inteiras de conteúdo, pois um fragmento como “ca” não tem significado próprio. As métricas serão reportadas separadamente para cada categoria.

6. Origem dos dados

Será utilizada uma amostra de textos reais em português, inicialmente obtida da Wikipédia. Os textos serão processados utilizando o tokenizador do próprio Transformer analisado. Tokens especiais serão excluídos.

Para cada ocorrência serão mantidos o token, o `token_id`, a posição, o documento, a sentença, a palavra de origem, a posição do token dentro da palavra e o contexto textual. Esses metadados são necessários para rotular as ocorrências (Seção 5) e para associar comunidades a contextos (P3).

A análise principal utilizará aproximadamente 1.5×10^4 ocorrências de tokens. Para impedir que tokens muito frequentes dominem artificialmente a topologia, será imposto um limite máximo $f_{\max}$ de ocorrências por tipo. Os tipos serão agrupados em **faixas de frequência** na amostra, inicialmente $f_t \in \{1-2\}$ (raros), $\{3-9\}$, $\{10-49\}$ e $\{\geq 50\}$ (até $f_{\max}$), ajustadas à distribuição observada.

Tokens raros permanecem como vértices, para que o conjunto de vértices seja o mesmo em todas as redes, mas serão excluídos das análises por tipo. Para $f_t = 1$ a dominância lexical é nula por definição, e para $f_t = 2$ ela não passa de $1/k$. Por isso, dominância lexical e análise intra-token serão calculadas apenas para $f_t \geq 3$, com a análise de separação em comunidades (P4) concentrada em $f_t \geq 10$. Como análise complementar, poderá ser selecionado um subconjunto controlado de palavras utilizadas em contextos distintos.

7. Como os objetivos serão atingidos?

7.1 Representações e redes

Será utilizado um Transformer aberto, preferencialmente entre 4B e 8B parâmetros, com L blocos. Para cada ocorrência i , serão extraídos seu embedding lexical e_{t_i} , lido diretamente da matriz de embeddings de entrada, e os estados internos $h_i^{(\ell)}$ na saída de três camadas representativas: o primeiro bloco ($\ell = 1$), um bloco intermediário ($\ell = \lfloor L/2 \rfloor$) e o último bloco ($\ell = L$).

Serão construídos três tipos de rede:

1. **Rede lexical de tipos:** um vértice para cada tipo de token, representado por seu embedding de entrada e_t e com a frequência f_t como atributo.
2. **Rede lexical por ocorrência:** os vértices são as ocorrências analisadas, mas cada ocorrência i é representada por $x_i = e_{t_i}$. Assim, ocorrências de um mesmo tipo possuem inicialmente representações idênticas.
3. **Redes contextuais:** os mesmos vértices são representados pelos estados $x_i = h_i^{(\ell)}$ em cada camada

ℓ analisada.

A similaridade entre dois vértices será medida pelo cosseno,

$$s_{ij} = \frac{x_i^\top x_j}{\|x_i\| \|x_j\|},$$

e cada vértice i escolherá o conjunto N_i de seus k vizinhos mais próximos (excluindo o próprio vértice). O mesmo k e as mesmas regras serão utilizados em todas as redes, e diferentes valores de k serão testados como análise de robustez. Busca aproximada com FAISS poderá ser utilizada para reduzir o custo computacional.

7.2 Direcionalidade

A relação de k vizinhos mais próximos não é simétrica: $j \in N_i$ não implica $i \in N_j$. O objeto produzido pelo k -NN é, portanto, uma **rede direcionada** com arestas $i \rightarrow j$ para $j \in N_i$, na qual todo vértice tem grau de saída exatamente k . Essa versão direcionada será usada para:

- as medidas de vizinhança (Jaccard e dominância lexical), que dependem dos conjuntos N_i de tamanho fixo k ;
- a distribuição de graus de entrada, que revela *hubs* (vértices escolhidos como vizinhos por muitos outros), e a reciprocidade.

Para clusterização, distâncias, diâmetro, componentes conexos e comunidades, será usada a **versão não direcionada por união**, na qual existe a aresta $\{i, j\}$ se $j \in N_i$ ou $i \in N_j$; nela, o grau de cada vértice é pelo menos k . A versão por k -NN mútuo ($j \in N_i$ e $i \in N_j$) será usada como análise de robustez. Distância média e diâmetro serão calculados no maior componente conexo.

7.3 Tratamento de empates

Na rede lexical por ocorrência, as $f_{t_i} - 1$ outras ocorrências do mesmo tipo têm similaridade $s_{ij} = 1$ com i . Se $f_{t_i} - 1 > k$, a escolha de quais delas entram em N_i depende de um desempate arbitrário. Se $f_{t_i} - 1 < k$, as vagas restantes são ocupadas por ocorrências do tipo mais próximo, que também são idênticas entre si e, portanto, também empatam. Como os resultados das redes contextuais são comparados com essa rede inicial, os empates serão tratados explicitamente de três formas:

- (a) **Desempate aleatório com sementes (principal):** entre candidatos empatados na fronteira do k -ésimo vizinho, a escolha será uniforme ao acaso. A construção será repetida com R sementes (por exemplo, $R = 20$), e todas as métricas serão reportadas como média $\pm$ desvio padrão. O Jaccard entre as redes lexicais de duas sementes distintas servirá como nível de referência: uma mudança lexical $\rightarrow$ contextual só será interpretada como reorganização se for maior que a variação produzida pelo próprio desempate. O desempate pela menor posição no texto, usado no piloto, será mantido como caso determinístico de referência.
- (b) **Inclusão de todos os empatados:** cada vértice se conecta a todos os candidatos com similaridade maior ou igual à do k -ésimo vizinho. Essa variante elimina a arbitrariedade, ao custo de um grau de saída variável, e será usada como análise de robustez.
- (c) **Vizinhos de tipos distintos:** as ocorrências do próprio tipo são ignoradas, e cada ocorrência i passa a ter como vizinhança o conjunto T_i dos k tipos distintos ($t \neq t_i$) mais próximos, considerando, para cada tipo, sua ocorrência mais similar a i . Na etapa lexical, T_i é simplesmente o conjunto dos k tipos mais próximos de t_i , o que coincide com a rede lexical de tipos, com f_t como atributo, e não possui empates. Nas camadas contextuais, T_i indica *de quais outros tokens* a ocorrência se aproxima em seu contexto. Essa variante complementa a dominância lexical, que continua sendo calculada nas variantes (a) e (b).

Nas camadas contextuais, empates exatos são praticamente inexistentes; similaridades que diferirem por menos de uma tolerância numérica ε (por exemplo, 10^{-6}) serão tratadas como empates, pela mesma regra.

7.4 Medidas

A reorganização da vizinhança de uma ocorrência entre as redes a e b será medida pela similaridade de Jaccard

$$J_i(a, b) = \frac{|N_i^{(a)} \cap N_i^{(b)}|}{|N_i^{(a)} \cup N_i^{(b)}|},$$

calculada também sobre os conjuntos de tipos T_i na variante (c). A dominância lexical será a fração de vizinhos do mesmo tipo, $D_i^{(\ell)} = |\{j \in N_i^{(\ell)} : t_j = t_i\}|/k$. Comunidades serão identificadas com Leiden ou Louvain na rede não direcionada e comparadas entre camadas por NMI e ARI. Para responder a P3, as partições também serão comparadas com as partições por tipo de token e por documento/sentença, e será medida a pureza de cada comunidade em relação a esses rótulos.

8. Como os resultados serão avaliados?

O cumprimento dos objetivos será avaliado em três níveis. Primeiro, será verificado se todas as redes propostas puderam ser construídas com escala superior a 10^4 vértices e se as métricas estruturais requeridas pela disciplina foram calculadas.

Segundo, as perguntas P1–P3 serão respondidas comparando as redes entre camadas. Para P1, a distribuição de J_i e de D_i indicará quanto a identidade lexical continua determinando a vizinhança, e as métricas globais e a distribuição de graus de entrada mostrarão se a transformação também ocorre em escala maior. Para P2, a transição com a maior queda de Jaccard e de dominância indicará onde a reorganização se concentra. Para P3, a organização será considerada contextual se a concordância das comunidades com o tipo de token diminuir e a concordância com documento/sentença aumentar ao longo das camadas.

Por fim, para P4, serão analisados tipos com múltiplas ocorrências ($f_t \geq 10$), verificando em quantas comunidades suas ocorrências se distribuem e como a similaridade média entre elas evolui.

Todos os resultados serão reportados por faixa de frequência e por categoria de token, como média $\pm$ desvio entre as R sementes de desempate, e repetidos para diferentes valores de k , para as três variantes de tratamento de empates e para as simetrizações por união e mútua. Isso reduz a dependência das conclusões de uma única parametrização.

9. Planejamento e cronograma

- **Semanas 1–2:** seleção do modelo e corpus, definição da amostragem e das faixas de frequência, rotulagem palavra/subpalavra e extração dos embeddings e estados internos.
- **Semanas 2–3:** construção das redes direcionadas e não direcionadas, com as três variantes de tratamento de empates e as R sementes.
- **Semanas 3–4:** cálculo das métricas estruturais, persistência de vizinhança e dominância lexical, por faixa de frequência e categoria.
- **Semanas 4–5:** detecção de comunidades, associação com contextos, análise intra-token, visualizações e testes de robustez.
- **Semanas 5–6:** consolidação dos resultados e redação do relatório final.

10. Trabalhos futuros

- Estender a análise para todas as camadas do modelo, comparando cada camada com a seguinte ($\ell \rightarrow \ell + 1$), para localizar com mais precisão onde a reorganização ocorre.
- Construir redes no nível de palavras, agregando as representações das subpalavras que compõem cada palavra.

11. Resposta às observações da avaliação

Observação	Onde foi tratada
Objetivos além de “medir” e “comparar”	Seção 4: perguntas P1–P4 e forma de respondê-las na Seção 8.
(1) Rede direcionada ou não	Seção 7.2: k-NN direcionado para vizinhanças e graus de entrada; não direcionado por união para as demais métricas; k-NN mútuo como robustez.
(2) Faixas de frequência e tokens raros	Seção 6: faixas de frequência, limite $f_{\max}$ e exclusão de tokens com $f_t \leq 2$ das análises por tipo.
(3) Empates na rede inicial	Seção 7.3: desempate aleatório com R sementes, inclusão de empatados e vizinhos de tipos distintos.
(4) Palavras e tokens	Seção 5: definições e rotulagem de cada ocorrência como palavra inteira ou subpalavra.